Resumen

La congestión vehicular constituye uno de los principales retos de movilidad en entornos urbanos, generando impactos negativos en tiempos de desplazamiento y calidad de vida. Este proyecto aborda dicha problemática mediante el desarrollo de una metodología agnóstica a la topología urbana para la predicción de la congestión vehicular a partir de datos de tráfico.

La propuesta se basa en la construcción de una representación estructurada del sistema vial en forma de grafo, generada a partir de datos históricos de intensidad y ocupación del tráfico. El carácter "agnóstico a la topología urbana" hace referencia a que la metodología no depende directamente de la configuración física específica de una ciudad, sino del comportamiento observado en los datos y de las relaciones identificadas entre los puntos de medida.

La construcción del grafo considera procesos de agrupación y definición de conectividad basados en criterios derivados de los datos, como proximidad espacial y similitud en el comportamiento temporal del tráfico. Sobre esta representación se aplican redes neuronales de grafos para modelar dependencias espacio-temporales y realizar predicciones de congestión vehicular.

El foco principal del trabajo se centra en la metodología de construcción y representación del grafo más que en una arquitectura específica. El resultado es una metodología generalizable y adaptable a diferentes entornos urbanos, que integra modelado estructural y aprendizaje profundo para contribuir a una gestión más eficiente y proactiva de la movilidad urbana.

Descriptores

Congestión vehicular, Sensores de tráfico, Machine Learning, Deep Learning, Predicción espaciotemporal.

Índice general

1. INTRODUCCIÓN **2**

1.1. CONTEXTO Y MOTIVACIÓN 4

1.2. PROBLEMA ABORDADO 5

1.3. ESTRUCTURA DE LA MEMORIA 6

2. ANTECEDENTES Y JUSTIFICACIÓN **7**

2.1. ANTECEDENTES 8

2.2. MOTIVACIONES 8

2.3. JUSTIFICACIÓN 9

3. OBJETIVOS **11**

3.1. OBJETIVO GENERAL 11

3.2. OBJETIVOS ESPECÍFICOS 11

3.3. ALCANCE 12

4. FUNDAMENTOS TEÓRICOS Y ESTADO DEL ARTE **13**

4.1. CONGESTIÓN VEHICULAR Y VARIABLES DE TRÁFICO 13

4.2. PREDICCIÓN ESPACIOTEMPORAL DEL TRÁFICO 17

4.3. GRAFOS APLICADOS A MOVILIDAD URBANA 19

4.4. GRAPH NEURAL NETWORKS 22

4.5. TRABAJOS RELACIONADOS 25

5. PLAN DE GESTIÓN **30**

5.1. METODOLOGÍA DE TRABAJO 30

5.2. PLANIFICACIÓN TEMPORAL 30

5.3. PRESUPUESTO 31

5.3.1. Presupuesto de personal 31

5.3.2. Presupuesto de hardware 32

5.3.3. Presupuesto de software 32
5.3.4. Presupuesto total 32

6. DESARROLLO **34**
6.1. DISEÑO GENERAL 34
6.2. FUENTE DE DATOS Y ESTRUCTURA INICIAL 36
6.3. ANÁLISIS EXPLORATORIO DE DATOS 37
6.4. LIMPIEZA, VALIDACIÓN Y PREPARACIÓN DE DATOS 42
6.5. CONSTRUCCIÓN DEL ÍNDICE DE CONGESTIÓN 44
6.6. DEFINICIÓN DE NODOS DEL GRAFO 44
6.6.1. Sensores tal cual 46
6.6.2. Proximidad 47
6.6.3. Proximidad + comportamiento 49
6.6.4. Proximidad + sentido 53
6.7. CONSTRUCCIÓN DE ARISTAS Y MATRICES DE ADYACENCIA 56
6.7.1. Adyacencia por cercanía 57
6.7.2. Adyacencia por correlación 60
6.8. PREPARACIÓN DE DATASETS PARA GNN 62
6.9. ARQUITECTURA 64
6.9.1. GCN-LSTM 67
6.9.2. GCN-GRU 68
6.9.3. GAT-LSTM 68
6.10. REPRODUCIBILIDAD E IMPLEMENTACIÓN 69

7. EVALUACIÓN Y RESULTADOS **74**
7.1. DISEÑO EXPERIMENTAL 74
7.2. MÉTRICAS DE EVALUACIÓN 76
7.3. RESULTADOS GLOBALES 78
7.3.1. Experimento E1: evaluación con un mes de datos 79
7.3.2. Experimento E2: evaluación con dos meses de datos sobre configuraciones seleccionadas 80
7.3.3. Experimento E3: evaluación con una semana de abril 81
7.3.4. Experimento E4: evaluación con transformación inversa y MAPE 81
7.3.5. Lectura global de los resultados 83
7.4. ANÁLISIS POR TIPO DE ADYACENCIA 83
7.5. ANÁLISIS POR DEFINICIÓN DE NODO 85

7.6. ANÁLISIS POR ARQUITECTURA 86
7.7. ANÁLISIS GRÁFICO DE PREDICCIONES 88
7.8. COSTE COMPUTACIONAL Y ESCALABILIDAD 90

8. CONCLUSIONES **93**
8.1. CONCLUSIONES METODOLÓGICAS 93
8.2. CONCLUSIONES TÉCNICAS 94
8.3. LIMITACIONES 95
8.4. TRABAJO FUTURO 96

9. Valoración Ética del Proyecto **99**

Bibliografía **100**

A. RESULTADOS COMPLETOS DE LAS EJECUCIONES FINALES **102**
A.1. Ranking completo del experimento E1: un mes de datos 102
A.2. Ranking completo del experimento E3: una semana de abril 103
A.3. Ranking completo del experimento E4: transformación inversa y MAPE 105

B. Gráficas de MAE por adyacencia, nodo y modelo **107**
B.1. MAE por adyacencia 107
B.2. MAE por caso de nodo 108
B.3. MAE por modelo 109

C. Gráficas de predicción frente a valor real **110**
C.1. Experimento E1 110
C.2. Experimento E2 111
C.3. Experimento E4 112

Índice de figuras

1.1. Visión general de la metodología propuesta 3
1.2. Motivación de la representación grafo-temporal 5

2.1. Visualización actual del tráfico en Madrid a través del portal Informo. 7

6.1. Flujo general de desarrollo de la metodología 34
6.2. Punto de medida único en un tramo con varios carriles 39
6.3. Puntos de medida diferenciados según maniobra o sentido de circulación 39
6.4. Puntos de medida con la misma denominación en carriles próximos 40
6.5. Evolución mensual de las estadísticas descriptivas de intensidad y ocupación durante 2025. . . 42
6.6. Alternativas de definición de nodos dentro de la arquitectura metodológica 46
6.7. Agrupación espacial de puntos de medida mediante proximidad para 50 y 500 clusters. 48
6.8. Distribución espacial de los dos grupos obtenidos mediante *clustering* de comportamiento. . . 50
6.9. Agrupación final por proximidad y comportamiento con dos niveles de granularidad. 51
6.10. Ejemplo de codificación del sentido de circulación para sensores próximos. 54
6.11. Agrupación por proximidad y sentido para configuraciones cercanas a 50 clusters. 55
6.12. Agrupación por proximidad y sentido para configuraciones cercanas a 500 clusters. 55
6.13. Construcción de matrices de adyacencia en la metodología propuesta 57
6.14. Ejemplo gráfico del proceso de construcción de adyacencia por cercanía. 59
6.15. Esquema de construcción de adyacencia por correlación. 61
6.16. Estructura del dataset grafo-temporal. 64
6.17. Resaltado de la etapa de modelado dentro del flujo metodológico general. 65
6.18. Esquema comparativo de implementación de los modelos. 67
6.19. Estructura reproducible del repositorio. 70
6.20. Flujo de ejecución reproducible. 72

7.1. MAE por tipo de adyacencia en el experimento E1. 84

7.2. MAE por definición de nodo en el experimento E1. 85
7.3. MAE por modelo en el experimento E1. 87
7.4. Predicción v.s valor real nodo 120. 88
7.5. Predicción v.s valor real nodo 480. 89
7.6. Tiempo promedio de ejecución por caso de nodos en E1. 92

B.1. MAE por tipo de adyacencia en los experimentos E2, E3 y E4. 107
B.2. MAE por caso de nodo en los experimentos E2, E3 y E4. 108
B.3. MAE por modelo en los experimentos E2, E3 y E4. 109

C.1. Gráficas de predicción frente a valor real para el experimento E1. 110
C.2. Gráficas de predicción frente a valor real para el experimento E2. 111
C.3. Gráficas de predicción frente a valor real para el experimento E4. 112

Índice de tablas

5.1. Cronograma con las etapas del proyecto y su estimación en horas por semana. 31
5.2. Presupuesto de personal del proyecto. 31
5.3. Presupuesto de hardware del proyecto. 32
5.4. Presupuesto de software del proyecto. 32
5.5. Presupuesto total estimado del proyecto. 33

6.1. Muestra de la estructura tabular del fichero histórico de tráfico. 37
6.2. Muestra de la estructura tabular del fichero de puntos de medida. 37
6.3. Muestra de la asignación de puntos de medida a clusters de proximidad. 49
6.4. Muestra de la asignación de puntos de medida a clusters de proximidad, comportamiento e intersección. 52
6.5. Ejemplo de refinamiento de la agrupación espacial mediante el criterio de comportamiento. . . 52
6.6. Esquema de construcción de adyacencia por cercanía. 58
6.7. Ejemplo de aristas generadas en la adyacencia por correlación. 62
6.8. Elementos principales del dataset grafo-temporal utilizado por los modelos GNN. 63
6.9. Comparación de las arquitecturas evaluadas en el proyecto. 66
6.10. Organización general del repositorio. 70
6.11. Módulos internos del código fuente del proyecto. 71

7.1. Bloques experimentales documentados. 76
7.2. Métricas utilizadas en la evaluación experimental. 78
7.3. Ranking de las diez mejores configuraciones del experimento E1. 79
7.4. Ranking de configuraciones del experimento E2. 80
7.5. Ranking de las diez mejores configuraciones del experimento E3. 81
7.6. Ranking de las diez mejores configuraciones del experimento E4. 82
7.7. Tiempo promedio de ejecución por caso de nodos en E1. 91

A.1. Ranking completo de configuraciones del experimento E1. 103
A.2. Ranking completo de configuraciones del experimento E3. 105
A.3. Ranking completo de configuraciones del experimento E4. 106

Índice de Códigos

7.1. Ejemplo de ejecución del pipeline completo. 75

AGRADECIMIENTOS

- A los profesores Asier Perrallos y Enrique Onieva, por la guía, apoyo y motivación en el desarrollo de este trabajo.

1. INTRODUCCIÓN

La congestión vehicular constituye uno de los principales retos de movilidad actuales. Su impacto se refleja en el aumento de los tiempos de desplazamiento, la pérdida de eficiencia del sistema vial, el incremento del consumo energético y el deterioro de la calidad de vida de los ciudadanos. Aunque las ciudades disponen cada vez de más información procedente de sensores, cámaras y sistemas de monitorización, muchas soluciones se orientan principalmente a describir el estado actual del tráfico. El verdadero desafío consiste en anticipar la congestión antes de que esta se convierta en un problema operativo.

Este trabajo aborda dicho reto mediante el desarrollo de una **metodología agnóstica a la topología urbana** para la predicción de la congestión vehicular mediante la construcción de grafos a partir de datos de tráfico y el uso de redes neuronales. La propuesta parte de una idea central:

> Para predecir la congestión no basta con analizar cada punto de medida como una serie temporal independiente, sino que es necesario representar las relaciones existentes entre distintos puntos de la ciudad.

En este contexto, el tráfico urbano se interpreta como un fenómeno espaciotemporal. Es temporal porque la congestión evoluciona según patrones horarios, días laborales, fines de semana y variaciones de demanda. Es espacial porque el estado de una zona puede estar relacionado con el comportamiento de otras zonas. Sin embargo, estas relaciones no siempre dependen únicamente de la cercanía física o de la conectividad vial directa. Dos puntos alejados pueden presentar patrones de congestión similares, mientras que dos sensores próximos pueden comportarse de forma diferente si corresponden a sentidos de circulación, carriles o bifurcaciones distintas.

La pregunta que guía este trabajo puede formularse de la siguiente manera: ¿es posible predecir la congestión del tráfico sin depender exclusivamente de una topología vial previamente definida? A partir de esta pregunta, se propone una metodología que construye representaciones del sistema urbano en forma de grafo a partir de los datos observados. En dicha representación, los nodos pueden corresponder a sensores individuales o agrupaciones de sensores, mientras que las aristas pueden definirse mediante criterios como la proximidad espacial o la similitud temporal del comportamiento del tráfico.

El carácter “agnóstico a la topología urbana” no implica ignorar por completo la información espacial, sino reducir la dependencia de una estructura vial fija, manual o específica de una ciudad concreta. La metodología utiliza información disponible en los datos (como localización, intensidad y ocupación) para construir distintas

hipótesis de relación entre puntos de medida. De esta forma, el enfoque puede adaptarse a diferentes escenarios urbanos siempre que existan datos de tráfico comparables.

Sobre estas representaciones grafo-temporales se aplican modelos basados en redes neuronales de grafos, capaces de aprender tanto la evolución temporal de la congestión como la relación entre nodos. En particular, se comparan arquitecturas híbridas que combinan componentes gráficos y recurrentes, como GCN-LSTM, GCN-GRU y GAT-LSTM. No obstante, el foco principal del trabajo no se sitúa en defender una arquitectura concreta como solución única, sino en analizar cómo la forma de construir el grafo influye en la capacidad predictiva del sistema.

> La contribución principal de proyecto, está en el diseño y evaluación de una metodología completa para transformar datos brutos de tráfico en una representación grafo-temporal útil para la predicción de congestión.

Esta metodología integra análisis exploratorio, construcción de una variable de congestión, agrupación de sensores, definición de adyacencias, preparación de datasets para GNN, entrenamiento de modelos y evaluación comparativa de resultados. La figura 1.1 ilustra la visión general de la metodología.

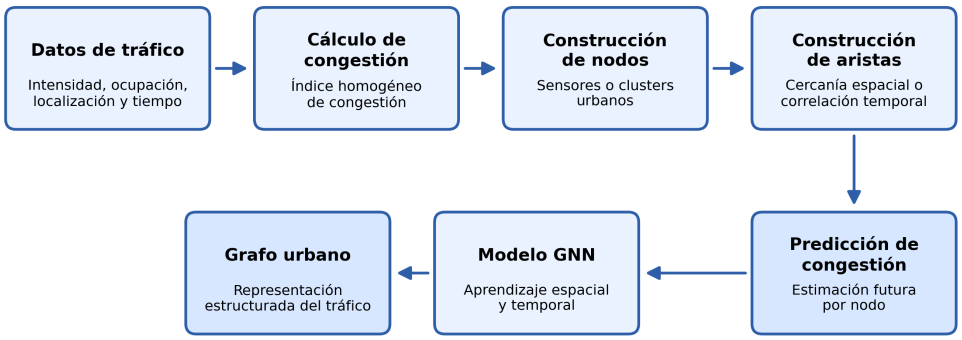

Figura 1.1.: Visión general de la metodología propuesta

1.1. CONTEXTO Y MOTIVACIÓN

En una ciudad, la congestión puede aparecer de forma localizada, propagarse hacia otras zonas o manifestarse simultáneamente en puntos que no necesariamente están próximos. Por ello, la predicción del tráfico requiere métodos capaces de capturar tanto la evolución temporal como las dependencias entre diferentes zonas urbanas.

La disponibilidad de datos abiertos de tráfico ofrece una oportunidad para estudiar este fenómeno desde una perspectiva basada en datos. En el caso de Madrid, los puntos de medida proporcionan información histórica sobre variables como la intensidad y la ocupación, lo que permite construir una variable de congestión para el modelado predictivo.

Sin embargo, trabajar con datos reales de tráfico plantea varios desafíos. En primer lugar, los sensores no siempre tienen una interpretación espacial inmediata. Algunos puntos de medida pueden estar muy próximos entre sí, pero corresponder a carriles, sentidos de circulación o maniobras distintas. En segundo lugar, la presencia de sensores que aparecen y desaparecen entre periodos introduce variabilidad en la estructura de los datos. En tercer lugar, la relación entre zonas urbanas no siempre puede explicarse únicamente mediante distancia física.

Estas dificultades motivan la necesidad de construir una representación flexible del sistema vial. Si se utiliza exclusivamente el mapa de carreteras o la cercanía entre sensores, se puede imponer una estructura que no refleje completamente la dinámica real del tráfico. En cambio, al construir grafos a partir de criterios derivados de los datos, como la proximidad espacial y la similitud en el comportamiento temporal, es posible evaluar distintas formas de representar la ciudad y determinar cuál resulta más útil para la predicción. La Figura 1.2 ilustra esta distinción: mientras que el Enfoque 1 trata cada sensor como una serie temporal independiente —sin capturar relaciones entre ellos—, el Enfoque 2 representa los sensores como nodos de un grafo cuyas conexiones permiten a un modelo espaciotemporal (GNN) aprender tanto del historial temporal de cada nodo como de la influencia entre zonas.

Por ello, este TFM no se limita a aplicar redes neuronales de grafos sobre una estructura ya dada, sino que estudia cómo construir dicha estructura y cómo esta decisión afecta al rendimiento predictivo.

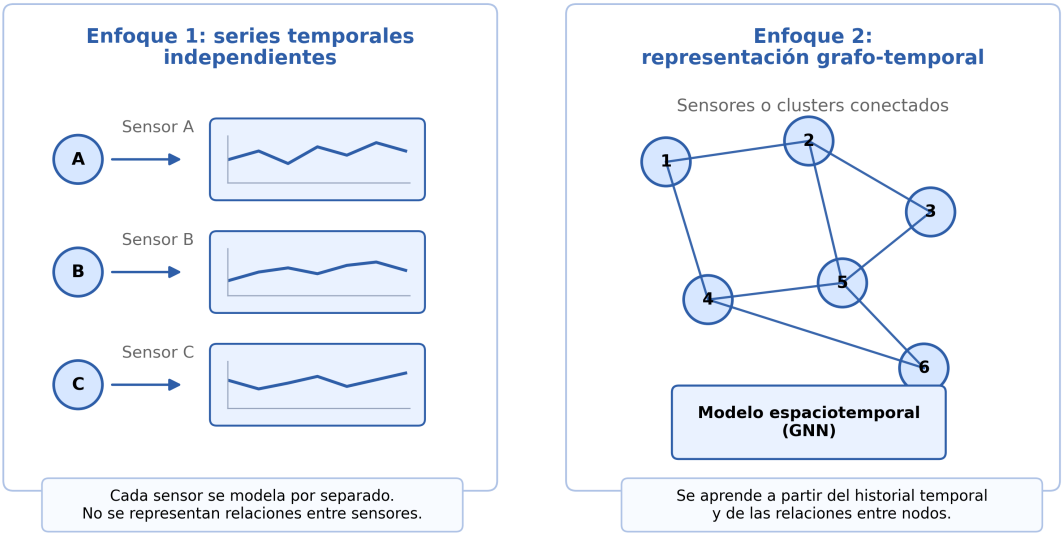

Figura 1.2.: Motivación de la representación grafo-temporal

1.2. PROBLEMA ABORDADO

El problema abordado en este trabajo consiste en predecir la congestión vehicular futura a partir de datos históricos de tráfico urbano. La información disponible se organiza como una serie temporal asociada a diferentes puntos de medida distribuidos en la ciudad. Cada punto registra variables relacionadas con el estado del tráfico: intensidad y ocupación, que permiten estimar el nivel de congestión en intervalos temporales.

Desde el punto de vista del aprendizaje automático, el problema se formula como una tarea de predicción espaciotemporal. Dada una ventana histórica de observaciones de congestión en un conjunto de nodos, se busca estimar la congestión futura de esos mismos nodos. La dificultad principal no reside únicamente en predecir la evolución temporal de cada punto, sino en determinar qué relaciones entre puntos deben considerarse relevantes para el modelo.

Para abordar esta cuestión, el sistema urbano se representa mediante un grafo. En esta estructura, los nodos representan sensores o agrupaciones de sensores, mientras que las aristas representan relaciones entre ellos. Dichas relaciones pueden definirse mediante criterios espaciales, como la cercanía entre centroides, o mediante criterios comportamentales, como la correlación entre series temporales de congestión.

El problema abarca, por tanto, tanto la selección de una arquitectura neuronal como —y con especial énfasis—

las decisiones de construcción del grafo: qué debe considerarse nodo, cómo agrupar sensores, qué tipo de relación define una arista y qué nivel de granularidad conserva mejor la información relevante.

En términos concretos, el trabajo busca responder las siguientes preguntas:

- ¿Qué representación de nodos resulta más adecuada para modelar la congestión urbana: sensores individuales o agrupaciones de sensores?
- ¿Es más informativa una conectividad basada en cercanía física o una conectividad basada en similitud temporal del comportamiento?
- ¿Qué nivel de granularidad, 50 o 500 clusters, permite conservar mejor la información relevante para la predicción?
- ¿Qué impacto tiene la elección de la arquitectura neuronal frente a la elección de la representación del grafo?
- ¿Cómo puede plantearse una metodología que reduzca la dependencia de una topología vial predefinida y sea potencialmente adaptable a otras ciudades?

1.3. ESTRUCTURA DE LA MEMORIA

La memoria se organiza en nueve capítulos. Los Capítulos 1, 2 y 3 enmarcan el trabajo: presentan el problema, los antecedentes y los objetivos. El Capítulo 4 desarrolla el marco teórico y el estado del arte, y el Capítulo 5 recoge el plan de gestión. El Capítulo 6 constituye el núcleo metodológico, donde se describe el flujo completo de construcción de la representación grafo-temporal. El Capítulo 7 presenta la evaluación experimental y el análisis de resultados. Finalmente, el Capítulo 8 expone las conclusiones, limitaciones y líneas de trabajo futuro, y el Capítulo 9 recoge la valoración ética del proyecto. El Apéndice incluye las tablas completas de resultados y gráficas de todos los experimentos realizados.

2. ANTECEDENTES Y JUSTIFICACIÓN

La ciudad de Madrid dispone actualmente de diferentes recursos públicos para consultar y analizar el estado del tráfico. A través del portal de movilidad Informo y del Portal de Datos Abiertos del Ayuntamiento de Madrid, es posible acceder a información relacionada con cámaras de tráfico, incidencias en vía pública, ubicación de puntos de medida y datos de intensidad del tráfico. Estos recursos permiten observar el estado de la movilidad urbana y constituyen una base relevante para el análisis de la congestión.

En particular, el conjunto de datos de tráfico en tiempo real se actualiza casi en tiempo real, con una periodicidad aproximada de cinco minutos. El propio portal indica que esta frecuencia permite obtener mediciones representativas tras varios ciclos semafóricos y que los datos pueden visualizarse junto con otra información de tráfico en la web Informo (Ver Figura 2.1). Además, el conjunto incluye información relacionada con intensidad del tráfico y coordenadas de medición, lo que permite vincular las observaciones con una localización espacial concreta.

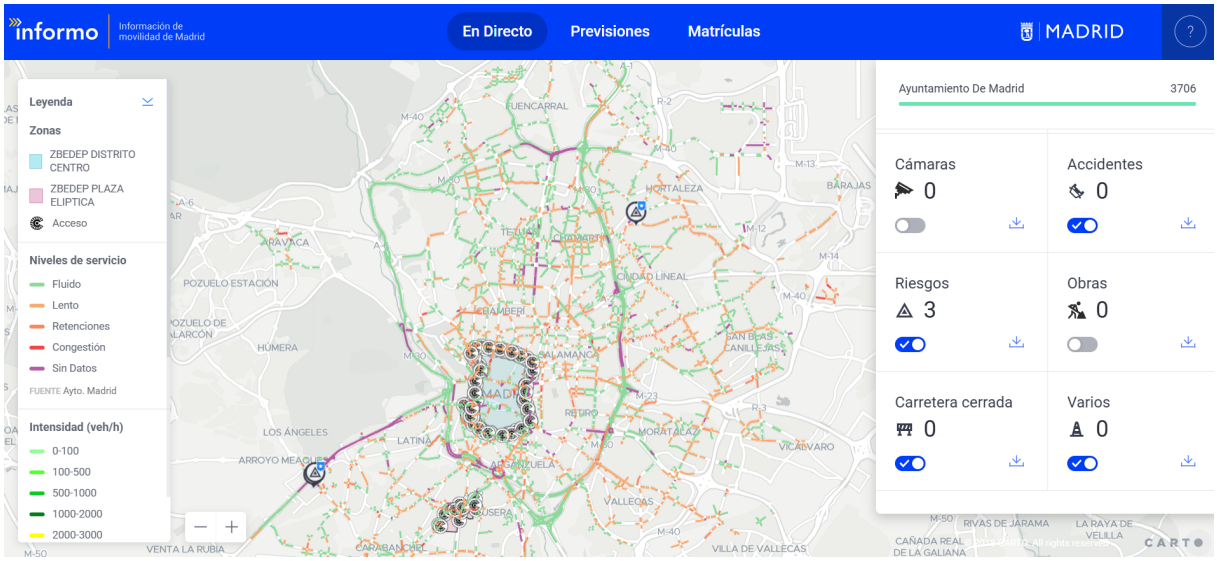

Figura 2.1.: Visualización actual del tráfico en Madrid a través del portal Informo.

Junto a estos datos en tiempo real, el Ayuntamiento de Madrid publica información histórica de puntos de medida y datos de ubicación de los sensores, accesibles como ficheros descargables organizados por mes y año. Asimismo, el portal incluye cámaras fijas con capturas periódicas orientadas a conocer la situación del tráfico o eventos que puedan afectar a la movilidad.

Estos sistemas resultan útiles para la supervisión y consulta del tráfico actual. Sin embargo, su función principal es mostrar lo que está ocurriendo o lo que ha ocurrido, no anticipar de forma sistemática la congestión futura en cada punto de la red. Esta diferencia es fundamental para el presente TFM: el trabajo no busca sustituir las herramientas de visualización existentes, sino aprovechar los datos que estas ponen a disposición para construir una metodología predictiva.

2.1. ANTECEDENTES

Los antecedentes directos de este trabajo se encuentran en los sistemas actuales de monitorización del tráfico urbano y en la disponibilidad de datos abiertos asociados a la movilidad. En el caso de Madrid, la información disponible permite observar el tráfico desde varias perspectivas: imágenes de cámaras, incidencias en vía pública, localización de puntos de medida y registros de intensidad del tráfico.

Las cámaras de tráfico ofrecen una visión visual e inmediata de determinados puntos de la ciudad. Este tipo de recurso es útil para verificar el estado de una vía concreta, identificar retenciones visibles o comprobar incidencias. No obstante, su uso está orientado principalmente a la observación y gestión operativa, no a la construcción directa de un modelo predictivo sobre toda la red urbana.

Por otra parte, los puntos de medida permiten disponer de registros estructurados de tráfico. Estos datos son especialmente relevantes para un enfoque de ciencia de datos porque no dependen únicamente de una observación visual, sino que proporcionan mediciones numéricas asociadas a localización y tiempo. En este trabajo, este tipo de información constituye la base para construir series temporales, calcular un índice de congestión y definir una representación grafo-temporal del sistema urbano.

El antecedente práctico más importante, por tanto, no es solo la existencia de modelos predictivos en la literatura, sino la existencia de una infraestructura pública de datos que permite pasar de la consulta del tráfico actual al análisis histórico y, posteriormente, a la predicción. El proyecto parte de esa disponibilidad de datos y plantea una metodología para transformar mediciones de tráfico en una estructura adecuada para modelos de aprendizaje profundo sobre grafos.

2.2. MOTIVACIONES

La primera motivación del trabajo surge de la diferencia entre monitorizar y predecir. Las herramientas actuales permiten consultar el estado del tráfico, visualizar cámaras o acceder a datos actualizados, pero la gestión de

la movilidad requiere anticipar posibles estados de congestión.

La segunda motivación está relacionada con la estructura de los datos. Los registros de tráfico no son únicamente observaciones temporales independientes, ya que cada punto de medida pertenece a un sistema urbano más amplio. La congestión en un punto puede estar relacionada con otros puntos cercanos, con zonas similares o con patrones de movilidad compartidos. Por ello, resulta necesario representar no solo la evolución temporal de cada sensor, sino también las relaciones entre sensores o agrupaciones de sensores.

La tercera motivación se deriva de la complejidad de la red urbana. Aunque el mapa de carreteras aporta información valiosa, depender exclusivamente de una topología vial fija puede ser restrictivo. En la práctica, dos puntos próximos pueden corresponder a sentidos de circulación distintos, bifurcaciones o carriles con funciones diferentes. Por esta razón, el trabajo propone construir grafos a partir de los datos observados, considerando tanto criterios espaciales como criterios de comportamiento temporal.

Finalmente, existe una motivación metodológica:

> Analizar hasta qué punto la forma de representar los datos condiciona la calidad de la predicción. Esta pregunta convierte la construcción del grafo —y no solo el entrenamiento de un modelo— en el objeto central de estudio.

2.3. JUSTIFICACIÓN

El proyecto se justifica por la disponibilidad de datos públicos de tráfico y por la necesidad de convertirlos en información predictiva útil. Madrid dispone de fuentes que permiten consultar el estado actual de la movilidad y acceder a datos históricos y en tiempo real. Sin embargo, disponer de datos no implica automáticamente contar con una metodología capaz de anticipar congestión. Para ello es necesario procesar los registros, construir una variable objetivo, representar las relaciones entre puntos de medida y evaluar modelos predictivos adecuados.

La propuesta de este trabajo responde a esta necesidad mediante una metodología agnóstica a la topología urbana. Esto significa que el enfoque no depende exclusivamente de una representación manual o fija del mapa vial, sino que construye relaciones entre puntos de medida a partir de los datos disponibles. En particular, se comparan relaciones basadas en cercanía espacial y relaciones basadas en similitud temporal del comportamiento del tráfico.

Desde el punto de vista académico, el valor del trabajo reside en estudiar cómo la construcción del grafo afecta

al rendimiento predictivo. En lugar de limitarse a aplicar un modelo sobre los datos originales, se comparan diferentes decisiones de representación: sensores individuales o clusters, granularidades de 50 y 500 nodos, adyacencia por cercanía o por correlación, y distintas arquitecturas basadas en redes neuronales de grafos. De esta forma, el trabajo aporta una metodología reproducible para pasar de datos públicos de tráfico a un sistema experimental de predicción de congestión.

3. OBJETIVOS

3.1. OBJETIVO GENERAL

El objetivo general de este trabajo es desarrollar y evaluar una metodología agnóstica a la topología urbana para la predicción de la congestión vehicular, mediante la construcción de grafos a partir de datos históricos de tráfico y el uso de modelos basados en redes neuronales de grafos.

Este objetivo integra tres aspectos: en primer lugar, la construcción de una variable de congestión a partir de las variables de tráfico disponibles, en segundo lugar, la generación de distintas representaciones grafo-temporales del sistema urbano, considerando diferentes criterios para definir nodos y aristas y en tercer lugar, la evaluación de modelos neuronales capaces de aprender dependencias espaciales y temporales sobre dichas representaciones.

3.2. OBJETIVOS ESPECÍFICOS

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

1. **Analizar y caracterizar los datos históricos de tráfico urbano.** Este objetivo incluye la revisión de los puntos de medida, las variables disponibles, la frecuencia temporal, la presencia de valores faltantes o inconsistentes, la variabilidad de sensores entre periodos y los patrones generales de movilidad.

2. **Construir una variable objetivo de congestión vehicular.** Dado que no todas las variables oficiales están disponibles de forma homogénea, se busca definir un índice de congestión a partir de intensidad y ocupación, de manera que pueda utilizarse como señal principal para el modelado predictivo.

3. **Diseñar distintas estrategias de definición de nodos del grafo.** Se consideran sensores individuales y agrupaciones de sensores basadas en proximidad espacial, similitud de comportamiento temporal y sentido de circulación, con el fin de analizar cómo la definición de nodo afecta a la predicción.

4. **Construir y comparar diferentes criterios de conectividad entre nodos.** Este objetivo incluye la generación de adyacencias por cercanía espacial y por correlación temporal, representando dos hipótesis distintas sobre la relación entre zonas urbanas.

5. **Preparar datasets espaciotemporales compatibles con redes neuronales de grafos.** Se generan ven-

tanas temporales de entrada, variables de congestión por nodo, variable objetivo futura, índices de aristas y pesos asociados, siguiendo el formato requerido para el entrenamiento de modelos GNN.

6. **Entrenar y evaluar modelos híbridos de aprendizaje profundo.** Se comparan arquitecturas que combinan componentes gráficos y temporales, concretamente GCN-LSTM, GCN-GRU y GAT-LSTM, para analizar su comportamiento en la predicción de congestión.

7. **Analizar el impacto de las decisiones de representación sobre el rendimiento predictivo.** Se estudia la influencia del tipo de nodo, el número de clusters, el criterio de adyacencia, la arquitectura neuronal, la cantidad de datos y el coste computacional.

8. **Plantear la proyección de la metodología hacia escenarios de uso en tiempo real.** Se analiza cómo el enfoque desarrollado podría adaptarse a datos actualizados periódicamente, con el objetivo de generar predicciones operativas o alertas tempranas de congestión.

3.3. ALCANCE

El alcance del TFM comprende el diseño, implementación y evaluación experimental de una metodología para la predicción de congestión vehicular mediante grafos y redes neuronales de grafos. El caso de estudio se desarrolla sobre datos de tráfico de Madrid, utilizando información histórica de puntos de medida y variables asociadas al estado del tráfico.

El trabajo incluye el análisis exploratorio de los datos, la construcción de un índice de congestión, la definición de distintas agrupaciones de sensores, la construcción de matrices de adyacencia, la preparación de datasets para modelos GNN, el entrenamiento de arquitecturas espaciotemporales y la evaluación comparativa de resultados. También se incluye una proyección conceptual hacia un posible uso con datos en tiempo real.

Asimismo, aunque la metodología se plantea como agnóstica a la topología urbana, esto no significa que ignore por completo la dimensión espacial. El trabajo utiliza coordenadas y criterios espaciales cuando son necesarios, pero evita depender exclusivamente de una topología vial fija o manualmente definida. La idea central es construir representaciones flexibles a partir de los datos observados, de forma que la metodología pueda adaptarse a otros entornos urbanos con datos equivalentes.

4. FUNDAMENTOS TEÓRICOS Y ESTADO DEL ARTE

Este capítulo desarrolla el marco teórico que sustenta las decisiones metodológicas del trabajo. Su propósito es justificar, desde la literatura y desde la documentación técnica disponible, tres decisiones centrales del proyecto: la construcción de una variable propia de congestión, la formulación del tráfico como un problema espaciotemporal y la representación del sistema urbano mediante grafos.

4.1. CONGESTIÓN VEHICULAR Y VARIABLES DE TRÁFICO

La **congestión vehicular** puede definirse, desde una perspectiva operativa, como una **condición en la que existe un exceso de vehículos en una sección de vía en un momento determinado**, lo que provoca velocidades inferiores a las habituales o de flujo libre y puede derivar en tráfico intermitente o detenido [1]. De forma complementaria, la FHWA señala que la congestión ocurre cuando **la demanda de tráfico se aproxima o supera la capacidad disponible del sistema vial** [2]. Esta segunda formulación resulta especialmente relevante para el presente trabajo, ya que permite interpretar la congestión como una relación entre la demanda observada y la capacidad o saturación de la infraestructura.

En el análisis de tráfico, esta relación entre demanda, capacidad y desempeño operativo constituye una base conceptual ampliamente utilizada. El Highway Capacity Manual sitúa la evaluación de la capacidad, el nivel de servicio y la gestión activa del tráfico como elementos centrales para analizar el funcionamiento de las infraestructuras viarias [3]. En consecuencia, la congestión no puede entenderse únicamente como un volumen elevado de vehículos, sino como una degradación del estado operativo de la vía asociada al grado de utilización de su capacidad.

En este trabajo, la congestión se aborda como una variable continua construida a partir de mediciones observables de tráfico. Esta decisión responde a las características del conjunto de datos empleado. La documentación oficial del Ayuntamiento de Madrid indica que los datos históricos proceden de puntos de medida de tráfico y que los sistemas de control integran automáticamente la información de los puntos de medida en periodos de 15 minutos [4], como se describe en detalle en la Sección 6.2. Entre las variables disponibles se encuentran la intensidad, la ocupación, la carga y la velocidad media.

La **intensidad** se define como el número de vehículos observado en el periodo de 15 minutos, expresado en vehículos por hora. Por tanto, el número efectivo de vehículos que han circulado durante ese intervalo se obtiene dividiendo la intensidad entre cuatro, aunque la variable se publica en unidades de vehículos/hora [4]. En

este trabajo, la intensidad se interpreta como una medida de demanda observada en cada punto de medida.

La **ocupación** representa el porcentaje de tiempo durante el cual el detector se encuentra ocupado por la presencia de un vehículo dentro del intervalo de integración. Según la documentación del conjunto de datos, una ocupación del 50 % en un periodo de 15 minutos significa que el detector estuvo ocupado durante 7 minutos y 30 segundos [4]. Esta variable aporta información complementaria a la intensidad, ya que no solo describe cuántos vehículos atraviesan el punto de medida, sino también durante cuánto tiempo el detector permanece ocupado.

La variable **carga** es el indicador oficial más próximo al concepto de congestión dentro del conjunto de datos. El Ayuntamiento de Madrid la define como un parámetro sintético que estima el grado de congestión o saturación del vial en el periodo de 15 minutos, calculado a partir de intensidad y ocupación, con determinados factores de corrección. Esta variable se expresa en una escala de 0 a 100, donde 0 representa una vía vacía y 100 una situación de colapso [4].

No obstante, la propia documentación oficial advierte que la **carga** no es un dato primario, sino un valor sintético dependiente de fórmulas y parámetros ajustados empíricamente según las características de la vía y del entorno. Además, con carácter general, en M30 no se calcula este parámetro y su valor puede aparecer como cero, aunque existen excepciones para algunos puntos de medida [4]. Por tanto, aunque la carga resulta conceptualmente relevante, no ofrece la homogeneidad necesaria para utilizarse como variable objetivo general en este trabajo.

La **velocidad media** tampoco constituye una variable adecuada para construir una medida universal de congestión, ya que la documentación oficial especifica que vmed solo está disponible para puntos de medida interurbanos M30 [4]. Esta limitación impide definir una variable objetivo basada en velocidad para todos los tipos de elementos incluidos en el conjunto de datos.

A partir de estas restricciones, el trabajo construye un índice propio de congestión utilizando las dos variables disponibles de forma más consistente: intensidad y ocupación. Esta decisión se fundamenta en dos criterios. En primer lugar, desde el punto de vista del análisis de capacidad vial, la congestión puede relacionarse con la proximidad entre la demanda observada y la capacidad o saturación de la infraestructura [2, 3]. En segundo lugar, los datos procedentes de detectores de tráfico contienen información relevante sobre el estado operativo de la circulación. Coifman [5] muestra que los datos de detectores de lazo pueden utilizarse para estimar tiempos de viaje y trayectorias de vehículos, lo que respalda su valor como fuente de información para inferir condiciones de tráfico.

La formulación del índice parte de la intensidad I, expresada en vehículos por hora $(\mathrm{veh/h})$, y de la ocupación O, expresada como porcentaje del intervalo de 15 minutos. En ambos casos, los valores negativos se tratan como datos faltantes, de acuerdo con la interpretación establecida en la documentación oficial del conjunto de datos y en el procedimiento metodológico definido para este proyecto [4].

En primer lugar, la ocupación se transforma a tanto por uno:

$$TO = \frac{O}{100}$$

Donde TO representa el tiempo de ocupación normalizado en el intervalo $[0, 1]$.

Aunque el número efectivo de vehículos del intervalo podría expresarse como $(I/4)$, en este trabajo se conserva la intensidad en vehículos/hora. Esta decisión mantiene la coherencia con el concepto de demanda/capacidad, que habitualmente se expresa en términos de vehículos por hora.

Como no se dispone de la capacidad física real de cada tramo o detector, se estima una intensidad de saturación empírica para cada detector j. Esta intensidad se define como el percentil 98 de las intensidades válidas observadas en dicho detector:

$$I_{s,j} = P_{98}(I_j)$$

Esta aproximación no pretende sustituir una estimación detallada de la capacidad de la vía. Su función es proporcionar una referencia empírica específica por detector, suficientemente robusta para normalizar la demanda observada y permitir la comparación entre puntos de medida.

A partir de la intensidad de saturación estimada, se calcula el grado de saturación:

$$Y = \frac{I}{I_{s,j}}$$

Posteriormente, el valor de Y se recorta al intervalo $[0, 1]$, evitando que observaciones extremas generen valores fuera del rango interpretativo del índice:

$$Y \leftarrow \min\left(\max(Y, 0), 1\right)$$

Finalmente, el índice de congestión se define como:

$$C = Y + (1 - Y) \cdot TO$$

donde C toma valores entre 0 y 1. La formulación combina dos componentes complementarias. Cuando la intensidad observada se aproxima a la intensidad de saturación estimada del detector, el término Y domina y el índice se aproxima a 1. En cambio, cuando la intensidad es moderada pero la ocupación es elevada, el término $(1 - Y) \cdot TO$ incrementa el valor del índice, permitiendo capturar condiciones compatibles con cola, retención o pérdida de fluidez.

Esta construcción resulta coherente con la interpretación oficial de la carga publicada por el Ayuntamiento de Madrid, ya que dicha variable también combina la relación entre intensidad e intensidad de saturación con el tiempo de ocupación. Sin embargo, el índice propuesto se diferencia en que evita depender de coeficientes de carga ajustados localmente y utiliza una referencia empírica homogénea basada en el percentil 98 de cada detector [4].

El índice resultante permite disponer de una variable continua, normalizada e interpretable para todos los puntos de medida con registros válidos de intensidad y ocupación. Su objetivo no es reproducir exactamente la variable oficial carga, sino construir una señal homogénea y técnicamente justificada para el modelado predictivo. **Esta decisión es fundamental porque transforma las mediciones originales de tráfico en una variable objetivo comparable entre sensores y periodos temporales.**

Desde el punto de vista metodológico, la construcción del índice constituye el primer paso para formular el problema como una tarea de predicción espaciotemporal. Una vez calculada la congestión para cada punto de medida y periodo temporal, cada sensor queda asociado a una serie temporal. Posteriormente, estas series pueden organizarse mediante grafos, en los que los nodos representan sensores o agrupaciones de sensores y las aristas representan relaciones espaciales o comportamentales entre ellos.

4.2. PREDICCIÓN ESPACIOTEMPORAL DEL TRÁFICO

La predicción espaciotemporal se ocupa de anticipar la evolución de variables que dependen simultáneamente del lugar y del tiempo. A diferencia de un enfoque puramente temporal, que modela cada serie de forma aislada a partir de sus valores pasados, un enfoque espaciotemporal incorpora también relaciones entre ubicaciones, sensores o regiones. Semper Lloret [6] define este tipo de predicción como aquella que integra patrones de covariación geográfica y dinámica temporal dentro de un mismo marco de modelado, precisamente para capturar dependencias cruzadas entre ambas dimensiones.

En el contexto de este trabajo, la variable de interés es la congestión estimada en cada punto de medida o agrupación de puntos. Tras construir el índice de congestión a partir de intensidad y ocupación, cada sensor queda asociado a una serie temporal. Sin embargo, el tráfico urbano no se comporta como un conjunto de series independientes: la evolución de un punto puede estar relacionada con la de otros puntos cercanos, con sensores funcionalmente similares o con zonas que presentan patrones temporales parecidos. Por ello, el problema se formula como una tarea de predicción espaciotemporal sobre grafos.

Formalmente, en cada instante temporal t, el sistema puede representarse mediante una matriz de características:

$$X_t \in \mathbb{R}^{N \times F}$$

donde N es el número de nodos del grafo y F el número de variables disponibles por nodo.

Al considerar una ventana histórica de longitud T, los datos de entrada se organizan como un bloque espaciotemporal de dimensión:

$$X \in \mathbb{R}^{T \times N \times F}$$

Esta representación coincide con el esquema de bloques espaciotemporales descrito por Semper Lloret, donde los datos se estructuran a partir de nodos, pasos temporales y características por nodo [6]. En este trabajo, dicha estructura permite que el modelo reciba simultáneamente la evolución reciente de la congestión y la información asociada a la organización relacional de los sensores.

El objetivo predictivo consiste en aprender una función f_θ capaz de estimar la congestión futura para todos los

nodos del grafo a partir de una ventana temporal pasada y de una matriz de adyacencia A:

$$\hat{Y}_{t+h} = f_\theta \left(X_{t-T+1}, X_{t-T+2}, \ldots, X_t, A \right)$$

donde A codifica las relaciones entre nodos, h representa el horizonte de predicción y $\hat{Y}_{t+h}$ corresponde a la congestión estimada en el instante futuro. En este TFM, la matriz A no se considera un elemento secundario, sino una parte central de la metodología, ya que permite comparar distintas hipótesis sobre cómo se relacionan los sensores: por cercanía espacial o por similitud temporal.

Esta formulación justifica el uso de arquitecturas híbridas que separan, pero integran, dos tipos de aprendizaje. Por una parte, se requiere un componente espacial capaz de propagar información entre nodos conectados. Por otra, se necesita un componente temporal capaz de aprender la evolución secuencial de la congestión. Semper Lloret [6] señala que, para problemas espaciotemporales, las GNN espaciales suelen combinarse con módulos temporales, como GRU, LSTM o convoluciones temporales, con el fin de integrar actualización espacial y dinámica temporal en un mismo modelo.

La pertinencia de esta combinación también aparece en trabajos específicos de predicción de tráfico. Zhao et al. [7] proponen T-GCN, una arquitectura que combina Graph Convolutional Networks y Gated Recurrent Units para capturar, respectivamente, dependencias espaciales y temporales en redes urbanas de tráfico. De forma similar, Cui et al. [8] plantean TGC-LSTM, un marco que aprende la red de tráfico como un grafo y utiliza una arquitectura de tipo Graph Convolutional Long Short-Term Memory para modelar interacciones entre vías y predecir el estado del tráfico a escala de red. Estos trabajos respaldan la idoneidad de combinar componentes de grafos con mecanismos recurrentes para problemas de tráfico.

En este trabajo se emplean tres arquitecturas híbridas con esa misma lógica —GCN-LSTM, GCN-GRU y GAT-LSTM—, cuya descripción detallada se recoge en la Sección 4.4.

La selección de estas tres arquitecturas responde a una decisión metodológica concreta. GCN-LSTM y GCN-GRU permiten comparar dos mecanismos temporales distintos manteniendo constante el componente espacial basado en convolución de grafos. Por su parte, GAT-LSTM permite comparar una variante espacial basada en atención frente a la agregación por convolución. De este modo, la evaluación posterior no se limita a determinar qué modelo obtiene menor error, sino que permite analizar cómo influyen las decisiones de representación espacial y temporal en la predicción de congestión.

Esta relación entre representación y modelado es central en el TFM. La predicción espaciotemporal no se en-

tiende únicamente como la aplicación de una red neuronal a datos históricos, sino como una cadena metodológica en la que primero se define una variable homogénea de congestión, después se organizan los sensores como nodos, luego se construyen aristas entre ellos y finalmente se aplican modelos híbridos capaces de aprender dependencias entre nodos y evolución temporal. Esta visión es coherente con el marco metodológico de Semper Lloret [6], donde se destaca la importancia de integrar construcción de grafos, diseño de arquitecturas y evaluación reproducible en problemas espaciotemporales.

En síntesis, formular el tráfico como un problema espaciotemporal permite representar dos dimensiones esenciales de la congestión urbana: su persistencia temporal y su dependencia relacional. Esta formulación prepara el uso posterior de los modelos GCN-LSTM, GCN-GRU y GAT-LSTM,y refuerza la hipótesis central enunciada en el Capítulo 1: la representación del grafo condiciona el rendimiento predictivo tanto como —o más que— la arquitectura neuronal.

4.3. GRAFOS APLICADOS A MOVILIDAD URBANA

Un grafo es una estructura matemática compuesta por un conjunto de nodos y un conjunto de aristas que representan relaciones entre dichos nodos. Formalmente, puede expresarse como:

$$G = (V, E)$$

donde V representa el conjunto de nodos y E el conjunto de aristas. En el contexto de la movilidad urbana, esta estructura resulta adecuada para representar sistemas distribuidos en el espacio, como redes de sensores, estaciones, tramos de vía o agrupaciones de puntos de medida. La utilidad del grafo reside en que permite modelar no solo las características individuales de cada nodo, sino también las relaciones existentes entre ellos.

En este trabajo, los nodos del grafo representan puntos de medida de tráfico o agrupaciones de sensores. Cada nodo contiene información temporal asociada a la congestión calculada previamente y, según la configuración experimental, otras variables derivadas del tráfico. Las aristas, por su parte, representan relaciones entre nodos. Estas relaciones pueden interpretarse como hipótesis sobre cómo se propaga o comparte la dinámica de congestión dentro del sistema urbano.

La representación mediante grafos resulta especialmente relevante porque el tráfico urbano no se distribuye sobre una rejilla regular ni sobre una estructura euclídea simple. Los sensores están ubicados en puntos específicos de la ciudad y sus relaciones no dependen únicamente de la distancia física. Dos sensores próximos

pueden corresponder a sentidos de circulación distintos, a ramales diferentes o a vías con funciones urbanas no equivalentes. Del mismo modo, dos sensores no necesariamente próximos pueden presentar patrones temporales similares si se ven afectados por dinámicas de movilidad comparables.

Esta idea es coherente con el marco descrito por Semper Lloret [6], quien plantea que, en problemas espaciotemporales, los datos pueden representarse como señales sobre un grafo, donde los nodos corresponden a estaciones o puntos de observación y las aristas codifican relaciones espaciales o estadísticas entre ellos. En su tesis, la construcción del grafo se presenta como una decisión metodológica relevante, ya que define qué nodos intercambian información y, por tanto, condiciona la capacidad del modelo para capturar dependencias espaciales o funcionales.

La estructura relacional de un grafo suele representarse mediante una matriz de adyacencia:

$$A \in \mathbb{R}^{N \times N}$$

donde N es el número de nodos. Cada elemento a_{ij} de la matriz indica si existe una relación entre el nodo i y el nodo j, o con qué peso se representa dicha relación. En grafos no ponderados, a_{ij} puede tomar valores binarios. En grafos ponderados, a_{ij} puede expresar la intensidad de la relación, por ejemplo, en función de la cercanía espacial o de la similitud entre series temporales.

La matriz de adyacencia es un elemento central en los modelos basados en redes neuronales de grafos, ya que define la vecindad de cada nodo y el flujo de información durante el proceso de agregación. Semper Lloret [6] señala que la forma de construir la matriz de adyacencia influye directamente en la capacidad del modelo para capturar dependencias espaciotemporales relevantes y en la interpretación de las relaciones aprendidas o utilizadas por la red.

En el ámbito de este trabajo se consideran dos grandes criterios de construcción de aristas: cercanía espacial y correlación temporal. La cercanía espacial parte de la hipótesis de que los nodos físicamente próximos pueden influirse entre sí o compartir condiciones similares de tráfico. Este enfoque es habitual cuando se busca representar relaciones locales o contigüidad física entre puntos de observación. En la literatura revisada por Semper Lloret [6], esta estrategia aparece asociada a la construcción de vecindades mediante distancia geográfica y selección de vecinos cercanos, por ejemplo, mediante esquemas *k*-NN.

Sin embargo, la cercanía espacial no siempre captura adecuadamente la dinámica funcional del tráfico. En sistemas urbanos, la proximidad geográfica puede no implicar equivalencia operativa, especialmente cuando

existen sentidos de circulación distintos, intersecciones, ramales, carriles auxiliares o vías con funciones diferentes. Por esta razón, el presente trabajo incorpora también un criterio de adyacencia basado en correlación temporal.

La adyacencia por correlación parte de una hipótesis diferente: dos nodos pueden estar relacionados si sus series temporales de congestión presentan comportamientos similares a lo largo del tiempo. En este caso, la relación entre nodos no se define por distancia física, sino por similitud estadística entre sus patrones temporales. Semper Lloret [6] identifica este tipo de estrategia como una forma de derivar la matriz de adyacencia a partir de la similitud entre series temporales, utilizando medidas como la correlación de Pearson o Spearman.

Esta distinción es fundamental para el enfoque metodológico del proyecto. Mientras que la adyacencia por cercanía representa una hipótesis espacial, la adyacencia por correlación representa una hipótesis comportamental. La primera asume que los nodos próximos son potencialmente relevantes entre sí; la segunda asume que los nodos con evolución temporal similar pueden compartir dinámicas de congestión, aunque no estén necesariamente próximos en el espacio.

La utilidad de considerar estas dos perspectivas también aparece en aplicaciones urbanas revisadas por Semper Lloret [6]. En su modelado de ruido ambiental, los datos de estaciones urbanas se representan como una señal sobre un grafo no dirigido y se consideran dos nociones de vecindad complementarias: proximidad geográfica mediante vecinos cercanos y similitud funcional mediante alta correlación de las series. Aunque el dominio de aplicación es diferente, la lógica metodológica es comparable: en sistemas urbanos, la relación entre puntos de observación puede ser física, funcional o una combinación de ambas.

En este trabajo, esta idea se traslada al análisis de congestión vehicular. Los sensores o clusters no se conectan únicamente porque estén cerca, sino también porque pueden presentar comportamientos temporales similares. De este modo, la construcción del grafo deja de ser una etapa auxiliar y se convierte en una parte central de la metodología. La pregunta no es solo qué modelo predictivo se utiliza, sino qué representación del sistema urbano permite al modelo capturar mejor la dinámica de congestión.

Esta perspectiva justifica la comparación experimental entre diferentes definiciones de nodos y diferentes matrices de adyacencia. Los nodos pueden corresponder a sensores individuales o a agrupaciones de sensores, mientras que las aristas pueden definirse mediante cercanía espacial o correlación temporal. Cada combinación representa una hipótesis distinta sobre la estructura del fenómeno y permite evaluar si la congestión se explica mejor mediante relaciones locales, relaciones comportamentales o configuraciones híbridas.

En síntesis, los grafos proporcionan una estructura adecuada para formular la movilidad urbana como un siste-

ma relacional. En lugar de tratar cada sensor como una entidad aislada, permiten representar explícitamente las relaciones entre puntos de medida y alimentar modelos capaces de propagar información entre nodos. Esta formulación prepara la base conceptual para la siguiente subsección, dedicada a las redes neuronales de grafos, donde se explica cómo los modelos GCN y GAT utilizan la estructura del grafo para aprender representaciones espaciales de los nodos.

4.4. GRAPH NEURAL NETWORKS

Las *Graph Neural Networks*, o redes neuronales de grafos, son modelos de aprendizaje profundo diseñados para trabajar con datos cuya estructura no sigue una disposición euclídea regular, sino que se organiza mediante nodos y aristas. En este tipo de representación, cada nodo contiene una serie de atributos o señales, mientras que las aristas codifican relaciones de vecindad, dependencia o similitud entre nodos. Semper Lloret [6] define las GNN como una extensión del aprendizaje profundo al dominio de los grafos, especialmente útil cuando las observaciones proceden de redes de estaciones, mallas irregulares o sistemas donde la dependencia espacial no puede representarse adecuadamente mediante una rejilla regular.

En el contexto de este trabajo, las GNN resultan adecuadas porque los datos de tráfico no se distribuyen sobre una estructura matricial uniforme, sino sobre puntos de medida ubicados en distintas zonas de la ciudad. Cada sensor o cluster puede interpretarse como un nodo, mientras que las relaciones entre ellos se representan mediante una matriz de adyacencia. Esta formulación permite que el modelo no aprenda únicamente a partir de la historia temporal de cada nodo, sino también a partir de la información procedente de otros nodos relacionados.

La idea central de una GNN es actualizar la representación de cada nodo agregando información de sus vecinos. En términos generales, para una capa l, la representación de un nodo i puede actualizarse como:

$$h_i^{(l+1)} = \sigma\left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} W h_j^{(l)}\right)$$

donde $h_i^{(l)}$ es la representación del nodo i en la capa l, $\mathcal{N}(i)$ representa el conjunto de vecinos del nodo i, W es una matriz de parámetros entrenables, α_{ij} representa el peso asignado al vecino j, y σ es una función de activación. Esta expresión resume el principio de propagación de información o *message passing*, en el que cada nodo actualiza su estado a partir de la información de su vecindad.

Dentro de las GNN, las *Graph Convolutional Networks* constituyen una de las arquitecturas más utilizadas. Kipf y Welling [9] proponen una aproximación eficiente de convolución sobre grafos que opera directamente sobre la estructura definida por la matriz de adyacencia. En una formulación habitual, una capa GCN puede expresarse como:

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right)$$

donde $\tilde{A} = A + I$ corresponde a la matriz de adyacencia con autoconexiones, $\tilde{D}$ es la matriz diagonal de grados asociada a $\tilde{A}$, $H^{(l)}$ contiene las representaciones de los nodos en la capa l, $W^{(l)}$ es la matriz de pesos entrenables y σ es una función de activación. Esta operación permite combinar las características propias de cada nodo con las de sus vecinos, de acuerdo con la estructura del grafo.

En este trabajo, las GCN se utilizan como componente espacial en los modelos GCN-LSTM y GCN-GRU. Su papel es transformar la información de cada nodo teniendo en cuenta las relaciones definidas en la matriz de adyacencia. De esta forma, si dos sensores o clusters están conectados, el modelo puede incorporar información de ambos durante el proceso de aprendizaje. La utilidad de esta operación depende directamente de cómo se haya construido el grafo, lo que refuerza la importancia metodológica de comparar adyacencias por cercanía espacial y por correlación temporal.

Sin embargo, la agregación de vecinos en una GCN depende de una estructura de pesos fijada por la matriz de adyacencia normalizada. Esto significa que la importancia relativa de cada vecino está condicionada por la estructura previa del grafo. Para introducir mayor flexibilidad en la agregación espacial, las *Graph Attention Networks* incorporan mecanismos de atención que permiten asignar pesos diferenciados a los vecinos de cada nodo. Veličković et al. [10] proponen GAT como una arquitectura que opera sobre datos en forma de grafo mediante capas de autoatención enmascarada, permitiendo que cada nodo aprenda qué vecinos son más relevantes para actualizar su representación.

En una capa GAT, el peso de atención entre dos nodos conectados puede representarse como:

$$\alpha_{ij} = \frac{\exp\left(\mathrm{LeakyReLU}\left(\mathbf{a}^T\left[W\mathbf{h}_i \,\|\, W\mathbf{h}_j\right]\right)\right)}{\sum_{k\in\mathcal{N}(i)}\exp\left(\mathrm{LeakyReLU}\left(\mathbf{a}^T\left[W\mathbf{h}_i \,\|\, W\mathbf{h}_k\right]\right)\right)}$$

donde $\mathbf{h}_i$ y $\mathbf{h}_j$ son las características de los nodos i y j, W es una transformación lineal compartida, $\mathbf{a}$ es un vector de parámetros entrenables, $\|$ representa concatenación y $\mathcal{N}(i)$ es la vecindad del nodo i. Esta formulación

permite que el modelo asigne distinta relevancia a cada vecino durante la agregación.

En este trabajo, GAT se utiliza en el modelo GAT-LSTM. Esta arquitectura mantiene el componente temporal basado en LSTM, pero sustituye la convolución de grafos por una agregación espacial basada en atención. Con ello se evalúa si una agregación espacial más flexible puede aportar ventajas frente a la agregación definida por GCN. La comparación entre GCN-LSTM y GAT-LSTM permite analizar, por tanto, el efecto del mecanismo espacial utilizado sobre la predicción de congestión.

Dado que la congestión es una señal que evoluciona en el tiempo, el componente espacial de las GNN debe combinarse con un mecanismo capaz de modelar dependencias temporales. En este trabajo se emplean LSTM y GRU. Las *Long Short-Term Memory* fueron propuestas por Hochreiter y Schmidhuber [11] para abordar las limitaciones de las redes recurrentes simples al aprender dependencias de largo plazo. Su estructura se basa en compuertas que regulan qué información se conserva, se actualiza o se descarta a lo largo de la secuencia.

En términos conceptuales, una LSTM mantiene un estado de celda que actúa como memoria interna. Este mecanismo resulta adecuado para series temporales de tráfico, donde pueden existir patrones recurrentes asociados a horas punta, ciclos diarios o persistencia de estados de congestión. En el modelo GCN-LSTM, la GCN captura relaciones espaciales entre nodos y la LSTM modela la evolución temporal de las representaciones obtenidas. En GAT-LSTM, el componente temporal es análogo, pero la representación espacial procede de una capa de atención sobre grafos.

Las *Gated Recurrent Units* fueron introducidas por Cho et al. [12] como parte de una arquitectura encoder-decoder recurrente. Al igual que las LSTM, las GRU utilizan mecanismos de compuertas para controlar el flujo de información en la secuencia, pero presentan una estructura más compacta. En este TFM, la GRU se utiliza en el modelo GCN-GRU, donde se conserva el componente espacial basado en GCN y se sustituye la LSTM por una unidad recurrente más simple. Esta configuración permite comparar si una arquitectura temporal más compacta es suficiente para capturar la dinámica de congestión.

La combinación de GNN con modelos recurrentes responde a la naturaleza espaciotemporal del problema. Semper Lloret [6] señala que, en problemas de predicción sobre grafos, las GNN espaciales suelen acoplarse con módulos temporales como LSTM, GRU o convoluciones temporales para integrar simultáneamente estructura espacial y dinámica temporal. Esta idea coincide con la formulación adoptada en el presente trabajo, donde los modelos no operan únicamente sobre series temporales aisladas, sino sobre señales temporales definidas en los nodos de un grafo.

Desde el punto de vista metodológico, las tres arquitecturas utilizadas cumplen funciones comparativas espe-

cíficas. GCN-LSTM combina convolución de grafos y memoria temporal de largo plazo. GCN-GRU mantiene el mismo componente espacial, pero utiliza una unidad recurrente más compacta. GAT-LSTM conserva el componente temporal LSTM, pero sustituye la agregación espacial de GCN por un mecanismo de atención. Esta selección permite separar parcialmente el análisis de los efectos espaciales y temporales de cada arquitectura.

Las GNN se entienden aquí como herramienta para validar la representación grafo-temporal, no como el objeto central del estudio. El foco metodológico —en línea con la hipótesis del Capítulo 1- recae en la definición de nodos, la construcción de aristas y la comparación entre grafos por cercanía o correlación.

En síntesis, las Graph Neural Networks proporcionan el marco adecuado para modelar la dimensión relacional del tráfico urbano, mientras que LSTM y GRU permiten representar la evolución temporal de la congestión. Las arquitecturas GCN-LSTM, GCN-GRU y GAT-LSTM integran ambos componentes y permiten evaluar si la congestión futura puede estimarse mejor cuando la señal temporal de cada nodo se analiza junto con las relaciones estructurales o comportamentales del grafo.

4.5. TRABAJOS RELACIONADOS

La predicción de tráfico urbano ha sido abordada desde diferentes perspectivas metodológicas, que van desde modelos clásicos de series temporales y aprendizaje automático hasta arquitecturas profundas capaces de capturar relaciones espaciales y temporales. En el contexto de este TFM, los trabajos relacionados pueden organizarse en tres grupos principales: estudios aplicados a datos de tráfico de Madrid, modelos espaciotemporales basados en grafos y trabajos que resaltan la importancia de la representación espacial o topológica del sistema urbano.

En primer lugar, existen trabajos previos centrados específicamente en la predicción de tráfico en Madrid. Vélez-Serrano et al. [13] proponen un enfoque de predicción espaciotemporal del flujo de tráfico en Madrid mediante redes neuronales convolucionales residuales. Su trabajo utiliza datos del Portal de Datos Abiertos del Ayuntamiento de Madrid, procedentes de sensores distribuidos por la ciudad, e incluye variables como intensidad, ocupación, carga y velocidad media. Los autores comparan su modelo basado en ResNet con métodos clásicos de series temporales, mostrando que las redes convolucionales residuales pueden capturar patrones espaciotemporales relevantes para la predicción del flujo de tráfico.

Este trabajo es relevante para el presente TFM porque demuestra la utilidad de los datos abiertos de Madrid para tareas predictivas y confirma la importancia de considerar relaciones espaciales entre puntos de medida. Sin embargo, su enfoque representa la información mediante una estructura más cercana a una formulación

visual o convolucional, mientras que el presente trabajo formula el problema explícitamente como una señal sobre grafos. Por tanto, la diferencia principal no está solo en el tipo de modelo, sino en la forma de representar el sistema urbano: en lugar de proyectar los datos en una estructura tipo imagen, este TFM construye nodos y aristas a partir de sensores, agrupaciones y relaciones de cercanía o comportamiento temporal.

También en el contexto de Madrid, Ayuso Hernández [14] desarrolla un trabajo de fin de máster orientado a la estimación de atascos mediante inteligencia artificial, utilizando datos abiertos de tráfico del Ayuntamiento de Madrid. Su propuesta trabaja con intensidad y ocupación, plantea una definición de atasco a partir de estas variables y evalúa modelos de regresión y clasificación. Este antecedente resulta especialmente cercano porque aborda la necesidad de construir una variable relacionada con la congestión a partir de datos disponibles y porque trabaja con una fuente de datos similar a la utilizada en este TFM.

No obstante, el alcance metodológico del presente trabajo es diferente. Mientras que Ayuso Hernández [14] se centra en la estimación de atascos y en la comparación de modelos clásicos de aprendizaje automático, este TFM amplía el problema hacia una formulación espaciotemporal sobre grafos. En particular, no solo se busca estimar una condición de congestión, sino analizar cómo la organización de sensores en nodos y la construcción de relaciones entre ellos condicionan el rendimiento predictivo. Esta diferencia permite situar el presente trabajo como una evolución desde la predicción basada en variables individuales hacia una metodología de representación estructurada del sistema urbano.

Un tercer antecedente relevante para Madrid es el trabajo de Moral-Carcedo [15], que estudia la predicción de intensidad de tráfico en el área urbana de Madrid incorporando características de la topología de rutas. El autor señala que, además de los efectos temporales, los efectos espaciales deben considerarse en los modelos de intensidad de tráfico, ya que existen patrones repetitivos a lo largo del tiempo y simultaneidades entre sensores ubicados en vías de capacidad similar. El trabajo propone integrar información sobre rutas óptimas y localización de sensores para reproducir patrones espaciales y temporales observados en la intensidad de tráfico.

La relevancia de Moral-Carcedo [15] para este TFM es doble. Por un lado, refuerza la idea de que la predicción de tráfico en Madrid no puede tratarse únicamente como un problema temporal. Por otro, muestra que la forma de incorporar la estructura espacial de la red urbana es una decisión metodológica importante. Sin embargo, mientras que dicho trabajo incorpora la topología de rutas para estimar intensidades de uso, el presente TFM propone una metodología alternativa: construir grafos a partir de datos de tráfico y comparar relaciones basadas en cercanía espacial y similitud temporal. De este modo, el enfoque desarrollado aquí no depende exclusivamente de una topología de rutas predefinida, sino que explora relaciones derivadas del comportamiento observado en los datos.

En una línea más reciente, Gómez e Ilarri [16] abordan la predicción de tráfico en Madrid a diferentes escalas temporales mediante datos heterogéneos. Su propuesta combina información procedente de sensores con variables contextuales, como meteorología, calendario y atributos urbanos, y plantea una arquitectura ligera basada en embeddings de sensores y capas densas. Los autores destacan la importancia de construir modelos escalables, reproducibles y eficientes, capaces de mantener rendimiento en horizontes de predicción tanto cortos como largos.

Este trabajo es útil para contextualizar la actualidad del problema y la relevancia de la escalabilidad en predicción urbana. Sin embargo, su aportación se centra en la integración de fuentes heterogéneas y en una arquitectura eficiente para diferentes horizontes temporales. El presente TFM, en cambio, se concentra en el papel de la representación grafo-temporal y en el efecto de diferentes criterios de construcción del grafo sobre la predicción de congestión. Ambas líneas son complementarias: una enfatiza la riqueza de las fuentes y la eficiencia del modelo; la otra, la forma en que se estructura relacionalmente el sistema de tráfico.

Además de los trabajos aplicados a Madrid, la literatura internacional sobre predicción de tráfico ha avanzado significativamente mediante modelos espaciotemporales basados en grafos. Li et al. [17] proponen DCRNN, un modelo que representa la red de sensores de tráfico como un grafo dirigido y modela la dependencia espacial mediante un proceso de difusión, combinado con una arquitectura recurrente para capturar la dinámica temporal. El trabajo plantea explícitamente que la predicción de tráfico es compleja por la existencia de dependencias espaciales en la red vial, dinámicas temporales no lineales y dificultad de predicción a horizontes más largos.

DCRNN constituye una referencia importante porque formaliza la predicción de tráfico como una tarea sobre señales de grafo y muestra la necesidad de combinar estructura espacial y memoria temporal. No obstante, el presente TFM no adopta directamente la difusión sobre grafos dirigidos propuesta por Li et al. [17], sino que utiliza arquitecturas más próximas a GCN-LSTM, GCN-GRU y GAT-LSTM. Aun así, el trabajo de Li et al. [17] justifica conceptualmente la decisión de representar los sensores como nodos y de utilizar una matriz de adyacencia para codificar relaciones entre ellos.

Yu, Yin y Zhu [18] proponen STGCN, una arquitectura de convoluciones espaciotemporales sobre grafos para predicción de tráfico. Su planteamiento parte de la idea de que los datos de tráfico son series temporales estructuradas en una red y que las dependencias espaciales no pueden capturarse adecuadamente mediante convoluciones euclídeas convencionales. STGCN combina convoluciones temporales y convoluciones sobre grafos mediante bloques espaciotemporales, mostrando que la estructura del grafo permite representar de forma más adecuada la red de sensores.

La relación de STGCN con este TFM se encuentra en la formulación del tráfico como una señal estructurada sobre un grafo. Aunque el presente trabajo no implementa STGCN, comparte la idea de que las observaciones de tráfico no deben tratarse como series independientes ni como simples matrices regulares. La diferencia es que este TFM se enfoca en comparar cómo distintas definiciones de nodos y aristas afectan al rendimiento de modelos GNN híbridos, en lugar de centrarse en una arquitectura espaciotemporal específica.

Zheng et al. [19] proponen GMAN, una red multi-atención sobre grafos para predicción de tráfico. Este trabajo es especialmente relevante porque destaca que las correlaciones espaciales entre sensores pueden ser dinámicas: sensores cercanos no siempre presentan alta correlación y la relación entre ubicaciones puede cambiar según el momento temporal. GMAN utiliza mecanismos de atención espacial y temporal para modelar estas dependencias complejas y reducir problemas asociados a la propagación de errores en predicciones a varios pasos.

La idea de correlaciones espaciales dinámicas resulta cercana a la motivación de este TFM. En particular, refuerza la hipótesis de que la cercanía física no siempre es suficiente para definir relaciones entre sensores. Aunque el presente trabajo no implementa GMAN, sí incorpora una idea metodológicamente relacionada: comparar una adyacencia basada en cercanía espacial con una adyacencia basada en correlación temporal del comportamiento de congestión. Además, el uso de GAT-LSTM en este TFM permite explorar, de forma más acotada, el papel de la atención en la agregación de información entre nodos.

En conjunto, los trabajos revisados muestran una evolución clara. Los primeros enfoques aplicados a tráfico urbano se centraron en modelos clásicos, aprendizaje automático o redes neuronales aplicadas a series temporales. Posteriormente, los modelos profundos incorporaron componentes espaciales mediante CNN o representaciones visuales. Más recientemente, la predicción de tráfico se ha formulado como un problema grafo-temporal, donde los sensores son nodos, las relaciones entre ellos se codifican mediante una matriz de adyacencia y los modelos aprenden simultáneamente dependencias espaciales y temporales.

El presente TFM se sitúa dentro de esta última línea, pero con un énfasis específico en la construcción de la representación grafo-temporal: compara diferentes definiciones de nodos —sensores individuales y agrupaciones— y diferentes criterios de adyacencia —cercanía espacial y correlación temporal— para analizar qué decisiones de representación tienen mayor impacto sobre el rendimiento de los modelos.

De este modo, la aportación diferencial del trabajo se resume en tres aspectos. Primero, se construye un índice homogéneo de congestión a partir de intensidad y ocupación, debido a las limitaciones de disponibilidad de variables oficiales como carga y velocidad media. Segundo, se transforma el sistema de puntos de medida en una representación grafo-temporal flexible, no limitada a una única topología urbana predefinida. Tercero,

se evalúa empíricamente el efecto de distintas representaciones del grafo sobre modelos GNN híbridos, como GCN-LSTM, GCN-GRU y GAT-LSTM. Esta combinación permite posicionar el TFM como una propuesta metodológica centrada en la representación del sistema urbano y no únicamente en la elección de una arquitectura predictiva.

5. PLAN DE GESTIÓN

5.1. METODOLOGÍA DE TRABAJO

El proyecto se desarrolló siguiendo un enfoque iterativo organizado en dos modos de trabajo complementarios. En una primera etapa de carácter exploratorio, se utilizaron notebooks de Jupyter para analizar los datos, probar agrupaciones, revisar casos concretos y tomar decisiones metodológicas de forma interactiva. A medida que las decisiones se consolidaban, las funciones correspondientes se trasladaban a módulos del repositorio, lo que permitió pasar a una segunda etapa de trabajo reproducible y parametrizable.

Esta transición de lo exploratorio a lo reproducible condicionó la estructura del proyecto. Las decisiones sobre la definición de nodos, los criterios de adyacencia y los parámetros de clustering se tomaron a partir del análisis de enero de 2025 y se documentaron como configuraciones reutilizables. El pipeline final permite ejecutar cualquier combinación de configuraciones desde consola, lo que facilitó la evaluación sistemática de las 54 combinaciones del experimento principal.

Las fases técnicas del proyecto —exploración de datos, construcción del índice de congestión, definición de nodos y aristas, preparación de datasets, modelado y evaluación— se desarrollaron secuencialmente con dependencia directa entre etapas: las decisiones de cada fase condicionaban las posibilidades de la siguiente. Esta secuencia se detalla en el Capítulo 6.

El control de versiones se realizó mediante Git y GitHub. Durante las ejecuciones largas se utilizó subida automática de resultados parciales, lo que permitió conservar avances ante posibles interrupciones. La planificación temporal se recoge en la Tabla 5.1.

5.2. PLANIFICACIÓN TEMPORAL

En este apartado se describe la planificación, contemplando los tiempos y las etapas descritas. A partir de las fases trazadas en la metodología, se define el siguiente diagrama de Gantt que detalla cada una de las etapas con su duración en horas y semanas. El proyecto se pone en marcha desde el mes de enero hasta el mes de junio.

			Enero					Febrero				Marzo				Abril				Mayo				
Etapa	Horas	Semanas	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22
0. Reuniones iniciales y delimitación del proyecto	10	3		3	3	4																		
1. Comprensión del problema y revisión de datos	30	3				10	10	10																
2. Análisis exploratorio, limpieza y preparación	45	4						10	12	12	11													
3. Construcción del índice de congestión	30	2									15	15												
4. Definición de nodos del grafo	50	4										12	14	12	12									
5. Construcción de aristas y matrices de adyacencia	45	4												10	12	12	11							
6. Preparación de datasets para modelos GNN	35	3														12	12	11						
7. Modelado y experimentación	90	6																12	16	18	18	16	10	
8. Evaluación de resultados	50	4																				10	14	14
9. Documentación, reproducibilidad y redacción	85	7																		8	10	10	12	15
10. Reuniones semanales con tutores	21	21				1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

Tabla 5.1.: Cronograma con las etapas del proyecto y su estimación en horas por semana.

5.3. PRESUPUESTO

El presente proyecto se ha desarrollado en el marco del Trabajo Fin de Máster y, por tanto, no ha supuesto una contratación real de personal ni la adquisición específica de todos los recursos incluidos en esta estimación. No obstante, se presenta un presupuesto aproximado con el objetivo de valorar el coste que habría tenido el desarrollo del proyecto en un entorno profesional, considerando personal, equipamiento de hardware y herramientas de software.

5.3.1. Presupuesto de personal

En este presupuesto se listan las personas requeridas para el proyecto, detallando el cargo, el tiempo trabajado, y el coste por unidad de hora.

Perfil	Horas estimadas	Coste/hora	Coste total
Investigadora / desarrolladora	396	50 €/h	19.800 €
Tutor académico	33	75 €/h	2.475 €
Total personal	**429**		**22.275 €**

Tabla 5.2.: Presupuesto de personal del proyecto.

5.3.2. Presupuesto de hardware

Para el hardware se describe el equipamiento necesario para la ejecución del proyecto.

Equipo	Cantidad	Coste unitario	Coste total
Ordenador portátil	1	875 €	875 €
Total hardware	**1**		**875 €**

Tabla 5.3.: Presupuesto de hardware del proyecto.

5.3.3. Presupuesto de software

Se presentan las distintas herramientas propiamente de software que se usan a lo largo del proyecto, describiendo el tipo de licencia y sus costos asociados.

Herramienta	Tipo de licencia / coste	Coste total
Python	Libre	0 €
Visual Studio Code / Jupyter	Libre	0 €
Pandas y NumPy	Libre	0 €
GeoPandas / herramientas geoespaciales	Libre	0 €
Scikit-learn	Libre	0 €
PyTorch / PyTorch Geometric	Libre	0 €
Matplotlib	Libre	0 €
Git y GitHub	Libre	0 €
Microsoft Office Hogar 2024	149 €	149 €
Total software		**149 €**

Tabla 5.4.: Presupuesto de software del proyecto.

5.3.4. Presupuesto total

El presupuesto total resulta de sumar cada uno de los recursos descritos anteriormente.

Recurso	Cantidad	Coste total
Personal	2 perfiles	22.275 €
Hardware	1 equipo	875 €
Software	9 herramientas / licencias	149 €
Total estimado		**23.299 €**

Tabla 5.5.: Presupuesto total estimado del proyecto.

6. DESARROLLO

Este capítulo describe la implementación de la metodología propuesta, desde la preparación de los datos hasta el entrenamiento y evaluación de los modelos. La Figura 6.1 muestra el flujo general del desarrollo.

Figura 6.1.: Flujo general de desarrollo de la metodología

6.1. DISEÑO GENERAL

El desarrollo del proyecto se organizó como una metodología completa para transformar datos históricos de tráfico en una representación grafo-temporal apta para la predicción de congestión vehicular. El punto de partida fueron los datos abiertos de tráfico del Ayuntamiento de Madrid, compuestos por registros temporales asociados a puntos de medida distribuidos en la red urbana. A partir de estos datos se diseñó un flujo de trabajo progresivo que incluye exploración, limpieza, construcción de una variable propia de congestión, definición de nodos, construcción de aristas, preparación de datasets y entrenamiento de modelos basados en redes neuronales de grafos.

La metodología implementa el enfoque agnóstico a la topología urbana definido en el Capítulo 1, comparando distintas formas de organizar los sensores como nodos y de establecer relaciones entre ellos mediante criterios espaciales y comportamentales.

El flujo general del proyecto se compone de varias etapas:

1. Se realizó la carga y exploración de los datos, con el objetivo de comprender la estructura de los ficheros históricos, la cantidad de puntos de medida disponibles, la frecuencia temporal de los registros y la calidad de las variables. Esta exploración permitió identificar características importantes del conjunto de datos, como la existencia de puntos de medida muy próximos, la variación de sensores entre meses y la disponibilidad desigual de algunas variables.

2. Se llevó a cabo la limpieza y validación de los datos. Esta etapa incluyó la revisión de valores faltantes o no válidos, la comprobación de la estructura temporal de las observaciones y la preparación de los datos para el cálculo de la congestión. Dado que variables como la carga oficial o la velocidad media no estaban disponibles de forma homogénea para todos los elementos, se decidió construir un índice propio de congestión a partir de intensidad y ocupación.

3. Se definieron distintas representaciones de nodos. El proyecto no trabaja únicamente con los sensores originales, sino que también construye agrupaciones de sensores mediante criterios de proximidad espacial, comportamiento temporal y sentido de circulación. De este modo, cada configuración de nodos representa una hipótesis distinta sobre cómo simplificar y estructurar el sistema de puntos de medida de Madrid.

4. Se construyeron las aristas del grafo mediante los dos enfoques principales descritos en la Sección 4.3: *cercanía espacial* y *correlación temporal*.

5. Los datos se transformaron en datasets grafo-temporales. Para ello, la señal de congestión se organizó en ventanas temporales de entrada y valores futuros de salida, manteniendo la correspondencia entre nodos, tiempos y características. Esta etapa permitió formular el problema como una tarea supervisada de predicción de congestión futura para todos los nodos del grafo.

6. Se entrenaron y evaluaron modelos híbridos de redes neuronales de grafos y modelos temporales. Las arquitecturas consideradas fueron GCN-LSTM, GCN-GRU y GAT-LSTM. La selección de estos modelos permite comparar los efectos del componente espacial y temporal, subordinados al análisis principal: la influencia de la representación del grafo.

En conjunto, el diseño general del proyecto puede entenderse como una cadena metodológica en la que cada etapa condiciona a la siguiente:

los datos originales determinan la construcción del índice de congestión; este índice define la señal temporal de cada nodo; los nodos y aristas configuran el grafo; y el grafo, junto con las ventanas temporales, constituye la entrada de los modelos GNN.

6.2. FUENTE DE DATOS Y ESTRUCTURA INICIAL

Los datos de este proyecto provienen del Portal de Datos Abiertos del Ayuntamiento de Madrid, descrito en el Capítulo 2. Se emplean dos tipos de ficheros complementarios: los registros históricos de tráfico asociados a los puntos de medida y los ficheros de ubicación e información espacial de dichos puntos. Esta separación es relevante porque las mediciones temporales y la localización geográfica no se encuentran en un único archivo, sino que deben integrarse para construir la representación grafo-temporal del sistema.

En este trabajo se utiliza el histórico de tráfico como base principal del modelado, mientras que la información en tiempo real —actualizada cada 5 minutos— se considera únicamente como posibilidad futura hacia un escenario operativo (véase Sección 8.4). El histórico está disponible desde 2013 en ficheros CSV organizados por mes y año, con una frecuencia de registro de 15 minutos por punto de medida [4].

En la fase de exploración inicial se identificó que los datos históricos se encuentran organizados principalmente por año y mes, con un fichero CSV para cada mes. En el caso del año 2013, los registros se encontraban agrupados en un único archivo de gran tamaño, con más de 120 millones de registros, por lo que se decidió no utilizar ese año en la fase inicial del trabajo. Dado que existían datos suficientes en años posteriores, y que el objetivo era comprender el comportamiento reciente del sistema, el análisis exploratorio se centró en datos de 2025.

Para el análisis exploratorio detallado se trabajó específicamente con el mes de enero de 2025. Esta elección permitió estudiar un periodo reciente, suficientemente acotado para el análisis manual y, al mismo tiempo, representativo de la estructura real de los datos utilizados en el proyecto. Las conclusiones obtenidas en esta fase se plantearon como replicables a otros meses del histórico.

El fichero histórico de tráfico presenta una estructura tabular en la que cada fila corresponde a una observación temporal de un punto de medida. Entre las variables observadas se encuentran `id`, `fecha`, `tipo_elem`, `intensidad`, `ocupacion`, `carga`, `vmed`, `error` y `periodo_integracion`. Esta tabla constituye la base temporal del proyecto, ya que contiene la evolución del tráfico en intervalos regulares para cada sensor.

```
trafico_01_2025.head()
```

	id	fecha	tipo_elem	intensidad	ocupacion	carga	vmed	error	periodo_integracion
0	1002	2025-01-01 00:00:00	C30	216	2	0	66.0	N	5
1	1002	2025-01-01 00:15:00	C30	72	0	0	14.0	N	5
2	1002	2025-01-01 00:30:00	C30	444	2	0	69.0	N	5
3	1002	2025-01-01 00:45:00	C30	1260	6	0	66.0	N	5
4	1002	2025-01-01 01:00:00	C30	2028	7	0	66.0	N	5

Tabla 6.1.: Muestra de la estructura tabular del fichero histórico de tráfico.

Por su parte, el fichero de puntos de medida contiene la información descriptiva y espacial asociada a cada sensor. En este caso, las variables principales observadas fueron `tipo_elem`, `distrito`, `id`, `cod_cent`, `nombre`, `utm_x`, `utm_y`, `longitud` y `latitud`. Esta segunda tabla aporta la dimensión geográfica del problema y permite localizar espacialmente los sensores para construir agrupaciones y relaciones de proximidad.

```
punto_medida_01_2025.head()
```

	tipo_elem	distrito	id	cod_cent	nombre	utm_x	utm_y	longitud	latitud
0	URB	4.0	3937	05009	Serrano N-S - General Oraa-Diego de Leon	441778.976129	4.476398e+06	-3.686452	40.436193
1	URB	15.0	5947	45001	Hermanos García Noblejas - Dr. Cirajas-Vital Aza	446034.529936	4.476272e+06	-3.636269	40.435345
2	URB	15.0	10307	53053	Santa Genoveva - Santa Genoveva-Av. Trece Rosas	445059.893465	4.475300e+06	-3.647676	40.426521
3	URB	15.0	6135	53057	Av. Marqués de Corbera - Ntra. Sra. del Villar-Gerardo Cordón	444630.020772	4.475155e+06	-3.652731	40.425186
4	URB	15.0	10447	53062	Francisco Villaespesa - José María Pereda-Hermanos Machado	445042.418145	4.475567e+06	-3.647905	40.428921

Tabla 6.2.: Muestra de la estructura tabular del fichero de puntos de medida.

6.3. ANÁLISIS EXPLORATORIO DE DATOS

El análisis exploratorio de datos tuvo como objetivo comprender la estructura temporal, espacial y operativa del conjunto de datos antes de avanzar hacia la construcción del índice de congestión y de los grafos. Esta fase fue necesaria porque los datos de tráfico no solo contienen mediciones temporales, sino también información asociada a la localización y definición de los puntos de medida, lo que condiciona directamente la forma en

que pueden representarse posteriormente como nodos de un grafo.

La exploración inicial se realizó sobre el mes de enero de 2025, utilizando el fichero histórico `01-2025.csv` y el fichero de ubicación `pmed_ubicacion_01-2025.csv`. Esta elección respondió a dos criterios. En primer lugar, se buscó trabajar con datos recientes, representativos del estado actual del sistema de medición. En segundo lugar, se eligió un único mes para realizar una revisión detallada y controlada de la estructura de los datos, con la intención de que las decisiones metodológicas derivadas de este análisis pudieran replicarse posteriormente a otros periodos.

En el fichero de tráfico de enero de 2025 se identificaron 4.701 puntos de medida únicos. Por su parte, el fichero de ubicación asociado contenía 4.960 identificadores únicos y 4.797 nombres únicos de puntos de medida. Esta diferencia muestra que no todos los puntos registrados en el fichero de ubicación necesariamente aparecen con datos de tráfico en el mes analizado, y también que existen casos en los que distintos identificadores pueden compartir una denominación similar o idéntica. Esta observación fue importante porque descartó la posibilidad de reducir de forma significativa el problema agrupando únicamente por nombre del punto de medida.

Uno de los primeros análisis realizados consistió en estudiar la distancia al punto de medida más cercano. Este análisis buscaba entender si los sensores podían interpretarse como puntos aislados, puntos por carril o puntos asociados a tramos completos de vía. Para ello se calcularon distancias entre puntos de medida utilizando sus coordenadas. Se observó que existían numerosos puntos con identificadores diferentes situados a distancias muy reducidas entre sí. En particular, se identificaron 85 pares de puntos separados por menos de 4 metros, lo que motivó una revisión cualitativa de varios casos mediante QGIS y Google Earth Pro.

Como se observa en la Figura 6.2, existe **un solo punto de medida por vía o tramo**: si la vía tiene varios carriles en el mismo sentido, se mantiene un único punto de medida; si tiene un solo carril, también se registra un único punto. Los puntos de medida cambian principalmente cuando cambia el sentido de circulación o aparece una bifurcación del carril.

Figura 6.2.: Punto de medida único en un tramo con varios carriles

En la Figura 6.3, se observa que existen dos puntos de medida: uno asociado al carril que permite continuar en el mismo sentido o girar a la derecha, y otro asociado al giro a la izquierda.

Figura 6.3.: Puntos de medida diferenciados según maniobra o sentido de circulación

Como se observa en la Figura 6.4, existen pares de puntos de medida con la misma denominación, ubicados a pocos metros de distancia y asociados a carriles contiguos. Este caso evidencia que el nombre del punto de medida no siempre es suficiente para agrupar sensores, ya que puede haber varios registros cercanos con nombres iguales pero asociados a carriles o sentidos específicos.

Figura 6.4.: Puntos de medida con la misma denominación en carriles próximos

La inspección visual permitió comprobar que la lógica de los puntos de medida no es uniforme. En algunos casos, un único punto de medida representa varios carriles en el mismo sentido; en otros casos, existen puntos distintos para carriles específicos; y en otros, los puntos cercanos corresponden a bifurcaciones o sentidos de circulación diferentes. Por tanto, **la proximidad física entre sensores no permite concluir automáticamente que deban agruparse como una misma unidad funcional. Esta conclusión fue relevante para el diseño posterior de los nodos del grafo, ya que mostró la necesidad de considerar criterios adicionales además de la distancia.**

También se analizó la disponibilidad temporal de los registros. Para enero de 2025 se revisó si cada punto de medida tenía datos todos los días del mes. El análisis mostró que, de los 4.701 puntos de medida presentes en el fichero de tráfico, 203 tenían al menos un día sin datos. Esta situación confirma que la disponibilidad de datos no es completamente uniforme y que la preparación posterior debe contemplar la existencia de ausencias o discontinuidades temporales.

A continuación, se revisó la presencia de valores erróneos o negativos en las variables principales. En el análisis estadístico de enero de 2025, considerando intensidad, ocupación y carga, no se encontraron valores negativos. Los valores mínimos observados fueron cero en las tres variables, lo que permitió continuar con el análisis sin aplicar en esta fase una depuración por registros negativos. Para las variables principales, el resumen estadístico mostró una intensidad media de 352 vehículos/hora, una ocupación media de 5 % y una carga media de 17. Estos valores deben interpretarse como estadísticos globales del mes y no como una caracterización específica de una vía concreta, ya que agregan observaciones de todos los puntos de medida y todos los intervalos

temporales.

Además del análisis de un mes concreto, se comparó la evolución mensual de los datos durante 2025. Para ello se calcularon estadísticas descriptivas de intensidad, ocupación y carga mes a mes. Como se observa en la Figura 6.5 en términos generales, los valores se mantuvieron dentro de rangos similares a lo largo del año, aunque el mes de agosto presentó una disminución apreciable en la intensidad respecto al resto de meses. Esta observación es coherente con la existencia de patrones estacionales en la movilidad urbana y justifica que, en fases posteriores, el análisis pueda ampliarse a varios meses cuando se busque una mayor representatividad temporal.

También se estudió la estabilidad del conjunto de sensores entre meses. Se compararon los identificadores presentes en cada mes de 2025 para determinar cuántos sensores aparecían o desaparecían respecto al mes anterior. Los resultados mostraron que existe una variación mensual moderada en los puntos de medida disponibles. Por ejemplo, en febrero aparecieron 24 sensores nuevos respecto a enero y dejaron de aparecer 15; en marzo aparecieron 33 y dejaron de aparecer 27; y en abril aparecieron 38 y dejaron de aparecer 22. Esta variabilidad indica que la red de puntos de medida no debe considerarse completamente fija en el tiempo.

El análisis exploratorio permitió extraer varias conclusiones metodológicas. En primer lugar, el conjunto de datos es suficientemente amplio para formular un problema de predicción espaciotemporal, pero requiere una integración cuidadosa entre registros temporales y ubicación de sensores. En segundo lugar, la proximidad espacial entre puntos de medida no implica necesariamente equivalencia funcional, por lo que la definición de nodos no puede basarse exclusivamente en distancia. En tercer lugar, la existencia de ausencias temporales y variación mensual de sensores obliga a diseñar un flujo de preparación de datos reproducible y robusto. Finalmente, la disponibilidad consistente de intensidad y ocupación refuerza la decisión de construir un índice propio de congestión a partir de estas dos variables.

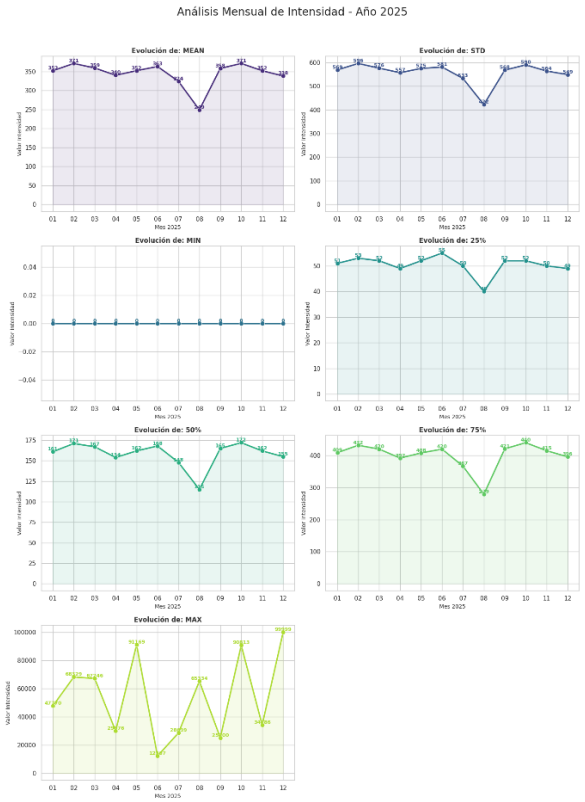

(a) Intensidad

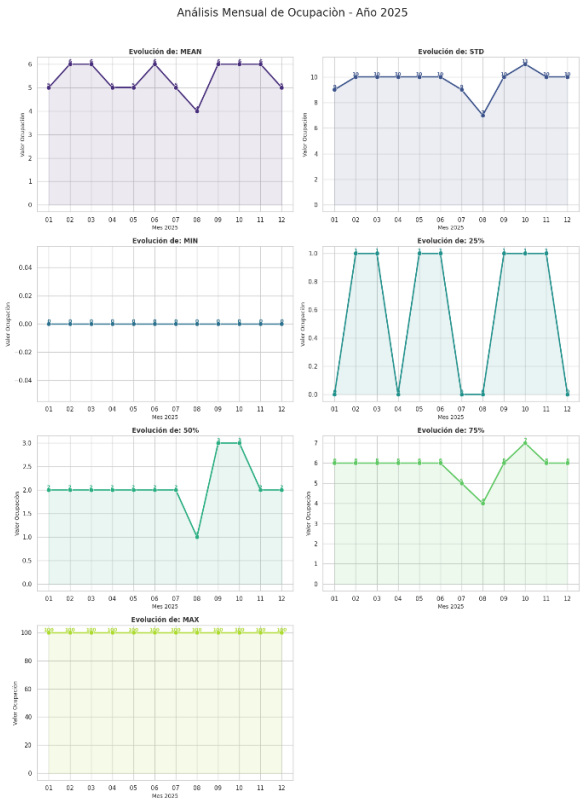

(b) Ocupación

Figura 6.5.: Evolución mensual de las estadísticas descriptivas de intensidad y ocupación durante 2025.

6.4. LIMPIEZA, VALIDACIÓN Y PREPARACIÓN DE DATOS

Tras el análisis exploratorio, se realizó una fase de limpieza, validación y preparación orientada a construir una base de datos consistente para las etapas posteriores del proyecto. Esta fase tuvo como objetivo transformar los ficheros originales en una estructura adecuada para calcular el índice de congestión, asociar cada punto de medida con su localización y generar series temporales utilizables en la construcción de grafos.

El primer paso consistió en revisar la calidad de las variables principales del fichero histórico de tráfico: `intensidad`, `ocupacion` y `carga`. Como se observó en el análisis exploratorio (Sección 6.3), en enero de 2025 no aparecieron valores negativos en estas variables; no obstante, dentro del procedimiento general se mantuvo el criterio de tratar los valores negativos como registros no válidos, de acuerdo con la documentación oficial. Esto garantiza que el flujo de limpieza sea aplicable a cualquier mes del histórico.

También se revisó la variable `error`, incluida en los registros históricos. Esta variable permite identificar observaciones que pueden estar afectadas por incidencias en la medición. Aunque en la exploración inicial se observaron registros sin error en los ejemplos analizados, la presencia de este campo se tuvo en cuenta como parte del control de calidad de los datos.

El segundo paso fue la validación temporal. Dado que los datos se registran en intervalos de 15 minutos, cada día completo puede contener hasta 96 observaciones por punto de medida. Se comprobó la disponibilidad de registros por sensor y por día para identificar ausencias parciales. Como se reportó en §6.3, 203 de los 4.701 puntos de medida presentaban al menos un día sin datos en enero de 2025.

Esta validación fue necesaria para evitar que la construcción posterior de ventanas de entrada se realizara sobre series desordenadas o incompletas. Antes de generar muestras para entrenamiento, los registros debían estar ordenados por identificador de punto de medida y por instante temporal.

El tercer paso consistió en integrar la información temporal con la información espacial. Para ello, se utilizó el campo id, presente tanto en el fichero histórico de tráfico como en el fichero de ubicación de puntos de medida. Esta unión permitió asociar cada serie temporal con su localización geográfica y con atributos descriptivos como el nombre del punto de medida, el tipo de elemento y las coordenadas.

En la preparación espacial se conservaron las coordenadas geográficas y las coordenadas UTM disponibles en el fichero de puntos de medida. El uso de coordenadas UTM resultó especialmente útil porque permite trabajar con distancias euclídeas expresadas en metros, lo que facilita la identificación de puntos próximos y la definición de criterios de agrupación espacial.

El cuarto paso fue la selección de variables relevantes. Como se fundamentó en la Sección 4.1, las variables `carga` y `vmed` no ofrecen la homogeneidad necesaria para construir una variable objetivo común a todos los puntos de medida, por lo que se trabajó con intensidad y ocupacion. Durante la exploración, carga se mantuvo como referencia informativa para verificar la coherencia del índice propio construido posteriormente, pero no se adoptó como variable objetivo.

El quinto paso consistió en preparar los datos para su uso en etapas reproducibles del pipeline. Para ello, los registros se organizaron en una estructura que permitiera trabajar por mes, punto de medida e instante temporal. Esta organización facilitó replicar el análisis realizado inicialmente sobre enero de 2025 en otros periodos del histórico. Además, permitió separar claramente las tareas de carga de datos, cálculo de congestión, construcción de agrupaciones, generación de grafos y entrenamiento de modelos.

Una decisión importante de esta fase fue no asumir que puntos de medida cercanos debían fusionarse automáticamente. El análisis espacial previo mostró que sensores a muy poca distancia podían representar carriles, sentidos o bifurcaciones diferentes. Por tanto, la preparación de datos mantuvo inicialmente la granularidad original de los puntos de medida y dejó la agrupación como una etapa metodológica posterior, donde se compararían distintas formas de definir los nodos del grafo.

6.5. CONSTRUCCIÓN DEL ÍNDICE DE CONGESTIÓN

Como se justificó en la Sección 4.1, la construcción del índice de congestión parte de intensidad y ocupacion —las dos variables disponibles de forma homogénea para todos los puntos de medida.

La formulación teórica del índice se llevó a la práctica mediante una función específica denominada `calcular_congestion`. Esta función se diseñó para aplicarse directamente sobre el `DataFrame` de tráfico y devolver la misma tabla enriquecida con nuevas columnas auxiliares y con la variable final `congestion`. De esta manera, el cálculo quedó integrado como un paso reproducible dentro del flujo de preparación de datos.

La función recibe como entrada los registros de tráfico con las columnas necesarias para el cálculo: identificador del punto de medida, fecha, tipo de elemento, intensidad y ocupacion. Antes de generar la nueva variable, el procedimiento controla posibles valores no válidos en `intensidad` y `ocupacion`, transformando los valores negativos en datos faltantes. Posteriormente, calcula las variables intermedias definidas en la Sección 4.1: la ocupación normalizada, la intensidad de saturación estimada por punto de medida y el grado de saturación. Finalmente, añade la columna `congestion`, que representa el índice calculado para cada observación temporal.

La importancia de esta implementación radica en que el índice de congestión se convirtió en la variable común del resto del proyecto. A partir de este punto, las fases posteriores dejaron de depender directamente de las variables originales `intensidad` y `ocupacion`, y pasaron a trabajar con una señal homogénea de congestión.

6.6. DEFINICIÓN DE NODOS DEL GRAFO

Una vez construida la señal de congestión, el siguiente paso consistió en definir qué elementos del sistema urbano serían representados como nodos del grafo. Esta decisión es central en la metodología, ya que determina el nivel de granularidad con el que se modela la red de tráfico y condiciona tanto la construcción de aristas como el entrenamiento posterior de los modelos GNN.

En este trabajo se consideraron varias definiciones de nodo. La primera conserva los sensores originales tal como aparecen en el conjunto de datos. Las demás construyen agrupaciones de sensores mediante distintos criterios: proximidad espacial, proximidad combinada con comportamiento temporal, y proximidad combinada con sentido de circulación. Cada alternativa representa una hipótesis distinta sobre cómo debe simplificarse o estructurarse el sistema urbano antes de aplicar modelos de aprendizaje profundo sobre grafos.

Para que las representaciones agregadas fueran comparables entre sí, se trabajó con dos niveles de granularidad: un nivel más compacto, 50 clusters, y un nivel más detallado, 500 clusters. Esta decisión permitió comparar los distintos criterios de agrupación bajo el mismo tamaño de grafo. De este modo, las diferencias observadas en la evaluación posterior no se atribuyen únicamente al número de nodos, sino principalmente al criterio utilizado para construirlos.

La elección de estos dos tamaños responde a una lógica metodológica. La representación de 50 clusters permite analizar una visión más agregada del sistema urbano, reduciendo la complejidad computacional y aproximándose a una escala más macroscópica. En cambio, la representación de 500 clusters conserva mayor detalle espacial, permitiendo mantener diferencias locales entre zonas, tramos o grupos de sensores. Comparar ambos niveles permite estudiar el equilibrio entre simplificación, coste computacional y capacidad predictiva.

En los casos agregados, cada cluster se interpreta como un nodo del grafo. Por tanto, ya no se trabaja directamente con sensores individuales, sino con grupos de sensores que comparten un criterio de agrupación. La señal temporal de cada nodo se obtiene a partir de la información de congestión de los sensores que componen el cluster. Esta transformación permite reducir la dimensión del problema y construir grafos más manejables para los modelos GNN.

La comparación entre estas definiciones permite evaluar si es más adecuado trabajar con la granularidad original de los puntos de medida o con representaciones agregadas. Esta cuestión es relevante porque el conjunto de datos contiene miles de sensores y porque, como se observó en el análisis exploratorio, existen puntos físicamente muy próximos que pueden corresponder a carriles, sentidos o bifurcaciones diferentes. Por tanto, la agrupación no puede asumirse como una operación trivial, sino que debe diseñarse y evaluarse de forma explícita.

Las configuraciones de nodos utilizadas en el proyecto fueron las siguientes: sensores tal cual, agrupación por proximidad, agrupación por proximidad y comportamiento, y agrupación por proximidad y sentido. La primera configuración funciona como caso base de máxima granularidad, mientras que las demás permiten estudiar cómo distintas formas de resumir el sistema urbano afectan al rendimiento predictivo.

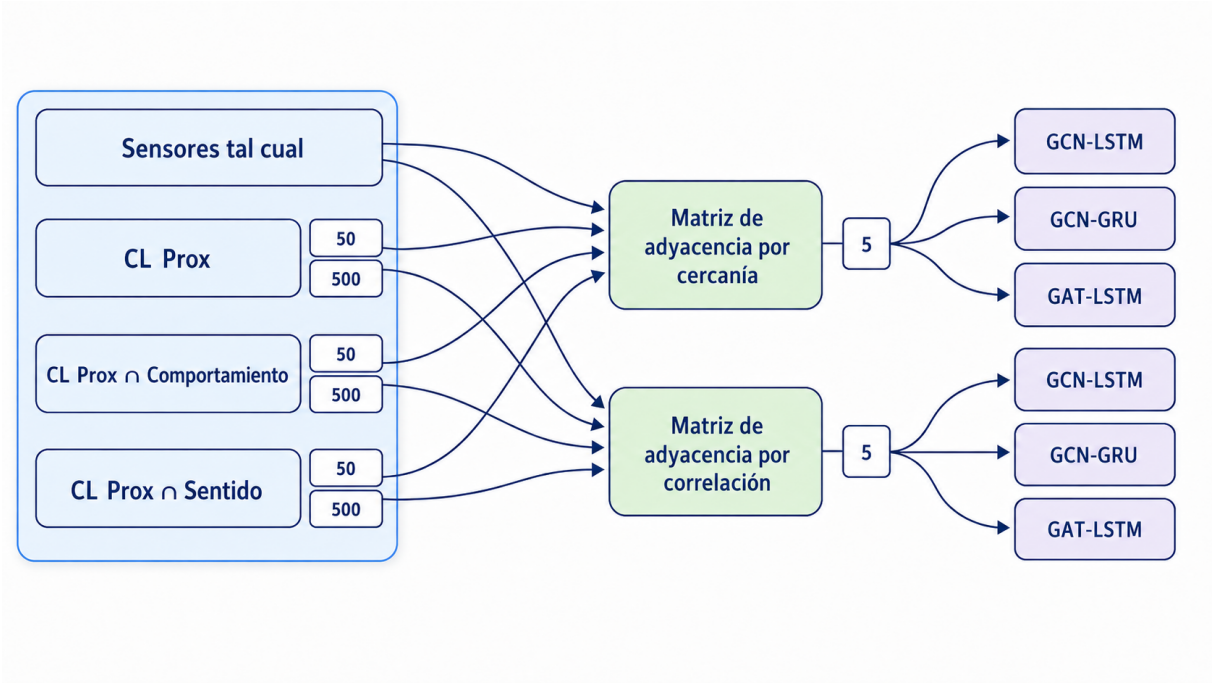

Figura 6.6.: Alternativas de definición de nodos dentro de la arquitectura metodológica

La Figura 6.6 presenta una visión general de la arquitectura metodológica seguida en el proyecto. Aunque el flujo completo se desarrolla en las subsecciones posteriores, en este punto la figura permite ubicar el paso específico abordado en esta sección: la definición de los nodos del grafo. En particular, se resaltan las distintas alternativas consideradas para representar los puntos de medida. A partir de estas representaciones se construirán posteriormente las matrices de adyacencia y se entrenarán las arquitecturas GNN evaluadas.

6.6.1. Sensores tal cual

La primera configuración de nodos consistió en conservar los puntos de medida originales del conjunto de datos. En este caso, cada sensor se representa directamente como un nodo del grafo, sin aplicar ningún procedimiento de agrupación previo. Esta configuración funciona como línea base metodológica, ya que mantiene la máxima granularidad disponible en los datos.

En el análisis inicial de enero de 2025 se identificaron 4.701 puntos de medida únicos en el fichero histórico de tráfico. Bajo esta configuración, cada uno de estos puntos se considera una unidad independiente de observación, con su propia serie temporal de congestión. La señal de cada nodo corresponde, por tanto, al índice de

congestión calculado para ese punto de medida en cada intervalo temporal.

Su papel dentro del diseño experimental es servir como punto de comparación para evaluar si la agregación de sensores aporta ventajas en términos de rendimiento, coste computacional o capacidad de generalización.

La principal ventaja de esta representación es que conserva toda la información disponible a nivel de sensor. No se pierde detalle espacial por agregación y se mantiene la estructura original de los datos publicados. Esto permite que el modelo trabaje con la resolución más fina posible, respetando diferencias entre puntos de medida próximos, carriles, sentidos de circulación o bifurcaciones.

Sin embargo, esta configuración también presenta limitaciones. Al conservar todos los sensores como nodos, el tamaño del grafo es considerablemente mayor que en los casos agregados. Esto incrementa el coste computacional en la construcción de matrices de adyacencia, la preparación de tensores y el entrenamiento de modelos. Además, la existencia de puntos de medida muy próximos puede introducir redundancia espacial, especialmente cuando varios sensores capturan dinámicas similares o pertenecen a una misma zona funcional.

6.6.2. Proximidad

La segunda configuración de nodos se construyó mediante agrupación por proximidad espacial. En este caso, el objetivo fue reducir el número de puntos de medida originales agrupando sensores físicamente cercanos, de manera que cada grupo resultante pudiera interpretarse como un nodo del grafo. Esta representación parte de la hipótesis de que sensores ubicados en una misma zona o tramo próximo pueden compartir parte de la dinámica local del tráfico.

Para esta agrupación se utilizaron las coordenadas UTM de los puntos de medida. Esta decisión fue importante porque las coordenadas UTM están expresadas en metros, lo que permite aplicar criterios de distancia euclídea de forma directa e interpretable. En lugar de trabajar con latitud y longitud, que se expresan en grados, el uso de `utm_x` y `utm_y` permitió definir radios de agrupación mediante valores métricos concretos.

La agrupación espacial se realizó mediante una función denominada `generar_cluster_proximidad`, que recibe como entrada la tabla de sensores y un parámetro `epsilon`. Este parámetro define el radio máximo de vecindad utilizado para formar los grupos. Conceptualmente, dos puntos pueden quedar asociados al mismo cluster si se encuentran dentro de una zona de proximidad definida por ese umbral espacial.

Para mantener la comparabilidad con los demás criterios de agrupación, se buscaron dos configuraciones de proximidad: una de alta granularidad, cercana a 500 clusters, y otra más agregada, cercana a 50 clusters. Se

realizó una búsqueda del valor de `epsilon` que permitiera alcanzar estos tamaños objetivo. Para el caso de 500 clusters, se exploraron valores de `eps` alrededor de 171,60 a 171,80 metros y se seleccionó `eps = 171,63`, obteniendo 500 clusters. Para el caso de aproximadamente 50 clusters, se exploraron valores entre 375 y 380 metros y se seleccionó `eps = 376`, obteniendo 50 clusters.

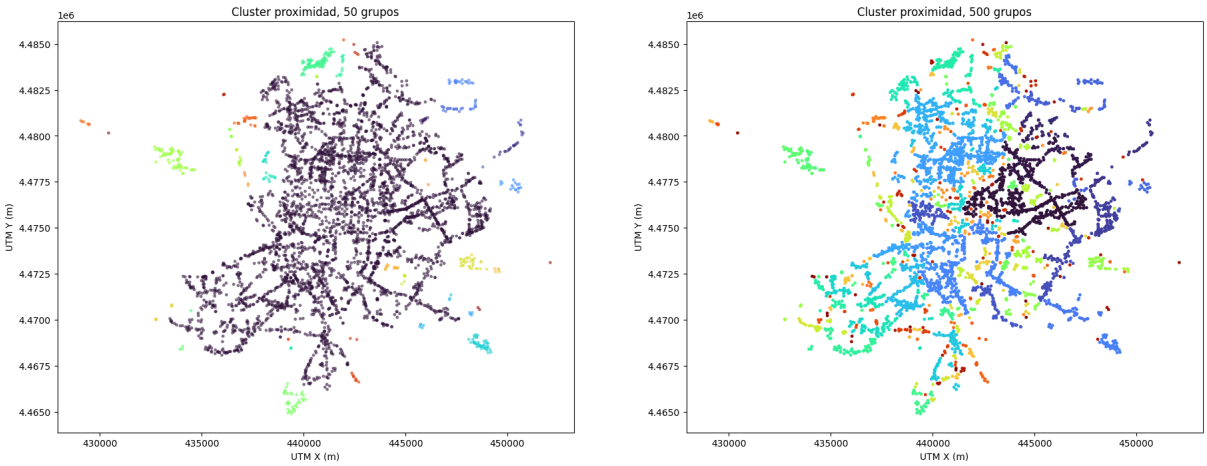

(a) Agrupación en 50 clusters

(b) Agrupación en 500 clusters

Figura 6.7.: Agrupación espacial de puntos de medida mediante proximidad para 50 y 500 clusters.

Como se observa en la Figura 6.7, la configuración de 50 clusters genera una representación más agregada del espacio urbano, mientras que la configuración de 500 clusters conserva una mayor granularidad espacial.

De esta manera, se generaron dos versiones de la representación por proximidad: `proximidad_500` y `proximidad_50`. En ambas, cada cluster se interpreta como un nodo del grafo. La diferencia entre ellas está en el nivel de detalle espacial: la versión de 500 clusters conserva una resolución más fina, mientras que la versión de 50 clusters resume la ciudad en unidades espaciales más amplias.

El resultado de esta etapa fue una tabla de asignación entre puntos de medida y clusters. Para cada sensor se conservó su identificador, su nombre y el identificador del cluster de proximidad al que pertenece. Esta tabla permitió trasladar la señal de congestión desde el nivel original de sensor al nivel agregado de nodo. Además, sirvió como entrada para las etapas posteriores de construcción de aristas y generación de datasets grafo-temporales.

```
cluster_proximidad_500_cl
```

	id	nombre	cluster_proximidad
0	3937	Serrano N-S - General Oraa-Diego de Leon	0
1	5947	Hermanos García Noblejas - Dr. Cirajas-Vital Aza	1
2	10307	Santa Genoveva - Santa Genoveva-Av. Trece Rosas	1
3	6135	Av. Marqués de Corbera - Ntra. Sra. del Villar-Gerardo Cordón	1
4	10447	Francisco Villaespesa - José María Pereda-Hermanos Machado	1
...	...	...	...
4955	4906	LOS YEBENES ENTRADA CRUCE SENTIDO E-O	322
4956	4903	VALMOJADO ENTRE YEBENES Y SESEÑA	322
4957	3637	CTRA. BOADILLA E-O (N-V-CARABIAS)	152
4958	5179	CTRA. BOADILLA O-E (CARABIAS-N-V)	152
4959	3641	CTRA. CARABANCHEL ARAVACA O-E(M502-SANCHIDRIAN) 85m.	179

4601 rows × 3 columns

Tabla 6.3.: Muestra de la asignación de puntos de medida a clusters de proximidad.

La Tabla 6.3 muestra un ejemplo de la asignación generada, donde cada punto de medida queda asociado a un identificador de cluster de proximidad.

6.6.3. Proximidad + comportamiento

La tercera configuración de nodos se construyó combinando dos criterios: proximidad espacial y comportamiento temporal. Esta alternativa surgió a partir de una limitación observada en la agrupación exclusivamente espacial: sensores físicamente cercanos no necesariamente representan la misma dinámica funcional de tráfico. En una ciudad, dos puntos próximos pueden pertenecer a carriles, sentidos o bifurcaciones diferentes y, por tanto, presentar patrones de congestión distintos. Por ello, se planteó una representación que no agrupara los sensores únicamente por distancia, sino también por la similitud de su comportamiento temporal.

Para representar el comportamiento temporal de cada punto de medida se construyó una tabla pivote a partir de la `congestion`. En esta tabla, cada fila corresponde a un punto de medida y cada columna representa un intervalo temporal del día. De esta forma, cada sensor queda descrito por un perfil diario medio de congestión. Sobre esta transformación se obtiene una matriz de comportamiento sobre la cual aplicar *clustering*.

El *clustering* de comportamiento generó dos grupos principales. La distribución obtenida fue de 3.146 sensores en un grupo y 1.455 sensores en el otro, lo que equivale aproximadamente al 68 % y 32 % de los puntos válidos. Esta división no buscaba definir zonas espaciales, sino separar sensores según patrones generales de evolución temporal de la congestión. Por tanto, el resultado del *clustering* de comportamiento no se utilizó directamente como grafo final, sino como un criterio adicional para refinar la agrupación espacial.

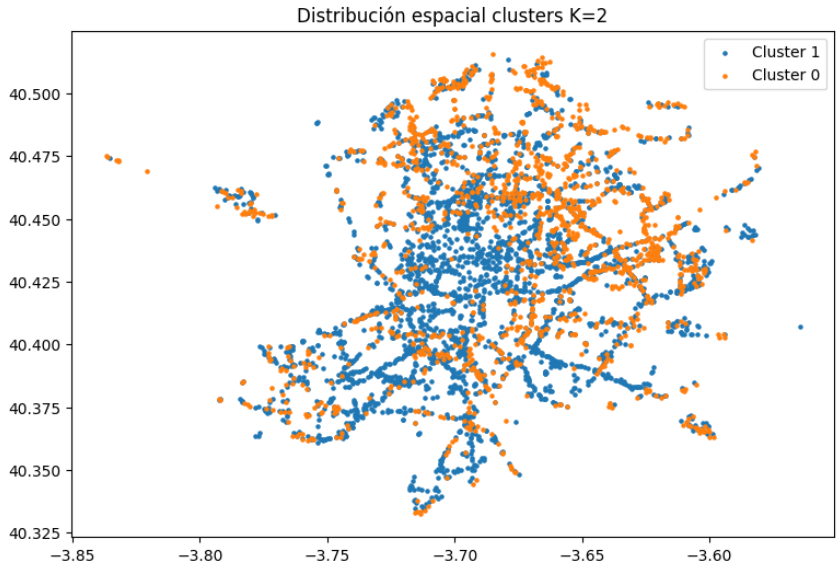

Figura 6.8.: Distribución espacial de los dos grupos obtenidos mediante *clustering* de comportamiento.

Como se observa en la Figura 6.8, los grupos obtenidos por comportamiento no definen zonas espaciales compactas, sino patrones funcionales distribuidos sobre la red urbana. Esto refuerza la idea de que la similitud temporal aporta una dimensión diferente a la proximidad física.

Posteriormente, se construyó la intersección entre el cluster de proximidad y el cluster de comportamiento. La lógica de esta operación fue que dos sensores solo quedaran en el mismo nodo si compartían simultáneamente una relación de cercanía espacial y un mismo patrón general de comportamiento. En términos metodológicos, esta intersección permite obtener nodos más específicos que los generados únicamente por proximidad, ya que evita fusionar sensores cercanos que presentan dinámicas temporales diferentes.

Para mantener la comparabilidad con el resto de casos agregados, también en esta configuración se buscaron dos niveles de granularidad: 500 y 50 clusters. En el caso de mayor detalle, se ajustó el parámetro espacial `eps` hasta obtener 500 clusters en la intersección entre proximidad y comportamiento. El valor seleccionado fue `eps = 195,43`, con el cual se obtuvo la configuración `proximidad_comportamiento_500`. Pa-

ra la versión más agregada, se exploraron valores de `eps` alrededor de 472 metros. En este caso, debido a la sensibilidad de la intersección entre proximidad y comportamiento, no se obtuvo exactamente una configuración de 50 clusters: con `eps = 472` se obtuvieron 51 clusters, mientras que valores ligeramente superiores producían 49 clusters. Se conservó la configuración de 51 clusters por ser la más cercana al objetivo de granularidad definido y por mantener la lógica comparativa con los demás casos. Esta versión se denominó `proximidad_comportamiento_50`.

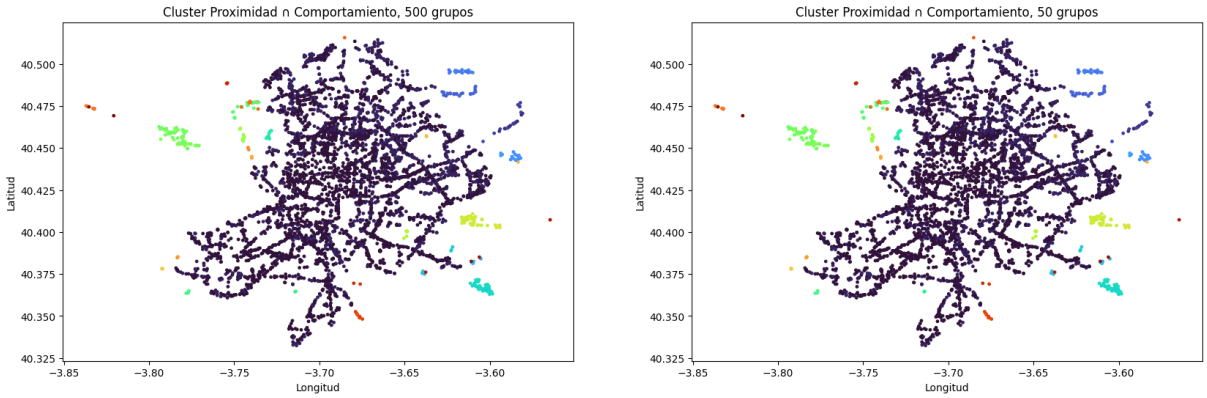

(a) Granularidad cercana a 500 clusters

(b) Granularidad cercana a 50 clusters

Figura 6.9.: Agrupación final por proximidad y comportamiento con dos niveles de granularidad.

Las Figura 6.9 muestran las dos versiones finales de esta configuración. La primera conserva una mayor resolución espacial, mientras que la segunda resume el sistema en unidades más agregadas, manteniendo la restricción adicional de similitud temporal.

El resultado de esta etapa fue una tabla de asignación en la que cada punto de medida queda asociado a un `cluster_proximidad`, un `cluster_comportamiento` y un `cluster_interseccion`. Esta tabla permitió trasladar la señal de congestión desde el nivel de sensor hacia nodos que combinan cercanía física y similitud temporal.

```
cl_interseccion_500_cl
```

	id	nombre	cluster_proximidad	cluster_comportamiento	cluster_interseccion
0	3937	Serrano N-S - General Oraa-Diego de Leon	0	1	1
1	5947	Hermanos García Noblejas - Dr. Cirajas-Vital Aza	0	1	1
2	10307	Santa Genoveva - Santa Genoveva-Av. Trece Rosas	0	0	0
3	6135	Av. Marqués de Corbera - Ntra. Sra. del Villar-Gerardo Cordón	0	1	1
4	10447	Francisco Villaespesa - José María Pereda-Hermanos Machado	0	1	1
...	...	...	...	...	...
4596	4906	LOS YEBENES ENTRADA CRUCE SENTIDO E-O	218	1	360
4597	4903	VALMOJADO ENTRE YEBENES Y SESEÑA	218	1	360
4598	3637	CTRA. BOADILLA E-O (N-V-CARABIAS)	101	1	180
4599	5179	CTRA. BOADILLA O-E (CARABIAS-N-V)	101	1	180
4600	3641	CTRA. CARABANCHEL ARAVACA O-E(M502-SANCHIDRIAN) 85m.	120	1	212

4601 rows × 5 columns

Tabla 6.4.: Muestra de la asignación de puntos de medida a clusters de proximidad, comportamiento e intersección.

La Tabla 6.4 muestra un ejemplo de la estructura generada. En ella se observa cómo cada sensor conserva su identificador y nombre, pero además incorpora los tres niveles de agrupación utilizados en esta configuración.

```
ids= [5008, 5032, 5033, 10424, 10425]

cl_interseccion_500_cl[cl_interseccion_500_cl.id.isin(ids)]
```

	id	nombre	cluster_proximidad	cluster_comportamiento	cluster_interseccion
747	5008	Pº EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	65	1	115
757	10425	PSO. EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	65	1	115
758	5032	GRAL. MANSO N-S(ALMIRANTE REQUESENS-PSO. EXTREMADURA)	65	1	115
759	5033	MILAGROSA S-N(JOSE ESPELIUS-PSO. EXTREMADURA)	65	0	114
760	10424	PSO. EXTREMADURA E-O(GRAL. MANSO-ALFONSO CEA)	65	0	114

Tabla 6.5.: Ejemplo de refinamiento de la agrupación espacial mediante el criterio de comportamiento.

La Tabla 6.5 ilustra de forma concreta la lógica de esta intersección. En este ejemplo, varios sensores pertenecen al mismo `cluster_proximidad`, pero quedan separados en distintos `cluster_interseccion` porque no comparten el mismo `cluster_comportamiento`. Esto evidencia que la incorporación del comportamiento temporal permite refinar la agrupación espacial y evitar la fusión de sensores cercanos con dinámicas distintas.

La representación proximidad + comportamiento tiene un papel metodológico importante en el TFM porque introduce una definición de nodo menos dependiente de la geometría física y más alineada con la dinámica observada en los datos. Frente al caso de proximidad simple, esta configuración intenta capturar unidades

urbanas que no solo están cerca, sino que además se comportan de forma similar en términos de congestión. Esto permite evaluar si la información comportamental aporta una estructura más útil para la predicción que la agrupación exclusivamente espacial.

6.6.4. Proximidad + sentido

La cuarta configuración de nodos se construyó combinando proximidad espacial y sentido de circulación. Esta alternativa surgió a partir de una limitación identificada en las agrupaciones exclusivamente espaciales: dos puntos de medida pueden estar muy próximos entre sí, pero pertenecer a calzadas, carriles, bifurcaciones o sentidos de circulación diferentes. En estos casos, agrupar únicamente por distancia puede mezclar sensores que no representan la misma dinámica funcional del tráfico.

Para abordar esta limitación, se incorporó información de la red viaria procedente de OpenStreetMap. La idea fue asociar cada punto de medida al tramo de vía más cercano y extraer de dicho tramo una aproximación a su orientación y sentido de circulación. De esta manera, la agrupación final no depende solo de que dos sensores estén cerca, sino también de que compartan una dirección compatible dentro de la red urbana.

Se trabajó con dos versiones de la variable de sentido. La primera versión, denominada aquí sentido V1, clasificó los puntos en cuatro direcciones cardinales generales: norte-sur, sur-norte, este-oeste y oeste-este. Esta aproximación permitió incorporar el sentido de circulación de manera simple y construir una primera intersección entre proximidad y dirección.

La segunda versión, denominada sentido V2, refinó la codificación del sentido. En este caso, se separaron explícitamente dos conceptos: la orientación geométrica de la vía y el sentido real de circulación. Para ello se utilizaron variables como `eje_via`, `sentido_flecha` y `sentido_claro`. La variable `sentido_claro` combina ambas informaciones en una etiqueta más interpretable, por ejemplo, diferenciando entre una vía orientada este-oeste y el flujo real hacia el este u oeste. Esta segunda versión produjo ocho etiquetas de sentido, lo que permitió distinguir mejor calzadas paralelas o tramos cercanos con sentidos opuestos.

```
resultado_1_version[resultado_1_version.id.isin(ids)][cols_1_version]
```

	id	nombre	latitud	longitud	utm_x	utm_y	name	sentido_cardinal
809	5008	Pº EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	40.410595	-3.736880	437478.262625	4.473591e+06	Paseo de Extremadura	ESTE-OESTE
834	10425	PSO. EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	40.411132	-3.735439	437600.994596	4.473650e+06	Paseo de Extremadura	ESTE-OESTE
835	5032	GRAL. MANSO N-S(ALMIRANTE REQUESENS-PSO. EXTREMADURA)	40.410774	-3.736740	437490.229111	4.473611e+06	Calle del General Manso	SUR-NORTE
836	5033	MILAGROSA S-N(JOSE ESPELIUS-PSO. EXTREMADURA)	40.410528	-3.736327	437525.124059	4.473584e+06	Calle de la Milagrosa	SUR-NORTE
837	10424	PSO. EXTREMADURA E-O(GRAL. MANSO-ALFONSO CEA)	40.410788	-3.736158	437539.685290	4.473612e+06	Paseo de Extremadura	OESTE-ESTE

```
resultado_2_version[resultado_2_version.id.isin(ids)][cols_2_version]
```

	id	nombre	latitud	longitud	utm_x	utm_y	name	sentido_claro
809	5008	Pº EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	40.410595	-3.736880	437478.262625	4.473591e+06	Paseo de Extremadura	EJE_E-O | ← O
834	10425	PSO. EXTREMADURA E-O(TURISMUNDO-GRAL. MANSO)	40.411132	-3.735439	437600.994596	4.473650e+06	Paseo de Extremadura	EJE_E-O | ← O
835	5032	GRAL. MANSO N-S(ALMIRANTE REQUESENS-PSO. EXTREMADURA)	40.410774	-3.736740	437490.229111	4.473611e+06	Calle del General Manso	EJE_N-S | ↓ S
836	5033	MILAGROSA S-N(JOSE ESPELIUS-PSO. EXTREMADURA)	40.410528	-3.736327	437525.124059	4.473584e+06	Calle de la Milagrosa	EJE_N-S | ↑ N
837	10424	PSO. EXTREMADURA E-O(GRAL. MANSO-ALFONSO CEA)	40.410788	-3.736158	437539.685290	4.473612e+06	Paseo de Extremadura	EJE_E-O | → E

Figura 6.10.: Ejemplo de codificación del sentido de circulación para sensores próximos.

Como se observa en la Figura 6.10, sensores ubicados en una misma zona pueden requerir una diferenciación adicional por sentido de circulación. Este ejemplo ilustra la diferencia entre una codificación direccional más general y una codificación más detallada del eje y el flujo real de la vía.

Una vez calculadas las variables de sentido, se construyó la agrupación final mediante intersección entre el cluster de proximidad y la categoría de sentido. La lógica de esta operación fue que dos sensores solo permanecieran en el mismo nodo si, además de estar próximos espacialmente, compartían una misma categoría de sentido. Así, el cluster final representa una unidad más específica que la agrupación por proximidad simple.

Al igual que en las otras configuraciones agregadas, se generaron dos niveles de granularidad para mantener la comparabilidad experimental: 500 y 50 clusters. Para la versión V1, se ajustó el valor de `eps` del clustering

espacial hasta obtener una intersección de 500 clusters con $\texttt{eps} = 221,80$. Para la escala más agregada, se utilizó $\texttt{eps} = 683,38$, obteniendo 49 clusters. Aunque no se alcanzó exactamente el valor objetivo de 50, se conservó esta configuración por ser la más próxima dentro de la búsqueda realizada.

En la versión V2, la intersección entre proximidad y sentido más detallado produjo una configuración de 501 clusters con $\texttt{eps} = 232,20$. Para la escala agregada, se utilizó $\texttt{eps} = 770$, obteniendo 53 clusters. En este caso, la diferencia respecto al objetivo de 50 se debe a la mayor granularidad introducida por las ocho categorías de sentido, que dividen los grupos espaciales en unidades más específicas.

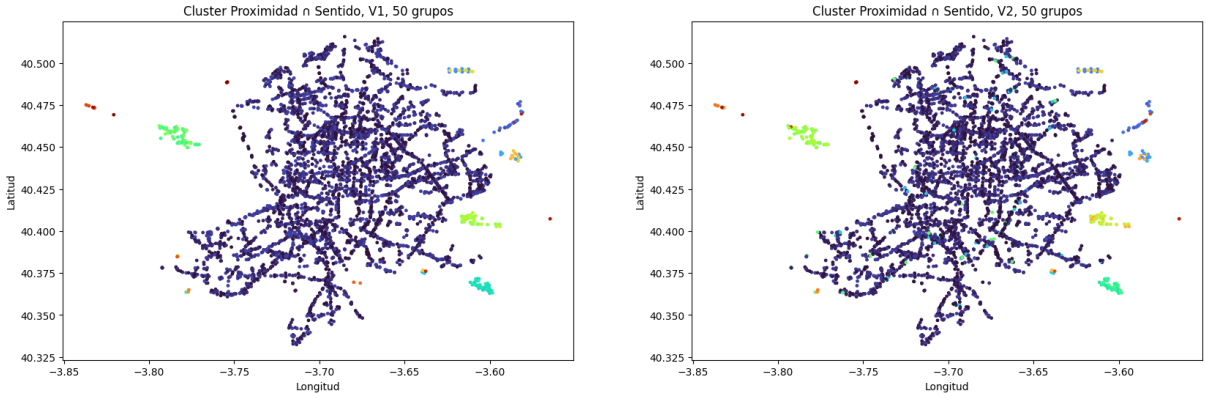

(a) Sentido V1, escala agregada

(b) Sentido V2, escala agregada

Figura 6.11.: Agrupación por proximidad y sentido para configuraciones cercanas a 50 clusters.

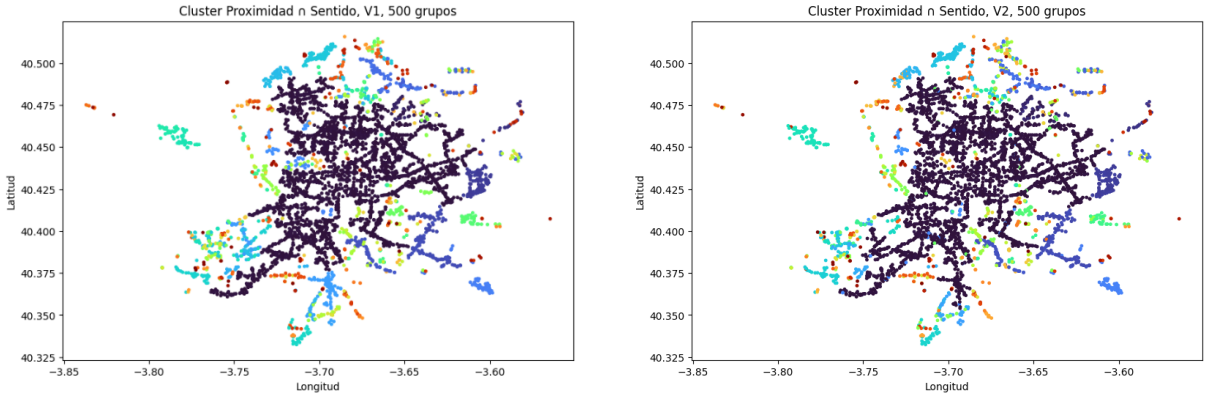

(a) Sentido V1, escala detallada

(b) Sentido V2, escala detallada

Figura 6.12.: Agrupación por proximidad y sentido para configuraciones cercanas a 500 clusters.

Las Figuras 6.11 y 6.12 muestran las configuraciones obtenidas para los dos niveles de granularidad. En ambos

casos, la versión V2 introduce una separación más específica que la versión V1, debido a que incorpora una codificación más detallada del eje y del sentido de circulación.

El resultado de esta etapa fueron cuatro tablas de asignación de sensores a nodos: proximidad-sentido V1 con aproximadamente 500 clusters, proximidad-sentido V1 con aproximadamente 50 clusters, proximidad-sentido V2 con aproximadamente 500 clusters y proximidad-sentido V2 con aproximadamente 50 clusters. En cada tabla, cada punto de medida queda asociado a un cluster de proximidad, una categoría de sentido y un cluster final de intersección.

Desde el punto de vista experimental, las dos versiones de sentido permiten comparar distintos niveles de detalle en la incorporación de información viaria. La versión V1 introduce una clasificación direccional más simple y compacta, mientras que la versión V2 ofrece una codificación más clara e interpretable del eje y del flujo de circulación. La evaluación posterior permitirá analizar si esta información adicional mejora la representación de los nodos o si introduce una fragmentación excesiva del grafo.

En conjunto, la configuración proximidad + sentido completa el conjunto de alternativas de nodos evaluadas en el proyecto. Junto con sensores tal cual, proximidad y proximidad + comportamiento, permite estudiar distintas hipótesis sobre la estructura del sistema urbano: mantener la granularidad original, agrupar por cercanía física, agrupar por cercanía y comportamiento temporal, o agrupar por cercanía y sentido de circulación.

6.7. CONSTRUCCIÓN DE ARISTAS Y MATRICES DE ADYACENCIA

Una vez definidos los nodos del grafo, el siguiente paso consistió en establecer las relaciones entre ellos. En una red neuronal de grafos, los nodos no se procesan de forma completamente aislada, sino que intercambian información con otros nodos conectados. Por esta razón, la construcción de aristas constituye una decisión metodológica fundamental: determina qué nodos pueden influirse entre sí durante el aprendizaje del modelo.

En este proyecto se construyeron dos tipos de adyacencia: una basada en cercanía espacial y otra basada en correlación temporal. La primera representa una hipótesis física: los nodos próximos en el espacio pueden compartir o transmitir dinámicas locales de congestión. La segunda representa una hipótesis comportamental: dos nodos pueden estar relacionados, aunque no estén próximos si sus series temporales de congestión evolucionan de forma similar.

La Figura 6.13 permite ubicar el paso específico abordado en esta sección: la construcción de las matrices de adyacencia. En particular, se resaltan las dos alternativas consideradas para definir las relaciones entre nodos,

basadas en cercanía espacial y correlación temporal. A partir de estas estructuras se generan posteriormente los datasets grafo-temporales y se evalúan las distintas arquitecturas GNN.

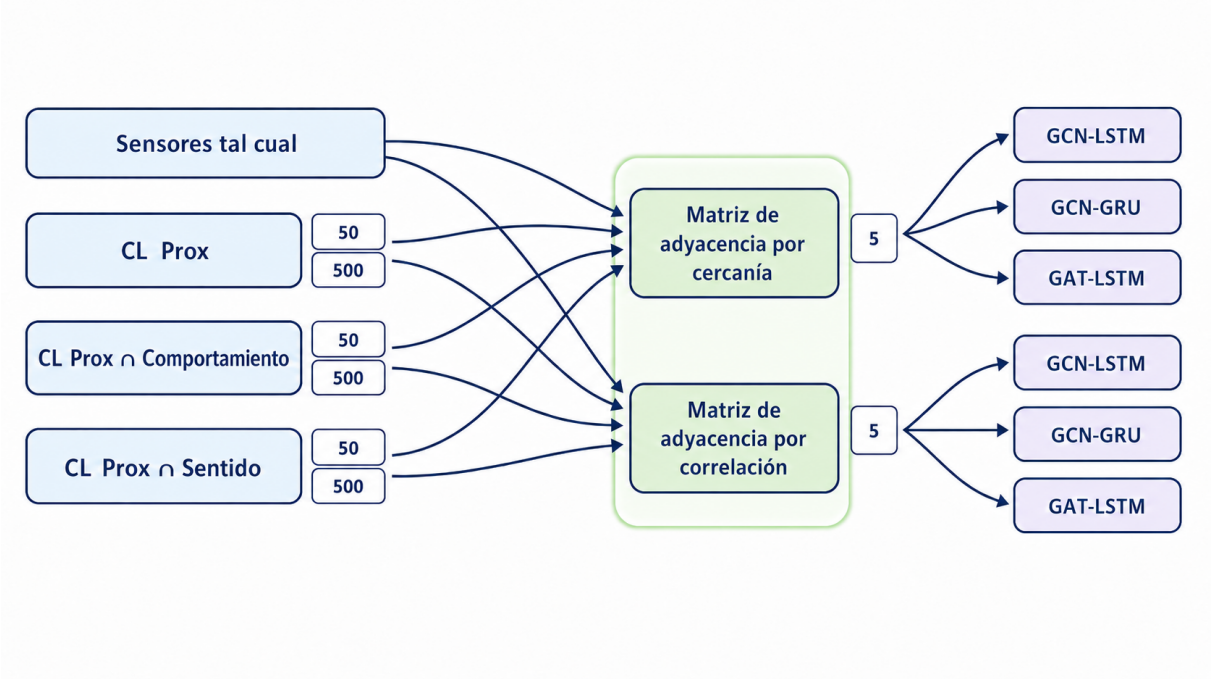

Figura 6.13.: Construcción de matrices de adyacencia en la metodología propuesta

En ambos enfoques, la salida se organizó en dos formatos. Por un lado, se generó una tabla interpretable de aristas, donde cada fila contiene un nodo origen, un nodo destino y un peso asociado. Por otro lado, se generaron los tensores necesarios para `PyTorch Geometric`: `edge_index`, que contiene la conectividad del grafo, y `edge_weight`, que contiene el peso de cada arista. Esta conversión permitió que las matrices de adyacencia construidas metodológicamente pudieran ser utilizadas directamente por los modelos GNN.

6.7.1. Adyacencia por cercanía

La primera estrategia de construcción de aristas se basó en la cercanía espacial entre nodos. En este enfoque, dos nodos se conectan si se encuentran entre los vecinos más próximos en el espacio. La finalidad fue representar una estructura local del sistema urbano, bajo la hipótesis de que la congestión puede propagarse o estar relacionada entre zonas físicamente cercanas.

Cuando los nodos corresponden a sensores individuales, la localización del nodo viene dada directamente por las coordenadas del punto de medida. En cambio, cuando los nodos corresponden a clusters de sensores, cada nodo no posee una ubicación puntual original. Por ello, antes de construir la adyacencia espacial, se calculó una localización representativa para cada cluster mediante el centroide geométrico de sus sensores. Este centroide se obtuvo promediando las coordenadas UTM `utm_x` y `utm_y` de los puntos de medida que forman parte del cluster.

Una vez calculados los centroides, para cada nodo se identificaron sus cinco vecinos más cercanos. Para ello se utilizó un modelo de vecinos más próximos con distancia euclídea. Se empleó `NearestNeighbors` con `n_neighbors = k + 1`, donde `k = 5`. El valor adicional se debe a que el vecino más cercano de cada nodo es el propio nodo; por tanto, ese primer elemento se descarta y se conservan únicamente los cinco vecinos reales.

A partir de este procedimiento se construyó un grafo dirigido. Una arista $i \rightarrow j$ indica que el nodo j pertenece al conjunto de los cinco vecinos espaciales más cercanos del nodo i. Esta decisión implica que la relación no necesariamente es simétrica: puede ocurrir que j esté entre los vecinos más cercanos de i, pero que i no esté entre los vecinos más cercanos de j.

Además de la conectividad, se asignó un peso a cada arista. El peso se definió de forma inversamente relacionada con la distancia: nodos más cercanos reciben pesos más altos, mientras que nodos más lejanos reciben pesos más bajos. Este peso se calcula mediante una transformación exponencial de la distancia, utilizando como escala la distancia media de las aristas generadas. De este modo, la adyacencia espacial no solo indica qué nodos están conectados, sino también la intensidad relativa de esa cercanía.

```
••• Tabla de aristas:
```

	source	target	distance	weight
0	0	362	286.854249	0.645756
1	0	466	709.924756	0.338802
2	0	397	829.958376	0.282143
3	0	312	886.637226	0.258787
4	0	348	903.201545	0.252333

```
edge_index shape: torch.Size([2, 2500])
edge_weight shape: torch.Size([2500])
```

Tabla 6.6.: Esquema de construcción de adyacencia por cercanía.

La Tabla 6.6 resume el procedimiento seguido para construir la adyacencia por cercanía. En primer lugar, cada nodo se representa mediante la localización del sensor o mediante el centroide del cluster. Posteriormente, se calculan las distancias euclídeas entre nodos, se seleccionan los cinco vecinos más cercanos y se generan aristas dirigidas y ponderadas.

El resultado de este proceso fue una tabla `edges_df` con tres elementos principales: nodo origen, nodo destino y peso de la relación. Posteriormente, esta tabla se transformó en los tensores `edge_index` y `edge_weight`, que constituyen el formato requerido por los modelos GNN. La validación del grafo incluyó comprobar la forma de estos tensores y verificar que no existieran nodos sin aristas salientes.

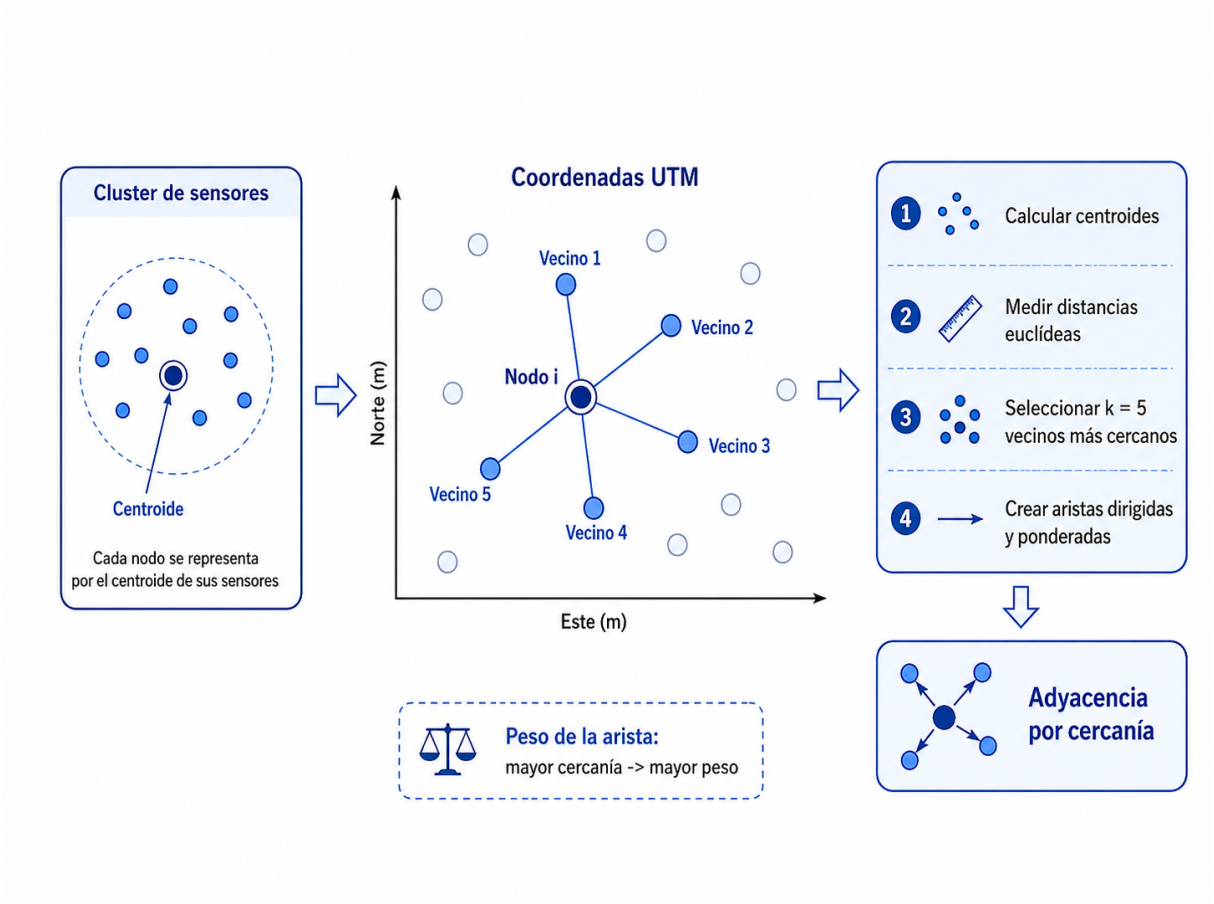

Figura 6.14.: Ejemplo gráfico del proceso de construcción de adyacencia por cercanía.

La Figura 6.14 presenta un ejemplo gráfico del proceso de construcción de la adyacencia por cercanía, mostrando la identificación de vecinos próximos y la generación de aristas ponderadas.

6.7.2. Adyacencia por correlación

La segunda estrategia de construcción de aristas se basó en la correlación temporal entre las series de congestión de los nodos. En este caso, la relación entre dos nodos no se define por su distancia física, sino por la similitud de su comportamiento a lo largo del tiempo. Esta adyacencia responde a la hipótesis de que dos zonas pueden compartir patrones de congestión aunque no se encuentren próximas en el espacio.

El primer paso fue construir una tabla temporal por nodo. En esta tabla, las filas corresponden a instantes temporales y las columnas corresponden a nodos o clusters. El valor de cada celda es la congestión del nodo en ese instante. Esta estructura permitió comparar el comportamiento temporal de todos los nodos mediante sus series de congestión.

Sobre esta tabla se calculó la matriz de correlación de Pearson entre nodos. Cada elemento de la matriz representa el grado de asociación lineal entre las series temporales de congestión de dos nodos. A partir de esta matriz, para cada nodo i se buscaron los cinco nodos con mayor correlación, excluyendo la autocorrelación del nodo consigo mismo.

El procedimiento genera una lista de aristas donde cada relación $i \rightarrow j$ indica que el nodo j se encuentra entre los cinco nodos más correlacionados con el nodo i. El peso de la arista corresponde al valor de la correlación entre ambas series. De esta forma, la estructura del grafo captura relaciones comportamentales y no únicamente relaciones de proximidad física.

Durante esta construcción se identificó un problema específico: algunos nodos podían presentar congestión constante durante el periodo analizado. En esos casos, la desviación estándar de la serie es cero y la correlación con otros nodos no puede calcularse de forma válida. Para evitar inconsistencias en la matriz de correlación, estos nodos se eliminaron antes de construir la adyacencia por correlación. En el ejemplo trabajado en el desarrollo para el caso de proximidad con 500 clusters, se eliminaron dos clusters constantes, quedando una tabla válida con 498 nodos para la construcción del grafo por correlación.

Después de eliminar los nodos constantes, se recalculó la matriz de correlación y se generaron las aristas *top-k*. Dado que al eliminar nodos la numeración original de clusters puede dejar de ser consecutiva, fue necesario crear un mapeo entre las etiquetas originales de los clusters y una nueva numeración consecutiva. Este paso fue indispensable para garantizar que los índices del grafo coincidieran con las columnas de la tabla temporal utilizada por la GNN.

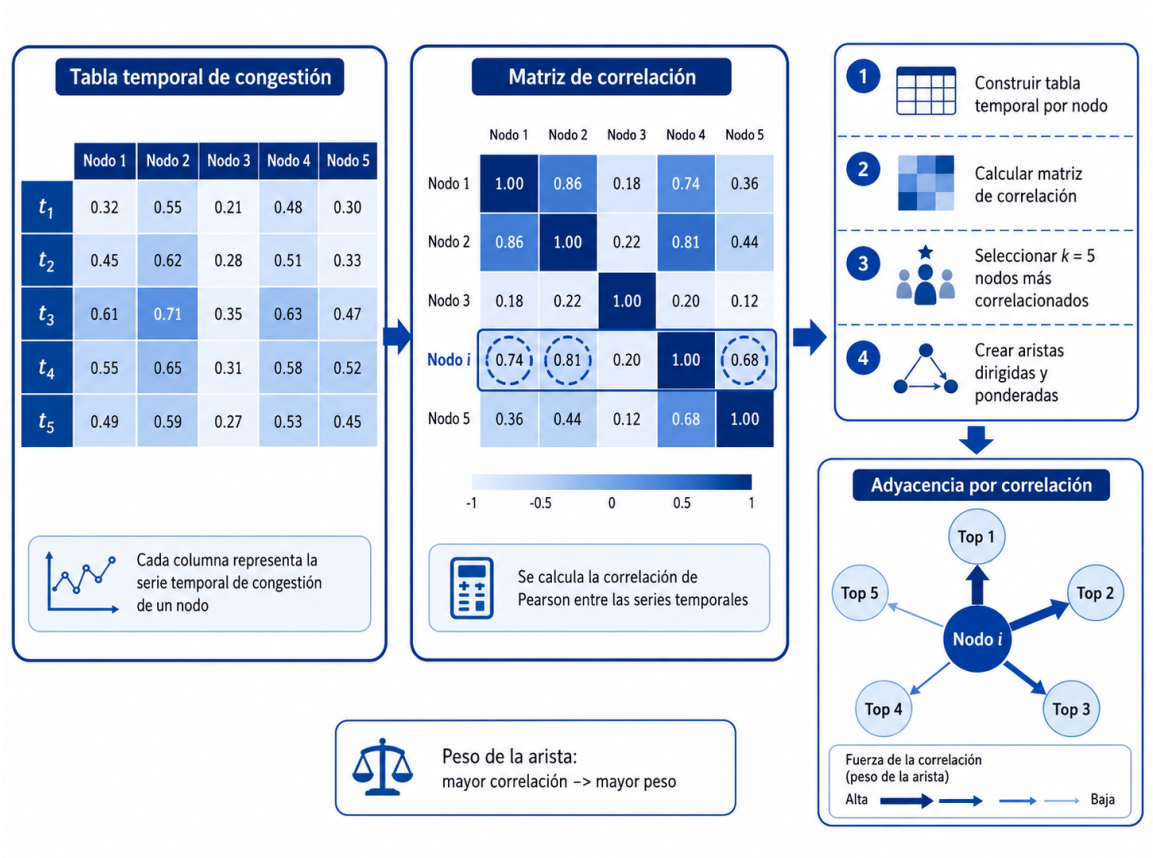

Figura 6.15.: Esquema de construcción de adyacencia por correlación.

La Figura 6.15 resume el procedimiento seguido para construir la adyacencia por correlación. A partir de la tabla temporal de congestión por nodo, se calcula la matriz de correlación de Pearson, se seleccionan los cinco nodos más correlacionados con cada nodo y se generan aristas dirigidas y ponderadas. En este caso, el peso de la arista refleja directamente la fuerza de la correlación entre las series temporales.

El resultado final de esta etapa fue una tabla `edges_corr_df` con las aristas en formato interpretable, una tabla `edges_corr_gnn` con los índices ya remapeados y los tensores `edge_index_corr` y `edge_weight_corr`. También se generó `tabla_gnn`, que corresponde a la matriz temporal por nodo con columnas remapeadas en el mismo orden que el grafo. Esta validación permitió asegurar que el número de nodos del grafo y el número de columnas de la tabla temporal coincidieran correctamente.

	source	target	weight
0	0	102	0.991816
1	0	81	0.986954
2	0	396	0.986182
3	0	147	0.983237
4	0	115	0.983054

Tabla 6.7.: Ejemplo de aristas generadas en la adyacencia por correlación.

La Tabla 6.7 muestra un ejemplo de las aristas obtenidas mediante este procedimiento. Cada fila contiene un nodo origen, un nodo destino y el peso asociado a la relación, que en este caso corresponde al valor de correlación entre ambas series temporales.

La adyacencia por correlación tiene un papel central en el enfoque del trabajo porque permite representar relaciones funcionales entre nodos. A diferencia de la cercanía espacial, esta matriz puede conectar nodos alejados si presentan patrones temporales similares.

6.8. PREPARACIÓN DE DATASETS PARA GNN

Una vez definidos los nodos y construidas las matrices de adyacencia, el siguiente paso consistió en preparar los datos en un formato compatible con modelos basados en redes neuronales de grafos.

El objetivo de esta fase fue transformar la señal de congestión en una estructura espaciotemporal. Para ello, cada nodo del grafo debía disponer de una serie temporal de congestión y, al mismo tiempo, debía conservarse la información relacional definida por las aristas. En consecuencia, el dataset final no se compone únicamente de una tabla temporal, sino de la combinación entre señales por nodo, ventanas temporales y conectividad del grafo.

La preparación del dataset partió de las tablas de asignación de nodos generadas en la Sección 6.6. En los casos agregados, cada sensor estaba asociado a un cluster, por lo que fue necesario trasladar la señal de congestión desde el nivel de punto de medida hasta el nivel de nodo. Para ello, la congestión de los sensores pertenecientes a un mismo cluster se agregó temporalmente, generando una única serie representativa por nodo. En el caso de sensores tal cual, esta agregación no fue necesaria, ya que cada punto de medida se mantuvo como nodo

independiente.

Después de obtener la señal temporal por nodo, se construyó una tabla en la que cada fila representa un instante temporal y cada columna representa un nodo del grafo. Esta tabla constituye la base temporal del dataset, ya que permite observar la evolución simultánea de la congestión en todos los nodos. Además, esta misma estructura fue necesaria para la construcción de la adyacencia por correlación, como se explicó en la sección anterior.

A partir de la tabla temporal por nodo se generaron ventanas temporales de entrada y salidas futuras. Cada muestra del dataset está formada por una secuencia de observaciones pasadas y por el valor de congestión que se desea predecir en un instante posterior. De este modo, el problema se formuló como una tarea supervisada: el modelo recibe como entrada la evolución reciente de la congestión en todos los nodos y aprende a estimar la congestión futura.

La entrada al modelo se estructura como un tensor de tres dimensiones: tiempo (longitud de la ventana de entrada), nodos (número de nodos del grafo) y características (variables por nodo). La señal principal utilizada fue la congestión calculada previamente, aunque el pipeline permite incorporar variables adicionales. La Tabla 6.8 detalla los cuatro componentes que conforman cada muestra del dataset.

Componente	**Qué representa**	**Cómo se obtiene en el pipeline**
`X`	Tensor de entrada del modelo. Contiene la ventana temporal pasada de congestión por nodo.	Se construye a partir de la tabla temporal por nodo y las ventanas temporales.
`y`	Variable objetivo. Corresponde a la congestión futura que el modelo debe predecir.	Se obtiene desplazando la serie temporal respecto a la ventana de entrada.
`edge_index`	Estructura de conectividad del grafo. Indica qué nodos están conectados mediante aristas.	Se genera a partir de la tabla de aristas por cercanía o por correlación.
`edge_weight`	Peso de cada arista del grafo. Indica la intensidad de la relación entre nodos.	Se obtiene de la distancia espacial transformada en peso o del valor de correlación temporal.

Tabla 6.8.: Elementos principales del dataset grafo-temporal utilizado por los modelos GNN.

La preparación de los datasets se realizó para cada combinación de caso de nodos, tamaño de agrupación, tipo de adyacencia y periodo temporal. Esto permitió que las distintas configuraciones fueran comparables entre sí. Por ejemplo, para una misma definición de nodos podía generarse un dataset con adyacencia por cercanía y otro con adyacencia por correlación, manteniendo el resto de condiciones constantes.

Además, se aplicó una división temporal de los datos para separar entrenamiento, validación y prueba. Esta decisión es importante en problemas de series temporales, ya que evita mezclar observaciones futuras dentro del entrenamiento. En lugar de realizar una partición aleatoria, los datos se ordenaron cronológicamente y se separaron respetando la estructura temporal del problema.

El resultado final de esta fase fue un conjunto de datasets grafo-temporales listos para ser utilizados por los modelos GNN, con la estructura ilustrada en la Figura 6.16.

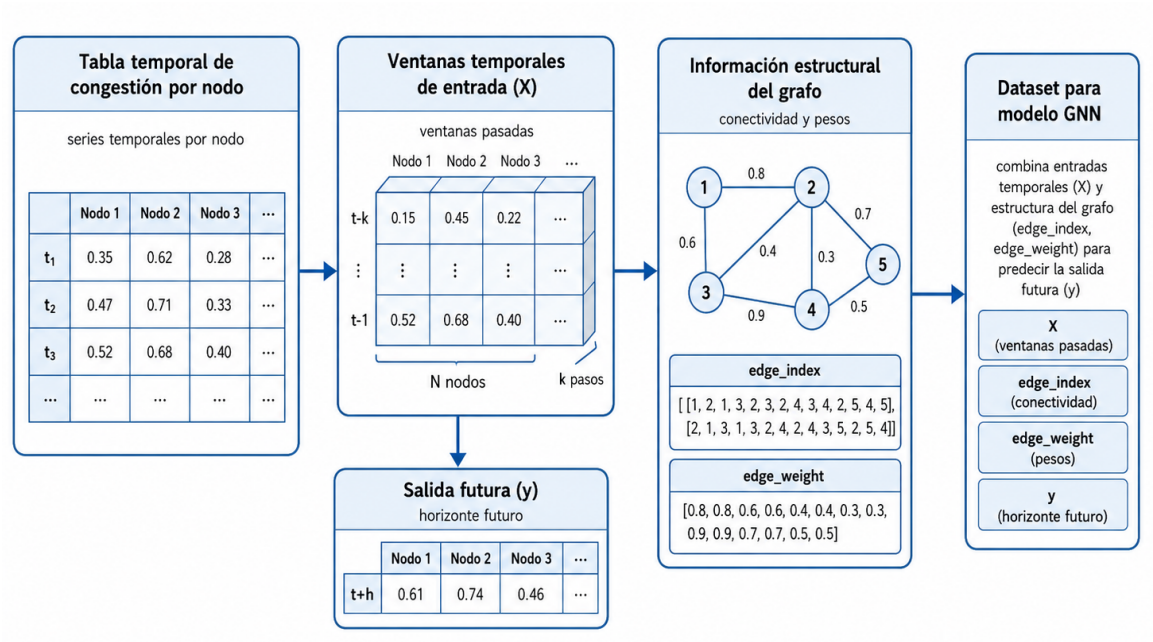

Figura 6.16.: Estructura del dataset grafo-temporal.

6.9. ARQUITECTURA

Una vez preparados los datasets grafo-temporales, se procedió al entrenamiento de modelos capaces de combinar información espacial y temporal. El objetivo de esta etapa fue evaluar si las representaciones construidas en las fases anteriores permitían predecir la congestión futura de los nodos del grafo.

La Figura 6.17 permite ubicar el paso específico abordado en esta sección: la etapa de modelado. En particular, se resaltan las tres arquitecturas evaluadas en el trabajo —`GCN-LSTM`, `GCN-GRU` y `GAT-LSTM`—, aplicadas sobre las distintas configuraciones de nodos y matrices de adyacencia construidas previamente. De este modo, la figura muestra cómo la representación del grafo se integra finalmente con los modelos para producir la predicción de congestión.

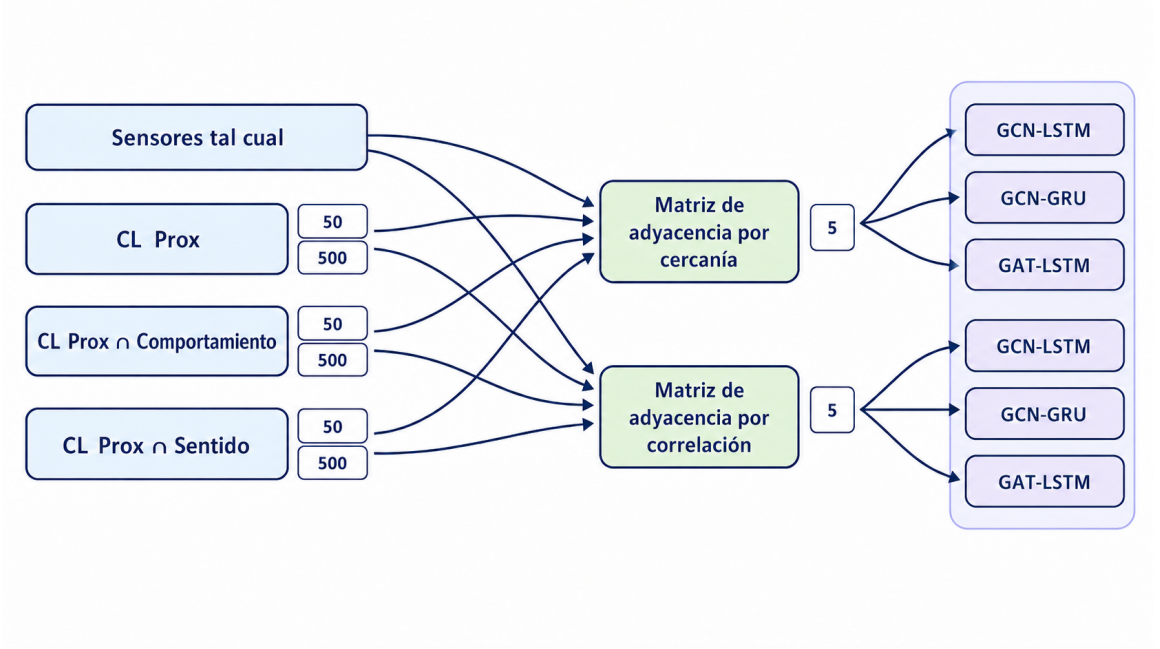

Figura 6.17.: Resaltado de la etapa de modelado dentro del flujo metodológico general.

Los tres modelos fueron diseñados con una misma lógica de entrada y salida para garantizar que pudieran compararse bajo las mismas condiciones experimentales. Como entrada reciben una secuencia temporal `x_seq`, que contiene ventanas pasadas de información por nodo, junto con la estructura del grafo representada mediante `edge_index` y, cuando corresponde, `edge_weight`. En términos generales, `x_seq` tiene la forma `[batch_size, window, N, F]`, donde `batch_size` es el número de muestras procesadas por lote, `window` es la longitud de la ventana temporal, `N` es el número de nodos del grafo y `F` es el número de características por nodo.

La implementación sigue una estrategia común en los tres modelos. Primero, para cada instante de la ventana temporal, se aplica el componente espacial sobre el grafo. Después, las representaciones generadas para cada nodo se reorganizan como secuencias temporales. Finalmente, el componente recurrente procesa la evolución temporal de cada nodo y una capa lineal genera la predicción final de congestión.

La salida de los modelos es un tensor con forma `[batch_size, N]`. Es decir, para cada muestra del lote, el modelo devuelve una predicción de congestión futura para todos los nodos del grafo. Esta salida se compara posteriormente con la variable objetivo `y`, preparada en los datasets grafo-temporales.

La Tabla 6.9 resume las arquitecturas evaluadas, distinguiendo la parte espacial, la parte temporal y el propósito comparativo de cada una.

Modelo	**Parte espacial**	**Parte temporal**	**Característica principal**
`GCN-LSTM`	`GCN`	`LSTM`	Se utiliza como modelo base de referencia. Combina convolución sobre grafos para captar relaciones entre nodos y memoria temporal `LSTM` para modelar la evolución de la congestión.
`GCN-GRU`	`GCN`	`GRU`	Mantiene el mismo componente espacial que `GCN-LSTM`, pero sustituye `LSTM` por `GRU` para comparar el efecto del componente temporal con una arquitectura recurrente más compacta.
`GAT-LSTM`	`GAT`	`LSTM`	Mantiene el mismo componente temporal que `GCN-LSTM`, pero sustituye `GCN` por `GAT` para comparar el efecto del componente espacial mediante un mecanismo de atención sobre los nodos vecinos.

Tabla 6.9.: Comparación de las arquitecturas evaluadas en el proyecto.

La Figura 6.18 muestra de forma esquemática la implementación comparativa de las tres arquitecturas evaluadas. En los tres casos, la entrada corresponde a `x_seq`, y el flujo general mantiene la misma lógica: primero se aplica el componente espacial sobre el grafo, después se procesa la dimensión temporal mediante un bloque recurrente, y finalmente una capa lineal genera la predicción $\hat{y}$.

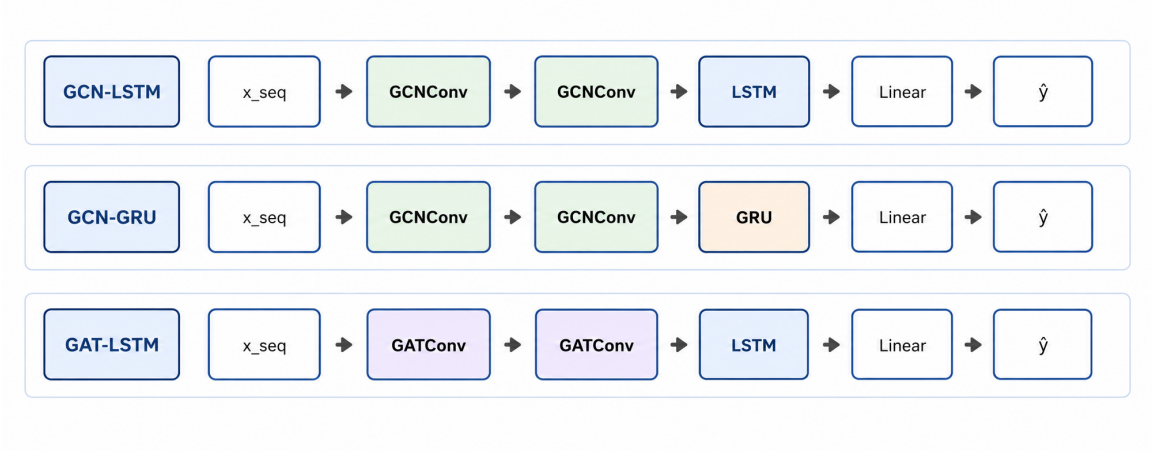

Figura 6.18.: Esquema comparativo de implementación de los modelos.

6.9.1. GCN-LSTM

El modelo `GCN-LSTM` se implementó mediante una clase denominada `GCN_LSTM`, que hereda de `torch.nn.Module`. Esta arquitectura recibe como parámetros principales el número de nodos, el número de características de entrada por nodo, el tamaño oculto de las capas `GCN` y el tamaño oculto de la `LSTM`.

La parte espacial del modelo está formada por dos capas `GCNConv`. La primera transforma las características de entrada de cada nodo hacia una representación oculta, y la segunda vuelve a aplicar una convolución sobre grafos para refinar dicha representación incorporando información de los vecinos. En ambas capas se aplica una activación `ReLU` después de la convolución.

En el método `forward`, el modelo recorre cada instante de la ventana temporal. Para cada paso temporal, extrae las características de todos los nodos y aplica las dos capas `GCN` utilizando `edge_index` y `edge_weight`. Esto significa que, en `GCN-LSTM`, los pesos de las aristas definidos en las matrices de adyacencia sí se incorporan al componente espacial del modelo.

Después de procesar todos los pasos temporales, las salidas de las `GCN` se apilan y reorganizan para que cada nodo tenga una secuencia temporal de representaciones. Esta secuencia se pasa a una `LSTM` configurada con `batch_first=True`. El modelo utiliza la salida del último instante de la `LSTM` y la proyecta mediante una capa lineal `Linear` hacia un único valor por nodo.

Por tanto, la salida de `GCN-LSTM` es una matriz de predicciones con forma `[batch_size, N]`, donde cada valor

corresponde a la congestión futura estimada para un nodo.

6.9.2. GCN-GRU

El modelo `GCN-GRU` se implementó mediante una clase denominada `GCN_GRU`. Su estructura es muy similar a la de `GCN-LSTM`, ya que conserva el mismo bloque espacial basado en dos capas `GCNConv`. Por tanto, también utiliza `edge_index` y `edge_weight` para aplicar la convolución sobre el grafo en cada instante temporal.

La diferencia principal se encuentra en el componente temporal. En lugar de utilizar una `LSTM`, este modelo emplea una capa `GRU`. Una vez que las dos capas `GCN` generan las representaciones espaciales para cada instante de la ventana, estas representaciones se reorganizan como secuencias temporales por nodo y se entregan a la `GRU`.

La `GRU` produce una salida temporal para cada nodo, de la cual se conserva el último instante. Posteriormente, una capa lineal transforma esa representación final en un único valor de congestión predicha por nodo. Igual que en el modelo anterior, la salida final tiene forma `[batch_size, N]`, idéntica a la de `GCN-LSTM`, lo que garantiza su comparabilidad directa.

6.9.3. GAT-LSTM

El modelo `GAT-LSTM` se implementó mediante la clase `GAT_LSTM`. A diferencia de los dos modelos anteriores, esta arquitectura sustituye las capas `GCNConv` por capas `GATConv`, con el objetivo de incorporar un mecanismo de atención en la agregación espacial.

La parte espacial del modelo está formada por dos capas `GATConv`. La primera recibe las características de entrada de cada nodo y genera una representación oculta; la segunda vuelve a aplicar atención sobre el grafo para obtener una representación espacial refinada. En la implementación utilizada, el número de cabezas de atención se define mediante el parámetro `heads`, con valor por defecto igual a `1`, y se configura `concat=False`.

En el método `forward`, el modelo recorre cada instante de la ventana temporal y aplica las dos capas `GAT` a las características de los nodos usando `edge_index`. En esta versión básica, el `GATConv` no utiliza `edge_weight`, por lo que la conectividad del grafo se incorpora mediante las aristas, pero los pesos de las aristas no se pasan directamente al componente de atención.

Después de aplicar el componente espacial en todos los pasos temporales, las representaciones se apilan y reorganizan como secuencias por nodo. Estas secuencias se procesan mediante una `LSTM`, igual que en `GCN-LSTM`.

Finalmente, se toma la salida del último instante temporal y se aplica una capa lineal para obtener la predicción de congestión futura de cada nodo.

La salida de `GAT-LSTM` también tiene forma `[batch_size, N]`. A diferencia de `GCN-LSTM`, la no incorporación de `edge_weight` en la atención implica que la ponderación de vecinos es completamente aprendida, sin utilizar los pesos construidos en la fase de adyacencia.

6.10. REPRODUCIBILIDAD E IMPLEMENTACIÓN

La implementación del proyecto se organizó en un repositorio de GitHub con el objetivo de estructurar el trabajo de forma reproducible. Esta decisión fue necesaria porque la metodología desarrollada no consiste en una única ejecución aislada, sino en un flujo completo compuesto por varias etapas: carga de datos, cálculo de congestión, construcción de nodos, generación de matrices de adyacencia, preparación de datasets, entrenamiento de modelos y almacenamiento de resultados.

El repositorio recoge el flujo completo del proyecto para trabajar con datos de tráfico de Madrid, construcción de grafos y modelos GNN. La organización del repositorio separa las distintas partes del proyecto en carpetas específicas; esta separación permite distinguir entre datos originales, código fuente, pruebas exploratorias y resultados experimentales.

La Tabla 6.10 resume la función de las carpetas y archivos principales del repositorio. Esta estructura permite separar claramente los datos, el código fuente, los scripts de ejecución, las pruebas exploratorias y los resultados generados durante los experimentos.

La Figura 6.19 presenta de forma visual la organización del repositorio. En ella se observa cómo el proyecto se divide en carpetas principales para configuración, datos, notebooks, scripts, código fuente y resultados. Además, se muestra la organización modular interna de `src/traffic_gnn/`, donde se separan las funciones relacionadas con características, clustering, construcción de grafos, modelos, entrenamiento y pipelines.

Elemento	Función dentro del proyecto
`configs/`	Contiene archivos de configuración, como `params.yaml`, para centralizar parámetros del pipeline.
`data/`	Organiza los datos del proyecto en distintos estados de procesamiento: `raw`, `interim`, `processed` y `external`.
`notebooks/`	Conserva los cuadernos usados durante la exploración, validación metodológica y pruebas iniciales.
`scripts/`	Incluye scripts de ejecución para lanzar el pipeline y los experimentos de forma parametrizada.
`src/traffic_gnn/`	Contiene el código fuente principal del proyecto: carga, features, clustering, grafos, modelos, entrenamiento y pipelines.
`results/`	Almacena las salidas del proyecto: adyacencias, clusters, figuras, modelos entrenados, métricas y resultados experimentales.
`requirements.txt`	Lista las dependencias necesarias para instalar el entorno y reproducir la ejecución del proyecto.

Tabla 6.10.: Organización general del repositorio.

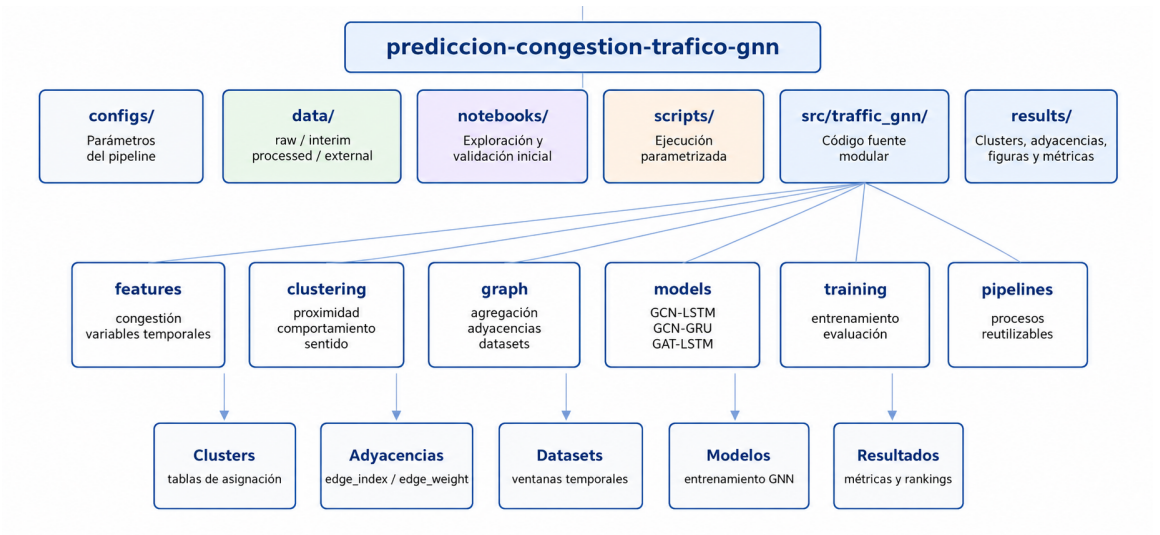

Figura 6.19.: Estructura reproducible del repositorio.

Dentro de `src/traffic_gnn/`, el código se organiza en módulos según la función que cumplen dentro del

pipeline. Esta estructura modular facilita reutilizar funciones y ejecutar diferentes configuraciones sin duplicar código.

Módulo	**Tarea dentro del flujo del proyecto**
`features/`	Calcula la congestión a partir de intensidad y ocupación, y construye variables temporales auxiliares.
`clustering/`	Implementa los criterios de agrupación: proximidad, comportamiento, sentido e intersecciones entre criterios.
`graph/`	Agrega la congestión por cluster, calcula centroides, construye adyacencias y genera datasets para GNN.
`models/`	Contiene las arquitecturas evaluadas: `GCN-LSTM`, `GCN-GRU` y `GAT-LSTM`.
`training/`	Centraliza el entrenamiento, validación, prueba y cálculo de métricas de los modelos.
`pipelines/`	Agrupa procesos completos reutilizables, como construcción de clusters y matrices de adyacencia.

Tabla 6.11.: Módulos internos del código fuente del proyecto.

La Tabla 6.11 resume los módulos internos del código fuente. Esta organización permitió pasar de una fase exploratoria basada en notebooks a una implementación más reproducible, donde las funciones principales quedaron integradas en módulos reutilizables.

La implementación diferencia claramente entre la fase exploratoria y la fase reproducible. Los notebooks permitieron analizar los datos, probar agrupaciones, revisar casos concretos y validar decisiones metodológicas. Posteriormente, las funciones principales se integraron en módulos y scripts del repositorio, de forma que el proceso pudiera repetirse de manera más ordenada sobre diferentes meses, casos de nodos, tipos de adyacencia y modelos.

El flujo reproducible parte de la construcción de clusters. El repositorio contempla la generación de ficheros como `cl_proximidad_50.csv`, `cl_proximidad_500.csv`, `cl_proximidad_comportamiento_50.csv`, `cl_proximidad_comportamiento_500.csv`, `cl_proximidad_sentido_50.csv` y `cl_proximidad_sentido_500.csv`. Estos archivos representan las distintas configuraciones de nodos utilizadas en el proyecto y permiten reutilizar las agrupaciones en etapas posteriores sin recalcularlas manualmente.

La siguiente etapa corresponde a la construcción de adyacencias. Para cada caso y tamaño de agrupación, el pipeline permite generar dos tipos de matriz: una por cercanía espacial y otra por correlación temporal. Esta etapa produce la estructura relacional del grafo y la transforma en los formatos necesarios para los modelos GNN, principalmente `edge_index` y `edge_weight`.

Después, el módulo de preparación GNN construye los elementos necesarios para el entrenamiento: agregación por cluster, tabla temporal por nodo, ventanas temporales, división temporal de los datos y tensores de entrada. Esta etapa permite convertir los datos procesados en una estructura compatible con `PyTorch Geometric` y con las arquitecturas implementadas en el proyecto.

El entrenamiento se automatizó mediante scripts de ejecución. Estos scripts permiten especificar meses de datos, casos de nodos, tamaños de cluster, tipos de adyacencia, modelos, fracciones de datos, número de épocas y tamaño de batch. Esta parametrización fue importante porque permitió ejecutar múltiples combinaciones experimentales de forma controlada y homogénea.

Un ejemplo de ejecución del pipeline completo es el uso del script `run_pipeline_completo.py`, indicando parámetros como `-months`, `-cluster_targets`, `-casos`, `-adyacencias`, `-modelos`, `-fracciones`, `-epochs` y `-batch_size`. De este modo, los experimentos no dependen de una ejecución manual paso a paso, sino de una instrucción reproducible que recorre las configuraciones definidas.

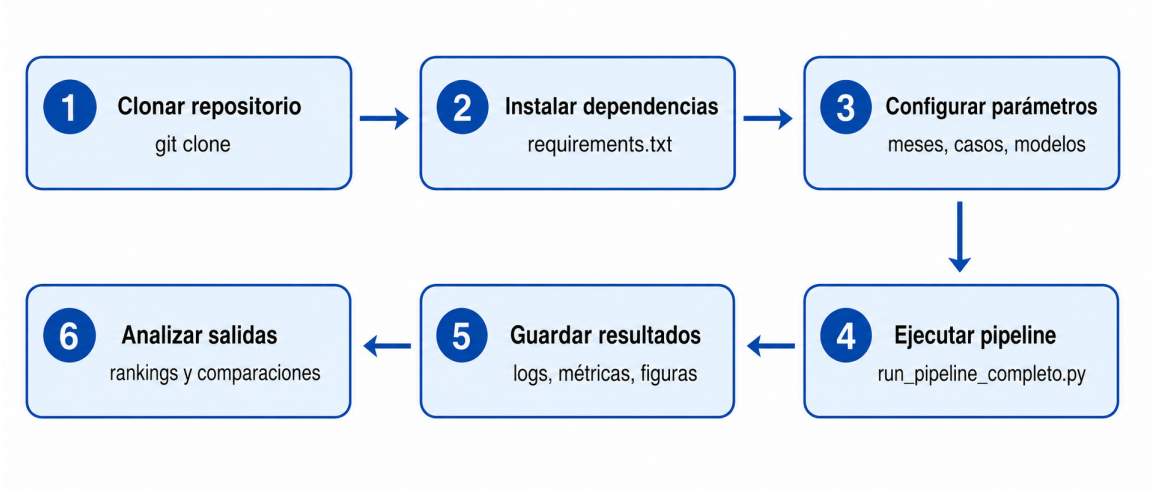

Figura 6.20.: Flujo de ejecución reproducible.

La Figura 6.20 resume el flujo de ejecución reproducible del proyecto. El proceso comienza con la clonación del repositorio y la instalación de dependencias, continúa con la configuración de parámetros y la ejecución del

pipeline, y finaliza con el almacenamiento y análisis de resultados. Esta secuencia permite repetir los experimentos bajo distintas combinaciones de meses, casos, adyacencias y modelos.

También se incorporó control de versiones mediante Git y GitHub. Durante las ejecuciones largas se utilizó una opción de subida automática de resultados, mediante el parámetro `-git_push` y un intervalo configurable. Esta decisión permitió conservar resultados parciales, registrar avances y reducir el riesgo de pérdida de información ante interrupciones del equipo de ejecución.

La reproducibilidad se apoya además en el archivo `requirements.txt`, que recoge las dependencias necesarias para instalar el entorno del proyecto. Junto con la estructura modular del código, este archivo facilita que el repositorio pueda clonarse y ejecutarse en otro entorno, siempre que se disponga de los datos requeridos.

Desde el punto de vista del desarrollo, la implementación produjo distintos tipos de salida: tablas de clusters, matrices de adyacencia, tensores para modelos GNN, logs de entrenamiento, métricas, rankings de modelos, tiempos de ejecución y figuras de resultados. Esta diversidad de salidas permite analizar tanto el rendimiento predictivo como el coste computacional de cada configuración experimental.

7. EVALUACIÓN Y RESULTADOS

Este capítulo presenta la evaluación experimental de la metodología propuesta. A diferencia del capítulo de desarrollo, centrado en explicar la construcción del índice de congestión, los nodos, las aristas, los datasets y los modelos, esta sección analiza el comportamiento de las configuraciones implementadas a partir de los resultados obtenidos en los experimentos.

La evaluación se diseñó con el objetivo de responder tres preguntas principales:

- ¿La forma de construir la matriz de adyacencia influye en la capacidad predictiva de los modelos?
- ¿La definición de los nodos del grafo afecta al rendimiento final?
- ¿La arquitectura neuronal utilizada tiene un efecto determinante o el mayor impacto proviene de la representación grafo-temporal de los datos?

Para ello, se documentan cuatro bloques experimentales. Los tres primeros corresponden a ejecuciones completas del pipeline con diferentes extensiones temporales de datos: un mes, dos meses y una semana de abril. El cuarto corresponde a una variante experimental orientada al análisis mediante MAPE, basada en una transformación inversa de la variable objetivo. Estos experimentos permiten analizar tanto el rendimiento predictivo como la estabilidad de las conclusiones bajo distintos escenarios de datos.

7.1. DISEÑO EXPERIMENTAL

El diseño experimental se estructuró a partir de la combinación de cuatro dimensiones principales: definición de nodos, tipo de adyacencia, arquitectura del modelo y periodo temporal utilizado para el entrenamiento y evaluación.

- En la dimensión de **nodos** se consideraron cinco casos:
  - sensores tal cual,
  - proximidad,
  - proximidad + comportamiento,

  - proximidad + sentido V1,
  - proximidad + sentido V2.

  El caso de sensores tal cual conserva los puntos de medida originales, mientras que los demás casos utilizan agrupaciones de sensores. Para los casos agregados se generaron dos niveles de granularidad, cercanos a 50 y 500 clusters, con el fin de comparar representaciones compactas y representaciones de mayor detalle espacial.

- En la dimensión de **adyacencia** se evaluaron dos estrategias definidas en la Sección 4.3: adyacencia por **cercanía espacial** y adyacencia por **correlación temporal**.
- En la dimensión de **modelado** se evaluaron tres arquitecturas híbridas: `GCN-LSTM`, `GCN-GRU` y `GAT-LSTM`. Estas arquitecturas fueron seleccionadas para comparar el efecto del componente temporal y del componente espacial. La Tabla 6.9 resume el propósito comparativo de cada arquitectura.

Los experimentos principales se ejecutaron con todas las combinaciones de casos, tamaños de agrupación, tipos de adyacencia y modelos. En las configuraciones agregadas se evaluaron los tamaños 50 y 500, mientras que el caso de sensores tal cual se mantuvo en su granularidad original. Esta combinación produjo un conjunto amplio de ejecuciones que permitió construir rankings de modelos y comparar resultados desde diferentes perspectivas.

La ejecución de los experimentos se realizó mediante un script parametrizado, lo que permitió controlar desde consola el periodo de datos, los casos de nodos, los tamaños de cluster, los tipos de adyacencia, los modelos evaluados y los parámetros de entrenamiento. A continuación se muestra un ejemplo del comando utilizado para lanzar el experimento principal con un mes de datos:

```
python scripts/run_pipeline_completo.py \
  --months 01-2025 \
  --cluster_targets 50 500 \
  --casos sensores_tal_cual proximidad proximidad_comportamiento proximidad_sentido_v1
      proximidad_sentido_v2 \
  --adyacencias cercania correlacion \
  --modelos GCN_LSTM GCN_GRU GAT_LSTM \
  --fracciones 1 \
  --epochs 25 \
  --batch_size 32 \
```

```
--git_push \
--git_push_interval_minutes 30
```

Código 7.1: Ejemplo de ejecución del pipeline completo.

Este comando ejecuta el pipeline completo sobre el mes de enero de 2025, evaluando los cinco casos de nodos, los dos tamaños de agrupación definidos para los casos agregados, las dos estrategias de adyacencia y las tres arquitecturas GNN. Además, incorpora la opción de subida automática a GitHub cada 30 minutos, lo que permitió conservar resultados parciales y logs durante ejecuciones prolongadas.

Además del experimento base con un mes completo de datos, se realizaron ejecuciones adicionales para analizar la estabilidad de los resultados bajo diferentes escenarios temporales y metodológicos. En concreto, se documentan cuatro bloques experimentales: un mes de datos, dos meses de datos, una semana de abril y una variante basada en la transformación inversa de la variable objetivo para el análisis mediante MAPE. La Tabla 7.1 resume estos bloques y la finalidad de cada uno dentro de la evaluación.

Bloque	**Experimento**	**Carpeta**	**Descripción**	**Finalidad**
E1	Un mes de datos	`run_20260504_171233`	Pipeline completo con todas las configuraciones usando un mes de datos.	Establecer el experimento base de comparación.
E2	Dos meses de datos	`run_20260508_145954`	Pipeline completo ampliando el histórico temporal a dos meses.	Analizar si una mayor cantidad de datos mejora el rendimiento.
E3	Una semana de abril	`run_20260518_131858`	Pipeline completo con una semana de datos de abril.	Evaluar el comportamiento con una ventana temporal corta y revisar la calidad visual de las predicciones.
E4	Variable inversa / MAPE	`run_20260514_153421`	Variante experimental orientada al análisis mediante MAPE en la rama de descongestión/inversa.	Analizar una formulación alternativa de la variable objetivo y su evaluación porcentual.

Tabla 7.1.: Bloques experimentales documentados.

7.2. MÉTRICAS DE EVALUACIÓN

La evaluación de los modelos se realizó mediante métricas de error calculadas sobre el conjunto de prueba. Dado que el objetivo del proyecto es predecir un índice continuo de congestión, las métricas principales utilizadas en los tres primeros bloques experimentales fueron el error absoluto medio, el error cuadrático medio en raíz y la pérdida de prueba. Estas métricas permiten analizar el rendimiento desde perspectivas complementarias: magnitud media del error, penalización de errores grandes y coherencia con la función de pérdida utilizada

durante el entrenamiento.

La métrica principal para interpretar el rendimiento fue el **MAE** (*Mean Absolute Error*). Esta métrica calcula el promedio de las diferencias absolutas entre los valores reales y los valores predichos. En el contexto de este trabajo, resulta especialmente útil porque la congestión está normalizada en el intervalo $[0, 1]$, por lo que el MAE puede interpretarse directamente como un error medio en la escala del índice de congestión.

$$MAE = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i|$$

donde y_i representa el valor real de congestión, $\hat{y}_i$ el valor predicho y n el número total de observaciones evaluadas.

También se utilizó el **RMSE** (*Root Mean Squared Error*), que corresponde a la raíz cuadrada del promedio de los errores al cuadrado. A diferencia del MAE, esta métrica penaliza con mayor fuerza los errores grandes, por lo que permite identificar configuraciones que pueden presentar desviaciones importantes en determinados nodos o instantes temporales.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2}$$

El RMSE se reportó junto con el MAE porque ambas métricas aportan información complementaria. Si una configuración obtiene un MAE bajo, pero un RMSE relativamente alto, esto puede indicar que el modelo predice bien en promedio, pero comete errores grandes en algunos casos. En cambio, valores bajos en ambas métricas sugieren un comportamiento más estable.

Además de MAE y RMSE, se registró el `test_loss`. Esta métrica corresponde al valor de la función de pérdida calculado sobre el conjunto de prueba. Su función principal fue mantener trazabilidad con el proceso de entrenamiento y validación, permitiendo comparar el comportamiento del modelo entre entrenamiento, validación y prueba. No obstante, para la interpretación final de resultados se priorizaron MAE y RMSE, por ser métricas más directamente interpretables en la escala de la variable de congestión.

En el cuarto bloque experimental se incorporó el **MAPE** (*Mean Absolute Percentage Error*) como métrica principal de análisis. Esta métrica expresa el error absoluto medio en términos porcentuales respecto al valor real. Su uso se reservó para el experimento basado en la transformación inversa de la variable objetivo, ya que en varia-

bles normalizadas o con valores cercanos a cero el MAPE puede volverse inestable y producir interpretaciones poco robustas.

$$MAPE = \frac{100}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Debido a esta sensibilidad, el MAPE no se utilizó como métrica principal en los tres primeros bloques experimentales. En dichos bloques, el análisis se centró en MAE, RMSE y `test_loss`. El MAPE se documenta como parte de un análisis complementario orientado a explorar una formulación alternativa de la variable objetivo y una lectura porcentual del error.

La Tabla 7.2 resume las métricas empleadas y su papel dentro de la evaluación.

Métrica	**Nombre completo**	**Bloques donde se utiliza**	**Interpretación en el proyecto**
MAE	Mean Absolute Error	E1, E2, E3	Error absoluto medio entre congestión real y predicha. Es la métrica principal para interpretar la magnitud media del error.
RMSE	Root Mean Squared Error	E1, E2, E3	Penaliza errores grandes y permite analizar la estabilidad de las predicciones.
`test_loss`	Pérdida en prueba	E1, E2, E3	Valor de la función de pérdida sobre el conjunto de prueba. Se usa como referencia del proceso de entrenamiento.
MAPE	Mean Absolute Percentage Error	E4	Error porcentual medio. Se utiliza únicamente en el experimento con transformación inversa por su sensibilidad a valores cercanos a cero.

Tabla 7.2.: Métricas utilizadas en la evaluación experimental.

7.3. RESULTADOS GLOBALES

A partir del diseño de evaluación descrito en la Sección 7.1, los resultados se organizaron mediante tablas de ranking generadas para cada ejecución final. Estas tablas registran, para cada configuración evaluada, todas las combinaciones entre el caso de nodos, el tipo de adyacencia, el modelo utilizado, las métricas de prueba y

el tiempo de ejecución. Su objetivo es permitir una comparación directa entre las alternativas metodológicas desarrolladas en el proyecto.

En esta sección se presentan los rankings globales de cada evaluación, en el anexo A se pueden encontrar los resultados de todos los experimentos ejecutados. Posteriormente, en las Secciones 7.4, 7.5 y 7.6, se profundiza en el análisis por tipo de adyacencia, definición de nodo y arquitectura. De esta forma, primero se documenta el conjunto completo de resultados y después se interpretan los patrones más relevantes.

7.3.1. Experimento E1: evaluación con un mes de datos

El primer experimento corresponde a la evaluación con un mes completo de datos. En esta ejecución se evaluaron 54 configuraciones, resultado de combinar los casos de nodos, los tamaños de agrupación 50 y 500 para los casos agregados, los dos tipos de adyacencia y los tres modelos GNN.

Cada fila del ranking representa una configuración completa de evaluación. Por tanto, la tabla no solo permite identificar la mejor configuración, sino también observar el comportamiento relativo de todas las alternativas consideradas.

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_500	correlacion	GCN_LSTM	0,0236	0,0539	20,21
proximidad_500	correlacion	GCN_GRU	0,0243	0,0534	20,06
sensores_tal_cual	correlacion	GCN_GRU	0,0248	0,0643	104,95
sensores_tal_cual	correlacion	GCN_LSTM	0,0250	0,0644	110,17
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0250	0,0569	31,45
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0252	0,0560	32,15
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0256	0,0577	24,23
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0262	0,0545	24,19
proximidad_sentido_v2_50	correlacion	GCN_LSTM	0,0272	0,0602	8,81
proximidad_sentido_v2_50	correlacion	GCN_GRU	0,0282	0,0606	8,86

Tabla 7.3.: Ranking de las diez mejores configuraciones del experimento E1.

El ranking de E1 permite identificar las primeras tendencias generales. Las configuraciones basadas en `proximidad_500` y adyacencia por correlacion aparecen entre las mejor posicionadas. Este resultado sugiere que una representación con mayor granularidad que 50 clusters, pero más compacta que los sensores originales, ofrece un equilibrio adecuado entre detalle espacial y capacidad predictiva. Destaca también la presencia

recurrente de la adyacencia por correlación entre los primeros puestos. Este patrón se analiza en detalle en la Sección 7.4.

7.3.2. Experimento E2: evaluación con dos meses de datos sobre configuraciones seleccionadas

El segundo experimento se realizó con dos meses de datos. A diferencia de E1, en este caso no se ejecutaron las 54 configuraciones completas. Debido al elevado tiempo de ejecución observado al trabajar con todas las combinaciones, se decidió evaluar únicamente 10 configuraciones seleccionadas a partir de los mejores resultados obtenidos en E1.

Esta decisión permitió comprobar si el aumento del histórico temporal mejoraba el rendimiento de las configuraciones más prometedoras, sin repetir todo el conjunto de ejecuciones. Por tanto, E2 debe interpretarse como una evaluación dirigida sobre los mejores casos identificados previamente, no como una repetición exhaustiva del experimento completo.

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_500	correlacion	GCN_LSTM	0,0214	0,0473	88,09
proximidad_500	correlacion	GCN_GRU	0,0220	0,0487	87,71
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0245	0,0527	115,97
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0247	0,0531	113,77
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0248	0,0567	205,15
sensores_tal_cual	correlacion	GCN_LSTM	0,0251	0,0633	565,26
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0252	0,0583	202,73
sensores_tal_cual	correlacion	GCN_GRU	0,0264	0,0646	505,25
proximidad_comportamiento_500	correlacion	GCN_LSTM	0,0373	0,0784	98,18
proximidad_comportamiento_500	correlacion	GCN_GRU	0,0379	0,0807	97,63

Tabla 7.4.: Ranking de configuraciones del experimento E2.

Los resultados de E2 muestran que ampliar el periodo de entrenamiento permitió mejorar las métricas en las mejores configuraciones. Los patrones de adyacencia y granularidad se mantienen coherentes con E1 y se analizan de forma conjunta en las secciones 7.4 y 7.5.

7.3.3. Experimento E3: evaluación con una semana de abril

El tercer experimento corresponde a la evaluación con una semana de datos de abril. En este caso se ejecutaron nuevamente 54 configuraciones, manteniendo la combinación completa de casos, tamaños de agrupación, tipos de adyacencia y modelos.

Esta evaluación permitió analizar el comportamiento del flujo de ejecución sobre una ventana temporal más corta. Aunque el periodo utilizado es menor, el experimento resulta útil para observar si las tendencias detectadas con un mes de datos se mantienen en otro escenario temporal.

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_500	correlacion	GCN_LSTM	0,0221	0,0500	41,99
proximidad_500	correlacion	GCN_GRU	0,0236	0,0507	41,66
sensores_tal_cual	correlacion	GCN_LSTM	0,0251	0,0638	274,34
sensores_tal_cual	correlacion	GCN_GRU	0,0253	0,0636	240,09
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0254	0,0571	96,13
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0263	0,0532	54,72
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0267	0,0535	53,63
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0267	0,0577	96,95
proximidad_500	correlacion	GAT_LSTM	0,0278	0,0614	60,09
sensores_tal_cual	correlacion	GAT_LSTM	0,0293	0,0707	343,37

Tabla 7.5.: Ranking de las diez mejores configuraciones del experimento E3.

Los resultados de E3 son coherentes con los de E1: los patrones de adyacencia y granularidad se mantienen estables en este escenario temporal diferente (véase las secciones 7.4 y 7.5). Además, al trabajar con una ventana de una semana, las gráficas de predicción frente a valor real resultan más interpretables visualmente, por lo que E3 se utiliza en la Sección 7.7 para el análisis cualitativo de predicciones.

7.3.4. Experimento E4: evaluación con transformación inversa y MAPE

El cuarto experimento se diseñó para analizar una variante de evaluación basada en MAPE. Durante el análisis de métricas se identificó una dificultad conceptual al aplicar MAPE directamente sobre la variable de congestión. Esta métrica divide el error absoluto entre el valor real, por lo que puede volverse inestable cuando el valor real es cercano a cero. En el caso de la congestión, esto es especialmente relevante porque muchos registros

pueden corresponder a situaciones de baja congestión.

Para explorar esta limitación, se planteó una transformación inversa de la variable objetivo. En lugar de evaluar directamente la congestión C, se construyó una nueva variable de descongestión definida como:

$$D = 1 - C$$

donde D representa el nivel de descongestión. Esta transformación cambia la interpretación de la variable: valores altos indican baja congestión y valores bajos indican alta congestión. La motivación fue adaptar la escala de la variable a la lógica del MAPE y reducir el problema de dividir por valores reales cercanos a cero en situaciones habituales de tráfico fluido o poco congestionado.

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	MAPE prueba	Tiempo (min)
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0290	0,0617	3,85	23,10
proximidad_500	correlacion	GCN_LSTM	0,0302	0,0589	3,92	18,28
proximidad_500	correlacion	GCN_GRU	0,0297	0,0604	3,94	19,45
proximidad_500	correlacion	GAT_LSTM	0,0300	0,0650	4,04	26,44
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0340	0,0615	4,42	22,99
proximidad_sentido_v1_500	correlacion	GAT_LSTM	0,0317	0,0683	4,43	40,79
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0315	0,0713	4,50	31,89
proximidad_sentido_v2_500	correlacion	GAT_LSTM	0,0334	0,0697	4,63	32,18
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0337	0,0704	4,68	30,80
sensores_tal_cual	correlacion	GCN_LSTM	0,0328	0,0715	4,79	119,65

Tabla 7.6.: Ranking de las diez mejores configuraciones del experimento E4.

El ranking de este experimento mantiene un patrón coherente con los resultados anteriores: las mejores configuraciones se concentran en adyacencias por correlación y representaciones cercanas a 500 clusters. Por el contrario, las configuraciones basadas en cercanía, presentaron los valores más altos de MAPE.

Estos resultados refuerzan dos conclusiones:

- La adyacencia por correlación vuelve a mostrarse más competitiva que la cercanía espacial, incluso bajo una formulación alternativa de la variable objetivo.

- Las representaciones de mayor granularidad, cercanas a 500 clusters, mantienen un comportamiento más estable que las configuraciones más agregadas de 50 clusters.

7.3.5. Lectura global de los resultados

A partir de los cuatro experimentos, resultan tres patrones que se repiten con independencia del escenario de evaluación:

- la ventaja de la adyacencia por correlación sobre la cercanía espacial,
- la mayor efectividad de las representaciones cercanas a 500 clusters frente a las de 50,
- y la menor influencia de la arquitectura en comparación con las decisiones de representación del grafo.

Cada uno de estos patrones se analiza con datos y visualizaciones propias en las secciones siguientes: la Sección 7.4 para la adyacencia, la Sección 7.5 para la definición de nodo y la Sección 7.6 para la arquitectura.

7.4. ANÁLISIS POR TIPO DE ADYACENCIA

El análisis por tipo de adyacencia (adyacencia por cercanía espacial y adyacencia por correlación temporal) permite evaluar una de las decisiones metodológicas más importantes del proyecto: cómo se definen las relaciones entre los nodos del grafo. Esta comparación es clave porque el objetivo del trabajo no es únicamente determinar qué arquitectura neuronal obtiene mejores resultados, sino analizar si la forma de construir el grafo influye en la capacidad predictiva del modelo.

Para analizar esta dimensión se utilizaron tanto los rankings de resultados como las gráficas comparativas generadas en las ejecuciones finales. En el cuerpo principal de la memoria se incluye la gráfica correspondiente al experimento E1, ya que esta evaluación contiene las 54 configuraciones completas con un mes de datos y permite analizar de forma transversal el efecto del tipo de adyacencia. Las gráficas equivalentes de los demás experimentos presentan una lectura similar y se incluyen en el anexo B.

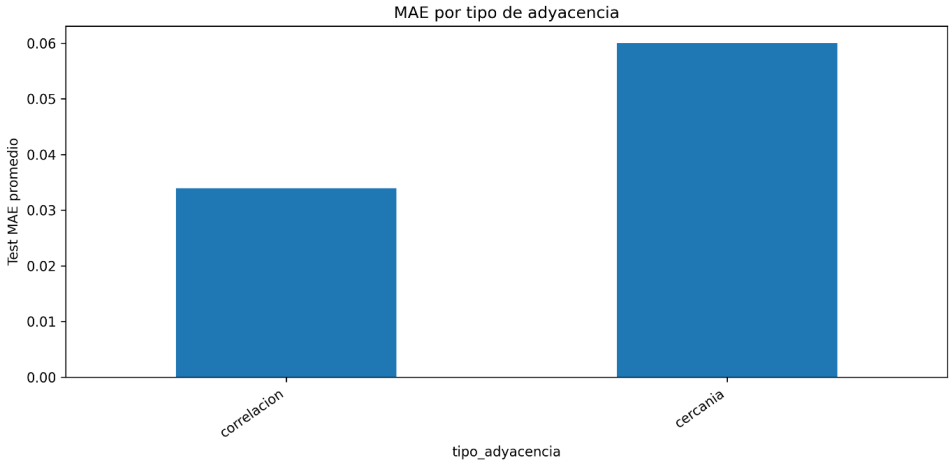

Figura 7.1.: MAE por tipo de adyacencia en el experimento E1.

La Figura 7.1 muestra que **las configuraciones construidas con adyacencia por correlación presentan un comportamiento más competitivo que aquellas basadas en cercanía espacial**:

- La adyacencia por correlación obtuvo un MAE promedio aproximado de **0,034**, mientras que la adyacencia por cercanía obtuvo un MAE promedio aproximado de **0,060**.
- Dado que el índice de congestión está normalizado entre 0 y 1, estos valores indican que el grafo construido por correlación produce predicciones con menor error medio que el grafo construido únicamente por distancia espacial.

Los rankings de resultados refuerzan esta lectura. Las configuraciones con adyacencia por correlación aparecen de forma recurrente entre las primeras posiciones, especialmente cuando se combinan con representaciones de aproximadamente 500 clusters. Esto sugiere que la mejora no depende exclusivamente del modelo utilizado, sino de la calidad de la representación grafo-temporal que se entrega al modelo.

> La comparación entre adyacencias muestra que el enfoque basado en correlación supera de forma general al enfoque basado en distancia. Esto posiciona la correlación temporal como uno de los elementos más innovadores del proyecto, ya que permite construir grafos urbanos menos dependientes de una topología física fija y más alineados con el comportamiento real observado en los datos.

7.5. ANÁLISIS POR DEFINICIÓN DE NODO

Después del tipo de adyacencia, la definición de los nodos es el segundo factor más relevante en los resultados. Esta dimensión permite evaluar si conviene trabajar con los sensores originales o con agrupaciones de sensores construidas a partir de criterios espaciales y funcionales.

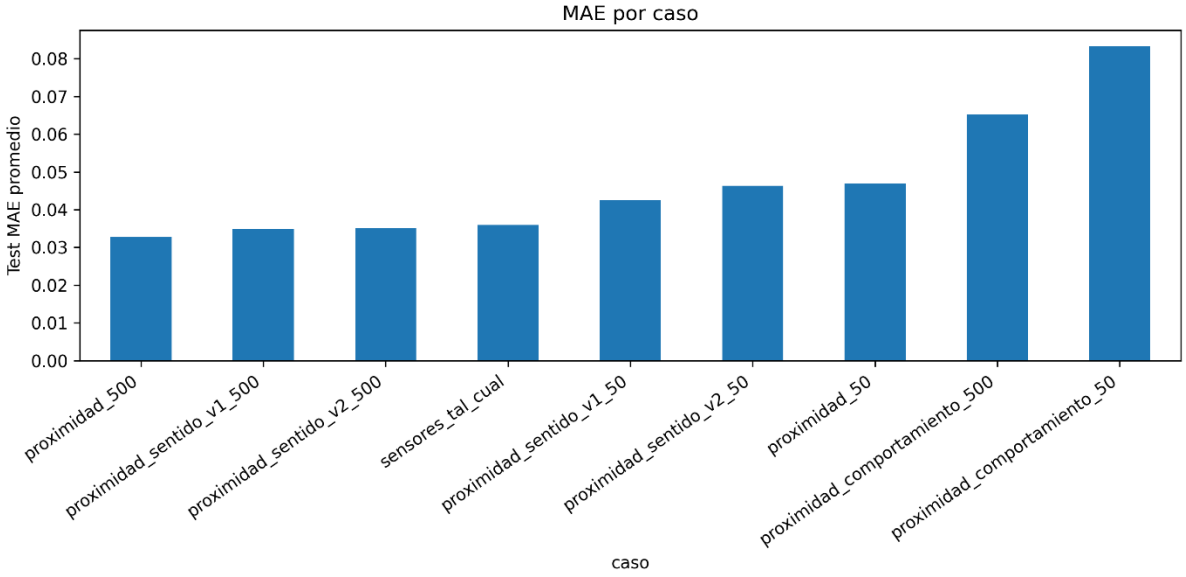

Figura 7.2.: MAE por definición de nodo en el experimento E1.

La Figura 7.2 muestra que las configuraciones con aproximadamente 500 clusters obtienen mejores resultados que sus versiones de 50 clusters. El caso más destacado es `proximidad_500`, con un MAE promedio aproximado de **0,033**. En cambio, `proximidad_50` obtuvo un MAE promedio aproximado de **0,047**.

Esta diferencia indica que una agrupación demasiado compacta puede perder información relevante. Al reducir el grafo a 50 clusters, se simplifica el problema, pero también se mezclan zonas que pueden tener dinámicas distintas de congestión. En cambio, la representación con 500 clusters conserva más detalle espacial y permite al modelo distinguir mejor entre zonas urbanas.

El caso `sensores_tal_cual` también obtuvo un resultado competitivo, con un MAE promedio aproximado de **0,036**. Sin embargo, este caso trabaja con muchos más nodos, por lo que tiene mayor coste computacional. Frente a esto, `proximidad_500` obtiene un error ligeramente menor y, al mismo tiempo, reduce el tamaño del

grafo.

Los casos con sentido de circulación también muestran un comportamiento favorable en su versión de 500 clusters. Tanto `proximidad_sentido_v1_500` como `proximidad_sentido_v2_500` obtuvieron MAE promedio cercanos a **0,035**. Esto indica que incorporar información de sentido puede ser útil, siempre que no se pierda demasiada granularidad.

En cambio, las configuraciones `proximidad_comportamiento` no fueron las más competitivas cuando el comportamiento se utilizó como criterio para agrupar sensores. `proximidad_comportamiento_500` obtuvo un MAE promedio aproximado de **0,065** y `proximidad_comportamiento_50` aproximadamente **0,083**. **Esto no significa que el comportamiento temporal no sea útil**; de hecho, en la Sección 7.4 se observa que **sí aporta valor cuando se usa para construir las aristas por correlación**.

> La conclusión principal es que la granularidad del nodo importa. Las configuraciones de 500 clusters mantienen un mejor equilibrio entre simplificación y conservación de información. En particular, `proximidad_500` aparece como una de las representaciones más sólidas, especialmente cuando se combina con adyacencia por correlación.

Las gráficas equivalentes de MAE por caso para los demás experimentos se incluyen en el anexo B.

7.6. ANÁLISIS POR ARQUITECTURA

El análisis por arquitectura permite comparar el comportamiento de los tres modelos evaluados: GCN-LSTM, GCN-GRU y GAT-LSTM. A diferencia de las secciones anteriores, donde se analizó la construcción del grafo, en esta parte se observa el efecto del modelo utilizado una vez que los datos ya han sido representados como una estructura grafo-temporal.

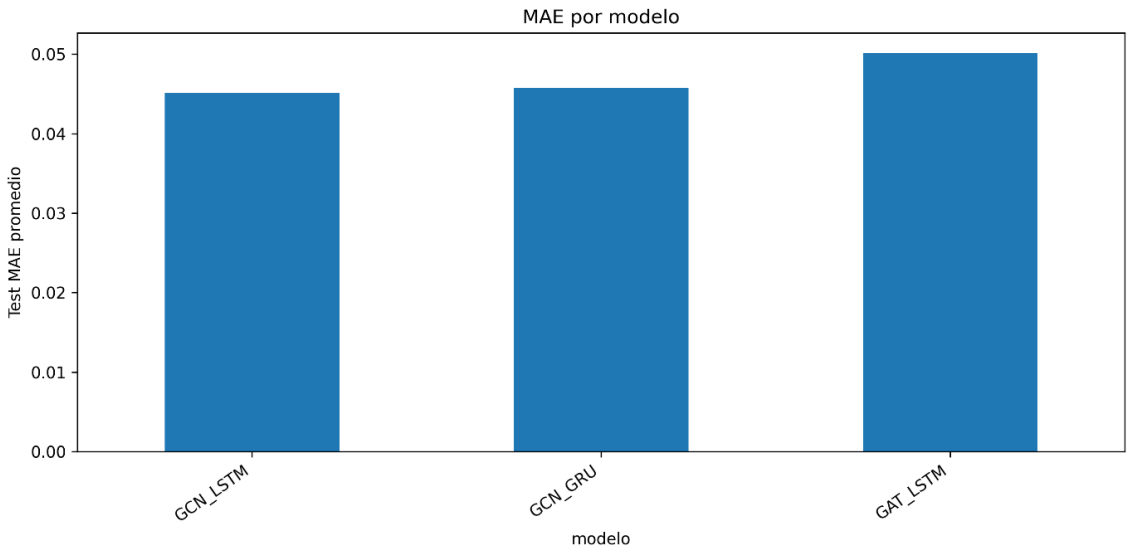

Figura 7.3.: MAE por modelo en el experimento E1.

La Figura 7.3 muestra que los tres modelos obtienen valores de MAE relativamente cercanos. En el experimento E1, el modelo `GCN-LSTM` obtuvo un MAE promedio aproximado de **0,045**, `GCN-GRU` obtuvo un MAE promedio aproximado de **0,046** y `GAT-LSTM` obtuvo un MAE promedio aproximado de **0,050**.

Estos valores indican que `GCN-LSTM` y `GCN-GRU` presentan un comportamiento muy similar. La diferencia entre ambos es pequeña, por lo que no puede afirmarse que el cambio de `LSTM` a `GRU` produzca una mejora clara en promedio. En cambio, `GAT-LSTM` presenta un error ligeramente mayor en esta evaluación, aunque sigue estando en un rango cercano al de los otros dos modelos.

Esta comparación permite extraer una conclusión importante: la arquitectura influye en los resultados, pero no parece ser el factor más determinante:

> La diferencia entre el MAE promedio de `GCN-LSTM` y `GAT-LSTM` es de aproximadamente **0,005**, mientras que la diferencia observada entre adyacencia por correlación y adyacencia por cercanía fue mucho mayor. Por tanto, **el tipo de adyacencia tiene un impacto más claro que la elección entre estas tres arquitecturas**.

El análisis también muestra que los modelos basados en GCN fueron más competitivos que GAT-LSTM en el promedio global de E1. Esto puede deberse a que, en las configuraciones evaluadas, la estructura del grafo construida previamente ya aporta una relación informativa entre nodos. En ese contexto, una agregación mediante

GCN puede ser suficiente para capturar la información espacial relevante, sin que el mecanismo de atención de GAT produzca una mejora sistemática.

En conjunto, el análisis por arquitectura confirma que GCN-LSTM y GCN-GRU fueron los modelos más competitivos en el promedio global de E1, con una ligera ventaja para GCN-LSTM. Sin embargo, la diferencia entre arquitecturas es menor que la observada al cambiar la forma de construir el grafo.

Las gráficas equivalentes de MAE por modelo para los demás experimentos se incluyen en el anexo B.

7.7. ANÁLISIS GRÁFICO DE PREDICCIONES

Además del análisis cuantitativo mediante MAE, se realizó una revisión gráfica de las predicciones frente a los valores reales de congestión. El objetivo de esta subsección es complementar la interpretación de las métricas, observando si los modelos son capaces de seguir la evolución temporal de la congestión en nodos concretos.

Para este análisis se seleccionaron gráficas del experimento E3, correspondiente a una semana de abril (Las gráficas de los demás experimentos se pueden ver en el anexo C). Se incluyen dos figuras representativas de la configuración `proximidad_500` con adyacencia por correlación y modelo `GCN_LSTM`. Esta configuración fue seleccionada porque aparece entre las alternativas más competitivas en los rankings y porque permite ilustrar el comportamiento de la metodología propuesta en una representación de 500 clusters conectada por similitud temporal.

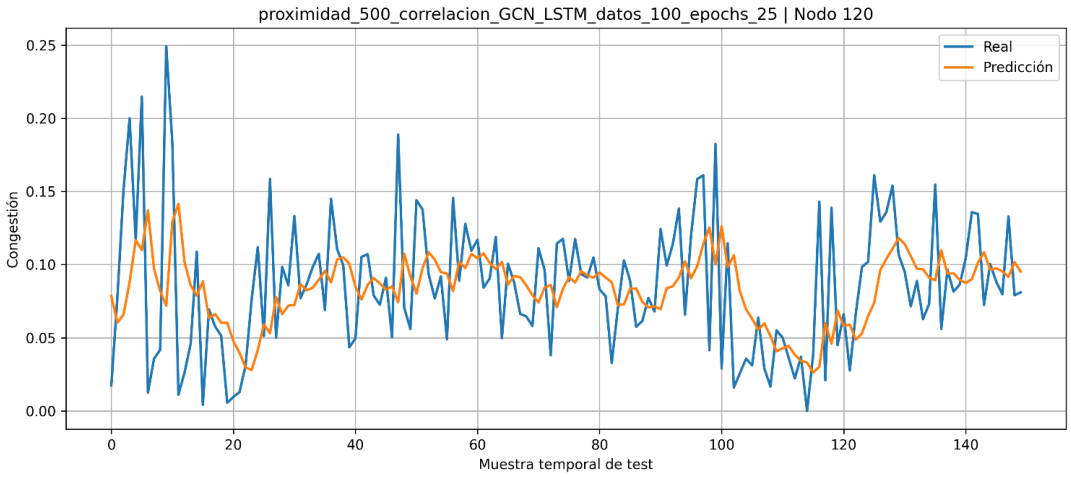

Figura 7.4.: Predicción v.s valor real nodo 120.

La Figura 7.4 muestra que la predicción sigue la tendencia general de la congestión real. Aunque la curva predicha es más suave que la curva real, reproduce varios cambios de nivel y mantiene una trayectoria coherente con la evolución observada. Este comportamiento indica que el modelo captura la dinámica temporal principal, aunque no reproduce con exactitud todas las variaciones locales.

Esta suavización es esperable en un problema de predicción temporal. La congestión real puede presentar cambios bruscos en algunos instantes, mientras que el modelo tiende a producir una estimación más estable. Por tanto, la figura no debe interpretarse únicamente como una coincidencia punto a punto, sino como evidencia de que la predicción conserva la forma general de la serie.

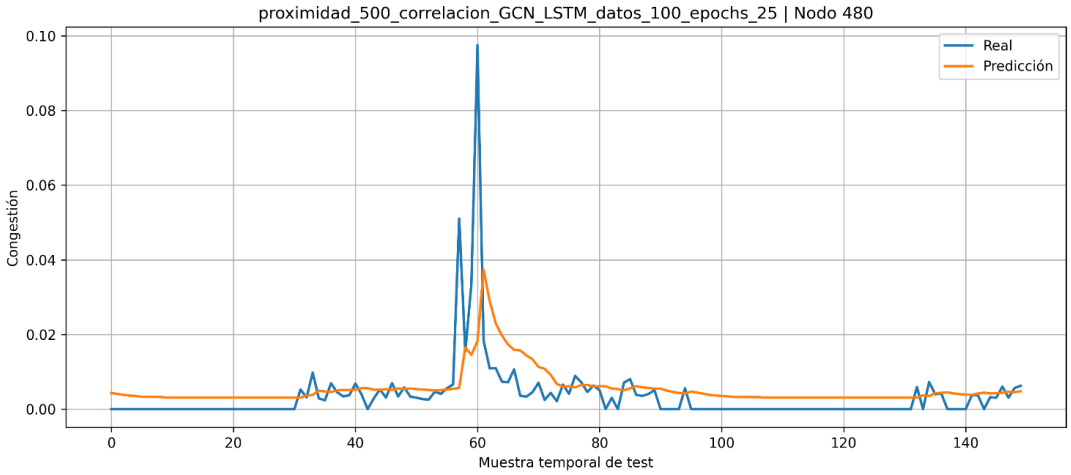

Figura 7.5.: Predicción v.s valor real nodo 480.

La Figura 7.5 permite observar una situación diferente. En este nodo, la serie real presenta un pico de congestión muy marcado alrededor de la muestra temporal 60. La predicción también aumenta en ese intervalo, lo que indica que el modelo detecta el cambio de comportamiento, pero el valor predicho es menor que el valor real. Esto muestra una limitación importante: *el modelo puede seguir la tendencia del evento, pero tiende a subestimar picos abruptos.*

Este resultado es útil para interpretar el alcance de la metodología. Las métricas globales muestran que determinadas configuraciones alcanzan errores bajos en promedio, pero las gráficas permiten ver que los errores no se distribuyen de forma uniforme. Los mayores desajustes aparecen principalmente en cambios rápidos o picos locales de congestión, mientras que en tramos más estables la predicción sigue mejor la evolución real.

En conjunto, las Figuras 7.4 y 7.5 muestran dos comportamientos complementarios. En el primer caso, el mo-

delo sigue la evolución general de una serie con variabilidad moderada. En el segundo, el modelo identifica un evento de congestión, pero lo predice de forma suavizada. Esta lectura confirma que la metodología es capaz de capturar patrones temporales generales, aunque todavía presenta margen de mejora para anticipar eventos puntuales de mayor intensidad.

En síntesis, el análisis gráfico refuerza la interpretación de los resultados numéricos: *las configuraciones basadas en correlación temporal y granularidad cercana a 500 clusters producen predicciones coherentes con la dinámica general de la congestión. No obstante, las curvas también muestran que los modelos tienden a suavizar la señal y a subestimar algunos picos, lo que constituye una línea de mejora para trabajos futuros.*

7.8. COSTE COMPUTACIONAL Y ESCALABILIDAD

Además del rendimiento predictivo, se analizó el coste computacional de las configuraciones evaluadas. Este análisis es importante porque la metodología propuesta no solo busca mejorar la predicción de congestión, sino también construir representaciones más manejables del sistema urbano. En este contexto, reducir el número de nodos del grafo puede disminuir el tiempo de entrenamiento y facilitar la escalabilidad del enfoque.

Para este análisis se utilizó el ranking del experimento E1, que contiene las 54 configuraciones completas evaluadas con un mes de datos. En esta tabla se registró el tiempo de ejecución de cada configuración en minutos y horas, lo que permite comparar el coste asociado a cada caso de nodos, tipo de adyacencia y arquitectura.

En conjunto, la ejecución completa de las 54 configuraciones de E1 tuvo una duración aproximada de **1.630 minutos**, equivalente a unas **27,2 horas**. Este valor refleja el coste total de evaluar todas las combinaciones consideradas en el experimento base.

El caso con mayor coste computacional fue `sensores_tal_cual`, ya que conserva todos los puntos de medida originales como nodos del grafo. En promedio, sus configuraciones tardaron aproximadamente **118,5 minutos** por ejecución. En cambio, el caso `proximidad_500` tuvo un tiempo promedio de aproximadamente **23,2 minutos** por ejecución. Esto muestra que agrupar sensores en 500 clusters reduce de forma considerable el tiempo de entrenamiento frente a trabajar con todos los sensores originales.

> Estas ventajas en tiempo de ejecución, sumadas al buen rendimiento predictivo documentado en la Sección 7.5, consolidan la representación de 500 clusters como la más equilibrada del conjunto evaluado.

La Tabla 7.7 resume el tiempo promedio por caso de nodos en el experimento E1.

Caso de nodos	Nº configuraciones	Tiempo promedio (min)	MAE promedio
sensores_tal_cual	6	118,53	0,036
proximidad_500	6	23,18	0,033
proximidad_sentido_v1_500	6	35,28	0,035
proximidad_sentido_v2_500	6	27,64	0,035
proximidad_comportamiento_500	6	24,70	0,065
proximidad_50	6	9,25	0,047
proximidad_sentido_v1_50	6	12,63	0,042
proximidad_sentido_v2_50	6	10,58	0,046
proximidad_comportamiento_50	6	9,86	0,083

Tabla 7.7.: Tiempo promedio de ejecución por caso de nodos en E1.

La tabla muestra que las configuraciones con 50 clusters son las más rápidas, con tiempos promedio cercanos a 9–13 minutos. Sin embargo, estas configuraciones no siempre obtienen los mejores resultados de predicción. Por ejemplo, `proximidad_50` tarda menos que `proximidad_500`, pero su MAE promedio es mayor. Esto indica que una reducción excesiva del número de nodos puede disminuir el coste computacional, pero también puede perder información relevante para el modelo.

Por el contrario, las configuraciones de 500 clusters ofrecen un equilibrio más favorable. Reducen de forma importante el tiempo frente a `sensores_tal_cual`, pero conservan suficiente detalle espacial para mantener un buen rendimiento. En particular, `proximidad_500` se posiciona como una de las configuraciones más sólidas porque combina bajo error y menor coste computacional.

También se observó que la arquitectura influye en el tiempo de ejecución. En el experimento E1, `GAT-LSTM` fue el modelo con mayor tiempo promedio, con aproximadamente **37,3 minutos** por configuración. `GCN-LSTM` y `GCN-GRU` tuvieron tiempos promedio similares, cercanos a **26–27 minutos**. Esta diferencia es coherente con el mayor coste del mecanismo de atención utilizado en GAT.

Desde el punto de vista de la escalabilidad, estos resultados refuerzan la utilidad de construir representaciones agregadas del sistema urbano. Trabajar directamente con todos los sensores puede ser viable en algunos escenarios, pero implica un coste elevado. En cambio, agrupar sensores en una cantidad intermedia de nodos permite reducir la complejidad sin sacrificar el rendimiento predictivo.

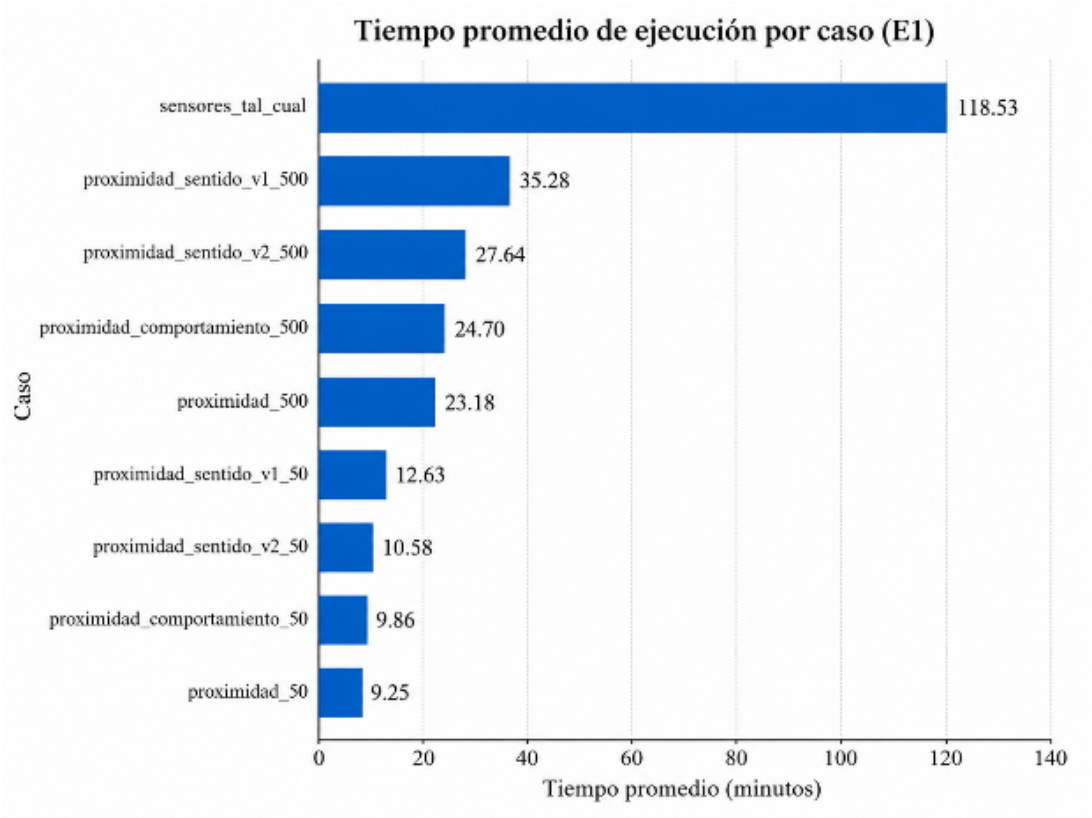

Figura 7.6.: Tiempo promedio de ejecución por caso de nodos en E1.

La Figura 7.6 permite visualizar la diferencia de coste computacional entre las distintas definiciones de nodos. Se observa que `sensores_tal_cual` presenta el mayor tiempo promedio, mientras que las configuraciones agregadas reducen considerablemente el tiempo de ejecución. Entre ellas, `proximidad_500` destaca por mantener un tiempo mucho menor que el caso original y, al mismo tiempo, conservar un buen rendimiento predictivo.

8. CONCLUSIONES

8.1. CONCLUSIONES METODOLÓGICAS

El desarrollo de este trabajo permitió construir y evaluar una metodología para representar la congestión vehicular como un problema grafo-temporal. **El principal aporte metodológico NO se encuentra únicamente en la aplicación de modelos de redes neuronales de grafos, sino en el proceso previo de transformación de los datos:** cálculo de una señal homogénea de congestión, definición de nodos, construcción de aristas y preparación de datasets compatibles con modelos GNN.

La metodología desarrollada demostró que la forma de representar el sistema urbano tiene un impacto directo en los resultados de predicción. En particular, la construcción de aristas mediante correlación temporal produjo mejores resultados que la adyacencia basada únicamente en cercanía espacial (Sección 7.4). Esto indica que, para este problema, conectar nodos que presentan comportamientos similares en sus series de congestión resulta más informativo que conectar nodos solo por proximidad física.

Este hallazgo respalda la hipótesis central:

> la correlación temporal como criterio de adyacencia permite construir grafos menos dependientes de la geografía física, confirmando en la práctica el carácter agnóstico de la metodología.

Además, la estabilidad de los resultados en diferentes configuraciones sugiere que el enfoque podría extrapolarse a otras ciudades con datos de tráfico equivalentes.

Otro resultado metodológico relevante es que:

> la preparación de los datos tuvo más peso que la elección de una arquitectura neuronal específica.

Aunque se evaluaron modelos diferentes, las mejoras más claras aparecieron al modificar la forma de construir el grafo, especialmente el tipo de adyacencia y la definición de nodos. Esto confirma, al menos en este contexto, que en problemas de predicción espaciotemporal, la calidad de la representación de entrada es tan importante como el modelo utilizado.

La comparación entre diferentes definiciones de nodos también permitió concluir que no siempre es conveniente trabajar con la máxima granularidad disponible. El caso de sensores originales conserva toda la infor-

mación, pero implica mayor complejidad computacional. Por el contrario, las representaciones agregadas cercanas a 500 clusters ofrecieron un equilibrio adecuado entre reducción de tamaño del grafo y conservación de información relevante para la predicción.

En conjunto, la principal conclusión metodológica es que:

> la predicción de congestión **no** debe abordarse únicamente como un problema de selección de modelos, sino como un problema de representación.

La metodología propuesta muestra que organizar adecuadamente los datos en forma de grafo, definiendo nodos y relaciones de manera coherente con el comportamiento del tráfico, puede mejorar la capacidad predictiva de distintas arquitecturas GNN.

8.2. CONCLUSIONES TÉCNICAS

Desde el punto de vista técnico, el proyecto permitió construir un flujo completo para transformar datos históricos de tráfico en entradas compatibles con modelos GNN. Este flujo incluyó la carga y depuración de datos, el cálculo del índice de congestión, la generación de agrupaciones de sensores, la construcción de matrices de adyacencia, la preparación de ventanas temporales y el entrenamiento de modelos híbridos de aprendizaje profundo.

Una de las primeras conclusiones técnicas es que fue necesario construir una variable propia de congestión, a partir de intensidad y ocupación (véase la Sección 4.1), este, aportó una señal continua y comparable entre sensores, directamente agregable por nodo y utilizable como variable objetivo en la predicción.

En cuanto a la definición de nodos, los resultados muestran que:

> las configuraciones cercanas a **500 clusters** ofrecieron mejor equilibrio que las configuraciones de **50 clusters**. Las agrupaciones de 50 clusters reducen el tamaño del grafo, pero pueden perder demasiada información espacial. En cambio, las configuraciones de 500 clusters conservan más detalle y, al mismo tiempo, reducen la complejidad frente al caso de sensores tal cual.

Entre los casos evaluados, `proximidad_500` fue una de las configuraciones más sólidas. Esta representación obtuvo buenos resultados predictivos y redujo de forma considerable el coste computacional respecto a trabajar con todos los sensores originales. Esto confirma que una agregación bien ajustada puede ser más eficiente sin perjudicar el rendimiento del modelo.

Respecto a las matrices de adyacencia, **la correlación temporal fue el criterio más competitivo:**

> En el experimento E1, la adyacencia por correlación obtuvo un MAE promedio aproximado de **0,034**, frente a un MAE promedio aproximado de **0,060** en la adyacencia por cercanía (Sección 7.4). Dado que la congestión se mide en una escala entre 0 y 1, esta diferencia muestra que **la forma de construir las aristas tiene un impacto claro sobre el error de predicción.**

En cuanto a los modelos:

> `GCN-LSTM` y `GCN-GRU` fueron las arquitecturas más competitivas en promedio.

`GAT-LSTM` también fue evaluado, pero no mostró una ventaja sistemática frente a las arquitecturas basadas en GCN. No obstante, la diferencia entre modelos fue menor que la diferencia observada al cambiar el tipo de adyacencia o la definición de nodos, lo que orientaría el trabajo futuro a refinar la representación del grafo antes que a explorar nuevas arquitecturas.

El análisis gráfico de predicción frente a valor real mostró que:

> los modelos son capaces de seguir la tendencia general de la congestión.

Sin embargo, también se observó que las predicciones tienden a suavizar algunos picos o cambios bruscos. Esto indica que el modelo aprende patrones temporales generales, pero puede tener más dificultad para anticipar eventos puntuales de congestión intensa.

Finalmente, el análisis de coste computacional confirmó la utilidad de las representaciones agregadas.

> El caso `sensores_tal_cual` presentó el mayor tiempo promedio de ejecución, mientras que configuraciones como `proximidad_500` redujeron de forma notable el tiempo sin perder capacidad predictiva.

Esto refuerza la **conveniencia de trabajar con grafos de tamaño intermedio**, especialmente si la metodología se quiere escalar a periodos más largos o a escenarios operativos.

8.3. LIMITACIONES

La primera limitación está relacionada con el uso de datos históricos. **Los modelos fueron entrenados y evaluados a partir de registros ya almacenados, por lo que el sistema no fue desplegado ni validado en un**

escenario operativo en tiempo real. Esto significa que, aunque la metodología puede proyectarse hacia un sistema de alerta temprana, en este trabajo no se implementó una integración automática con fuentes de datos en vivo.

La segunda limitación se encuentra en la variable de congestión. Al no disponer de `carga` ni `vmed` de forma homogénea (Sección 4.1), se construyó un índice propio a partir de intensidad y ocupación. Esta decisión permitió trabajar con una señal común para todos los sensores válidos, pero implica que **la congestión utilizada en el proyecto es una aproximación metodológica y no una medida oficial directa.**

Otra limitación está asociada a la información utilizada por los modelos. En este trabajo se consideraron principalmente variables derivadas de los datos de tráfico y de la estructura espacial de los puntos de medida. **No se incorporaron variables externas como meteorología, eventos, obras, accidentes, calendario laboral detallado o incidencias viales. Este tipo de información podría ayudar a explicar variaciones bruscas de congestión que no se capturan únicamente con el comportamiento histórico.**

También se observó una limitación en la predicción de picos de congestión. Las gráficas de predicción frente a valor real muestran que los modelos tienden a seguir la tendencia general de la señal, pero pueden suavizar eventos abruptos o subestimar picos locales. Esto indica que **la metodología captura patrones generales, aunque todavía puede mejorar en la anticipación de cambios rápidos o situaciones excepcionales.**

Desde el punto de vista experimental, **el coste computacional condicionó algunas decisiones.** En particular, la evaluación con dos meses de datos se realizó sobre configuraciones seleccionadas, en lugar de repetir todas las combinaciones completas, debido al tiempo requerido para ejecutar los entrenamientos. Esta decisión permitió comparar el efecto de ampliar el histórico temporal en los mejores casos, pero limita la comparación exhaustiva con todos los escenarios posibles.

Por último, aunque la metodología se plantea como agnóstica a la topología urbana, **su validación se realizó exclusivamente sobre datos de Madrid.** Para confirmar plenamente su generalización, sería necesario aplicar el mismo flujo sobre datos de otras ciudades con características urbanas, sensores y patrones de movilidad diferentes. Esto permitiría evaluar si los resultados obtenidos se mantienen en otros entornos urbanos.

8.4. TRABAJO FUTURO

A partir de los resultados obtenidos, una línea de trabajo futuro consiste en evolucionar la metodología hacia un sistema conectado a datos en tiempo real. En este TFM se trabajó con datos históricos, pero la misma lógi-

ca metodológica podría adaptarse a un escenario operativo en el que las mediciones de tráfico se consulten periódicamente, se transformen en una señal de congestión y se utilicen para generar predicciones futuras.

Para ello, sería necesario automatizar la ingesta de datos actuales de tráfico. El flujo futuro podría partir de consultas periódicas a la fuente de datos, con una frecuencia acorde a la actualización disponible. Cada nueva observación debería pasar por las mismas etapas desarrolladas en el proyecto: limpieza, cálculo del índice de congestión, asignación al sensor o cluster correspondiente y actualización de la ventana temporal de entrada del modelo.

Una vez actualizada la ventana temporal, el modelo entrenado podría generar predicciones de congestión para los nodos del grafo en un horizonte futuro. Estas predicciones podrían visualizarse en un panel de control o utilizarse para generar alertas tempranas en zonas con riesgo de congestión. De este modo, la metodología pasaría de ser una herramienta de análisis histórico a convertirse en un componente de apoyo a la gestión proactiva de la movilidad.

Otra línea futura consiste en ampliar el periodo de entrenamiento y evaluación. En este trabajo se realizaron evaluaciones con distintos periodos, incluyendo un mes, dos meses y una semana de abril. Sin embargo, incorporar más meses permitiría capturar mejor patrones estacionales, diferencias entre periodos lectivos y vacacionales, variaciones por día de la semana y cambios asociados a condiciones urbanas específicas. Esto podría mejorar la robustez del modelo y permitir una evaluación más completa de su capacidad de generalización temporal.

También sería relevante incorporar variables externas. Factores como meteorología, eventos masivos, obras, accidentes, incidencias viales o calendario laboral pueden influir en la congestión y explicar cambios bruscos que no siempre se capturan únicamente con las series históricas de intensidad y ocupación. Integrar estas variables podría ayudar a mejorar la predicción de picos y situaciones no recurrentes.

Desde el punto de vista metodológico, una línea interesante sería profundizar en la construcción del grafo por correlación. Los resultados mostraron que este enfoque fue más competitivo que la adyacencia por cercanía, por lo que sería conveniente explorar variantes más avanzadas, como correlaciones dinámicas por franja horaria, grafos dependientes del tiempo o mecanismos que actualicen las relaciones entre nodos a medida que cambian los patrones de tráfico.

Además, tal como se señaló en la Sección 8.3, sería relevante validar la metodología en otras ciudades. Aplicarla a entornos con diferente distribución de sensores, estructura vial y patrones de movilidad permitiría verificar la robustez del enfoque y reforzar su carácter generalizable.

Finalmente, desde la perspectiva del modelado, podrían explorarse arquitecturas adicionales o mejoras sobre las ya implementadas. No obstante, los resultados de este trabajo sugieren que el avance más prometedor no está únicamente en cambiar de modelo, sino en seguir refinando la representación grafo-temporal de entrada. Por tanto,

> el trabajo futuro debería mantener como eje principal la calidad de la construcción del grafo, combinando mejores datos, relaciones más informativas y mecanismos de actualización temporal.

En síntesis, la evolución natural del proyecto consiste en avanzar hacia un sistema predictivo más completo, capaz de operar con datos actualizados, generar alertas tempranas y adaptarse a diferentes contextos urbanos. Esta línea permitiría transformar la metodología desarrollada en una herramienta práctica para apoyar la toma de decisiones en movilidad urbana.

9. VALORACIÓN ÉTICA DEL PROYECTO

Es importante resaltar que desde este curso, los estudiantes debéis añadir una valoración ética de vuestro proyecto, siguiendo las directrices que habéis recibido y trabajado en la asignatura de Ética.

BIBLIOGRAFÍA

[1] Federal Highway Administration, “Traffic Congestion and Reliability: Trends and Advanced Strategies for Congestion Mitigation,” U.S. Department of Transportation, Tech. Rep., 2005.

[2] ——, “Status of the Nation’s Highways, Bridges, and Transit: Conditions and Performance. Chapter 4: Mobility and Access,” U.S. Department of Transportation, Tech. Rep., 2019.

[3] P. Ryus, M. Vandehey, L. Elefteriadou, R. G. Dowling, and B. K. Ostrom, “Highway Capacity Manual 2010,” *TR News*, vol. 273, pp. 45–48, 2011.

[4] Ayuntamiento de Madrid, “Descripción del conjunto de datos de tráfico: histórico de datos del tráfico desde 2013,” D. G. Gestión y Vigilancia de la Circulación, S. G. de Regulación de la Circulación y del Servicio del Taxi, Departamento de Tecnologías del Tráfico, 2023.

[5] B. Coifman, “Estimating Travel Times and Vehicle Trajectories using Loop Detector Data,” *Transportation Research Part A: Policy and Practice*, vol. 36, no. 4, pp. 351–364, 2002.

[6] M. S. Lloret, “Modelado espacio-temporal con redes neuronales para la predicción de fenómenos ambientales,” Ph.D. dissertation, Universidad de Alicante, s. f.

[7] L. Zhao, Y. Song, C. Zhang, Y. Liu, P. Wang, T. Lin, M. Deng, and H. Li, “T-GCN: A Temporal Graph Convolutional Network for Traffic Prediction,” arXiv preprint arXiv:1811.05320, 2018.

[8] Z. Cui, K. Henrickson, R. Ke, and Y. Wang, “Traffic Graph Convolutional Recurrent Neural Network: A Deep Learning Framework for Network-Scale Traffic Learning and Forecasting,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 21, no. 11, pp. 4883–4894, 2019.

[9] T. N. Kipf and M. Welling, “Semi-Supervised Classification with Graph Convolutional Networks,” in *International Conference on Learning Representations*, 2017.

[10] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, “Graph Attention Networks,” in *International Conference on Learning Representations*, 2018.

[11] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[12] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734.

[13] D. Vélez-Serrano, A. Álvaro-Meca, F. Sebastián-Huerta, and J. Vélez-Serrano, "Spatio-Temporal Traffic Flow Prediction in Madrid: An Application of Residual Convolutional Neural Networks," *Mathematics*, vol. 9, no. 9, p. 1068, 2021.

[14] J. A. Hernández, "Estimación de tráfico en las calles de Madrid mediante inteligencia artificial," Trabajo de Fin de Máster, Universidad Complutense de Madrid, 2023.

[15] J. Moral-Carcedo, "Predicting Traffic Intensity in the Urban Area of Madrid: Integrating Route Network Topology into a Machine-Learning Model," *Engineering Applications of Artificial Intelligence*, vol. 137, p. 109154, 2024.

[16] I. Gómez and S. Ilarri, "Advanced Prediction of Traffic at Different Temporal Scales using Heterogeneous Data Sources," *IEEE Open Journal of Intelligent Transportation Systems*, vol. 6, pp. 1539–1550, 2025.

[17] Y. Li, R. Yu, C. Shahabi, and Y. Liu, "Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting," in *International Conference on Learning Representations (ICLR)*, 2018.

[18] B. Yu, H. Yin, and Z. Zhu, "Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting," in *Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI)*, 2018.

[19] C. Zheng, X. Fan, C. Wang, and J. Qi, "GMAN: A Graph Multi-Attention Network for Traffic Prediction," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 1, 2020, pp. 1234–1241.

A. RESULTADOS COMPLETOS DE LAS EJECUCIONES FINALES

En este anexo se incluyen las tablas completas de ranking generadas en las ejecuciones finales de evaluación. Estas tablas complementan el análisis presentado en el Capítulo 7 y permiten consultar todas las configuraciones evaluadas, incluyendo caso de nodos, tipo de adyacencia, modelo, métricas de prueba y tiempo de ejecución.

A.1. RANKING COMPLETO DEL EXPERIMENTO E1: UN MES DE DATOS

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_500	correlacion	GCN_LSTM	0,0236	0,0539	20,21
proximidad_500	correlacion	GCN_GRU	0,0243	0,0534	20,06
sensores_tal_cual	correlacion	GCN_GRU	0,0248	0,0643	104,95
sensores_tal_cual	correlacion	GCN_LSTM	0,0250	0,0644	110,17
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0250	0,0569	31,45
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0252	0,0560	32,15
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0256	0,0577	24,23
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0262	0,0545	24,19
proximidad_sentido_v2_50	correlacion	GCN_LSTM	0,0272	0,0602	8,81
proximidad_sentido_v2_50	correlacion	GCN_GRU	0,0282	0,0606	8,86
proximidad_sentido_v1_50	correlacion	GCN_LSTM	0,0287	0,0621	10,67
proximidad_500	correlacion	GAT_LSTM	0,0295	0,0643	28,72
proximidad_sentido_v1_50	correlacion	GCN_GRU	0,0299	0,0623	10,78
sensores_tal_cual	correlacion	GAT_LSTM	0,0299	0,0742	143,30
proximidad_50	correlacion	GCN_LSTM	0,0306	0,0656	7,55
proximidad_sentido_v1_500	correlacion	GAT_LSTM	0,0307	0,0673	42,56
proximidad_50	correlacion	GCN_GRU	0,0315	0,0660	7,71
proximidad_sentido_v2_500	correlacion	GAT_LSTM	0,0333	0,0688	34,61
proximidad_500	cercania	GCN_LSTM	0,0351	0,0672	20,22
proximidad_comportamiento_500	correlacion	GCN_LSTM	0,0375	0,0814	21,60
proximidad_50	correlacion	GAT_LSTM	0,0378	0,0745	12,50
proximidad_comportamiento_500	correlacion	GCN_GRU	0,0387	0,0814	22,07
proximidad_sentido_v2_500	cercania	GCN_LSTM	0,0399	0,0782	24,17
proximidad_sentido_v1_500	cercania	GCN_LSTM	0,0404	0,0797	31,22
proximidad_sentido_v1_50	correlacion	GAT_LSTM	0,0405	0,0788	16,43
proximidad_500	cercania	GCN_GRU	0,0410	0,0692	21,02
proximidad_sentido_v2_500	cercania	GCN_GRU	0,0411	0,0767	24,06
proximidad_sentido_v2_50	correlacion	GAT_LSTM	0,0424	0,0797	14,00
proximidad_500	cercania	GAT_LSTM	0,0430	0,0777	28,83
sensores_tal_cual	cercania	GCN_LSTM	0,0438	0,0917	107,05

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_sentido_v1_500	cercania	GAT_LSTM	0,0439	0,0875	42,21
proximidad_sentido_v1_500	cercania	GCN_GRU	0,0440	0,0788	32,10
sensores_tal_cual	cercania	GCN_GRU	0,0441	0,0919	103,54
proximidad_sentido_v2_500	cercania	GAT_LSTM	0,0446	0,0851	34,59
sensores_tal_cual	cercania	GAT_LSTM	0,0480	0,0994	142,18
proximidad_comportamiento_500	correlacion	GAT_LSTM	0,0480	0,0978	30,69
proximidad_sentido_v1_50	cercania	GCN_LSTM	0,0491	0,0933	10,67
proximidad_sentido_v1_50	cercania	GCN_GRU	0,0495	0,0936	10,65
proximidad_comportamiento_50	correlacion	GCN_GRU	0,0545	0,0954	8,13
proximidad_comportamiento_50	correlacion	GCN_LSTM	0,0552	0,0997	8,16
proximidad_sentido_v2_50	cercania	GCN_GRU	0,0565	0,0960	8,89
proximidad_sentido_v1_50	cercania	GAT_LSTM	0,0567	0,1043	16,55
proximidad_50	cercania	GCN_LSTM	0,0580	0,1011	7,60
proximidad_sentido_v2_50	cercania	GCN_LSTM	0,0591	0,1037	8,82
proximidad_50	cercania	GCN_GRU	0,0595	0,0996	7,68
proximidad_comportamiento_50	correlacion	GAT_LSTM	0,0628	0,1107	13,23
proximidad_50	cercania	GAT_LSTM	0,0641	0,1093	12,45
proximidad_sentido_v2_50	cercania	GAT_LSTM	0,0646	0,1099	14,07
proximidad_comportamiento_500	cercania	GCN_LSTM	0,0847	0,1347	21,43
proximidad_comportamiento_500	cercania	GCN_GRU	0,0879	0,1335	21,88
proximidad_comportamiento_50	cercania	GAT_LSTM	0,0882	0,1326	13,27
proximidad_comportamiento_500	cercania	GAT_LSTM	0,0949	0,1425	30,55
proximidad_comportamiento_50	cercania	GCN_GRU	0,1171	0,1645	8,16
proximidad_comportamiento_50	cercania	GCN_LSTM	0,1224	0,1662	8,23

Tabla A.1.: Ranking completo de configuraciones del experimento E1.

A.2. RANKING COMPLETO DEL EXPERIMENTO E3: UNA SEMANA DE ABRIL

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_500	correlacion	GCN_LSTM	0,0221	0,0500	41,99
proximidad_500	correlacion	GCN_GRU	0,0236	0,0507	41,66
sensores_tal_cual	correlacion	GCN_LSTM	0,0251	0,0638	274,34
sensores_tal_cual	correlacion	GCN_GRU	0,0253	0,0636	240,09
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0254	0,0571	96,13
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0263	0,0532	54,72
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0267	0,0535	53,63
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0267	0,0577	96,95
proximidad_500	correlacion	GAT_LSTM	0,0278	0,0614	60,09
sensores_tal_cual	correlacion	GAT_LSTM	0,0293	0,0707	343,37

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_sentido_v1_500	correlacion	GAT_LSTM	0,0310	0,0671	129,09
proximidad_sentido_v1_50	correlacion	GCN_LSTM	0,0311	0,0631	23,50
proximidad_sentido_v2_500	correlacion	GAT_LSTM	0,0316	0,0668	75,26
proximidad_sentido_v1_50	correlacion	GCN_GRU	0,0318	0,0626	23,68
proximidad_500	cercania	GCN_GRU	0,0338	0,0667	41,12
proximidad_sentido_v2_50	correlacion	GCN_LSTM	0,0341	0,0646	18,46
proximidad_sentido_v2_50	correlacion	GCN_GRU	0,0350	0,0626	18,87
proximidad_500	cercania	GCN_LSTM	0,0362	0,0649	41,39
proximidad_50	correlacion	GCN_LSTM	0,0365	0,0793	16,55
proximidad_sentido_v1_500	cercania	GCN_GRU	0,0373	0,0747	93,90
proximidad_500	cercania	GAT_LSTM	0,0374	0,0659	59,17
proximidad_sentido_v1_500	cercania	GCN_LSTM	0,0377	0,0752	95,43
proximidad_sentido_v2_500	cercania	GCN_GRU	0,0383	0,0719	53,04
proximidad_comportamiento_500	correlacion	GCN_LSTM	0,0393	0,0846	46,60
proximidad_50	correlacion	GCN_GRU	0,0394	0,0775	16,81
proximidad_sentido_v2_500	cercania	GCN_LSTM	0,0399	0,0751	54,26
sensores_tal_cual	cercania	GCN_LSTM	0,0399	0,0877	268,67
proximidad_sentido_v2_50	correlacion	GAT_LSTM	0,0402	0,0752	28,19
sensores_tal_cual	cercania	GCN_GRU	0,0406	0,0875	236,47
proximidad_comportamiento_500	correlacion	GCN_GRU	0,0408	0,0863	46,49
proximidad_sentido_v1_50	correlacion	GAT_LSTM	0,0408	0,0747	35,30
proximidad_sentido_v1_500	cercania	GAT_LSTM	0,0434	0,0820	127,05
proximidad_sentido_v2_500	cercania	GAT_LSTM	0,0446	0,0792	74,88
sensores_tal_cual	cercania	GAT_LSTM	0,0448	0,0944	343,41
proximidad_50	correlacion	GAT_LSTM	0,0458	0,0915	25,61
proximidad_sentido_v1_50	cercania	GCN_LSTM	0,0481	0,0883	24,13
proximidad_sentido_v1_50	cercania	GCN_GRU	0,0493	0,0889	24,43
proximidad_comportamiento_500	correlacion	GAT_LSTM	0,0499	0,0971	65,74
proximidad_sentido_v2_50	cercania	GCN_GRU	0,0549	0,0935	21,18
proximidad_sentido_v2_50	cercania	GCN_LSTM	0,0556	0,0939	23,55
proximidad_comportamiento_50	correlacion	GCN_GRU	0,0570	0,0985	18,03
proximidad_sentido_v1_50	cercania	GAT_LSTM	0,0572	0,0955	35,79
proximidad_comportamiento_50	correlacion	GCN_LSTM	0,0589	0,1038	17,74
proximidad_50	cercania	GCN_LSTM	0,0592	0,1034	17,16
proximidad_50	cercania	GAT_LSTM	0,0594	0,1055	25,81
proximidad_sentido_v2_50	cercania	GAT_LSTM	0,0602	0,1012	28,45
proximidad_50	cercania	GCN_GRU	0,0611	0,0996	17,03
proximidad_comportamiento_50	correlacion	GAT_LSTM	0,0697	0,1197	26,95
proximidad_comportamiento_500	cercania	GCN_LSTM	0,0888	0,1392	45,95
proximidad_comportamiento_500	cercania	GCN_GRU	0,0908	0,1386	45,79
proximidad_comportamiento_50	cercania	GAT_LSTM	0,0942	0,1292	27,22
proximidad_comportamiento_500	cercania	GAT_LSTM	0,0975	0,1462	65,10
proximidad_comportamiento_50	cercania	GCN_GRU	0,1293	0,1693	18,20

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	Tiempo (min)
proximidad_comportamiento_50	cercania	GCN_LSTM	0,1325	0,1704	17,75

Tabla A.2.: Ranking completo de configuraciones del experimento E3.

A.3. RANKING COMPLETO DEL EXPERIMENTO E4: TRANSFORMACIÓN INVERSA Y MAPE

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	MAPE prueba	Tiempo (min)
proximidad_sentido_v2_500	correlacion	GCN_GRU	0,0290	0,0617	3,85	23,10
proximidad_500	correlacion	GCN_LSTM	0,0302	0,0589	3,92	18,28
proximidad_500	correlacion	GCN_GRU	0,0297	0,0604	3,94	19,45
proximidad_500	correlacion	GAT_LSTM	0,0300	0,0650	4,04	26,44
proximidad_sentido_v2_500	correlacion	GCN_LSTM	0,0340	0,0615	4,42	22,99
proximidad_sentido_v1_500	correlacion	GAT_LSTM	0,0317	0,0683	4,43	40,79
proximidad_sentido_v1_500	correlacion	GCN_GRU	0,0315	0,0713	4,50	31,89
proximidad_sentido_v2_500	correlacion	GAT_LSTM	0,0334	0,0697	4,63	32,18
proximidad_sentido_v1_500	correlacion	GCN_LSTM	0,0337	0,0704	4,68	30,80
sensores_tal_cual	correlacion	GCN_LSTM	0,0328	0,0715	4,79	119,65
proximidad_sentido_v1_50	correlacion	GCN_GRU	0,0336	0,0662	4,83	9,38
sensores_tal_cual	correlacion	GCN_GRU	0,0343	0,0718	4,97	110,76
proximidad_sentido_v2_50	correlacion	GCN_GRU	0,0355	0,0676	5,02	7,69
proximidad_sentido_v1_50	correlacion	GCN_LSTM	0,0347	0,0685	5,03	9,47
proximidad_50	correlacion	GCN_LSTM	0,0343	0,0697	5,06	6,59
proximidad_50	correlacion	GCN_GRU	0,0351	0,0694	5,12	6,61
proximidad_sentido_v2_50	correlacion	GCN_LSTM	0,0375	0,0680	5,19	7,73
proximidad_500	cercania	GAT_LSTM	0,0418	0,0778	5,53	26,47
proximidad_500	cercania	GCN_GRU	0,0433	0,0810	5,83	19,32
proximidad_sentido_v1_500	cercania	GCN_LSTM	0,0430	0,0817	5,91	30,62
proximidad_500	cercania	GCN_LSTM	0,0460	0,0837	6,11	18,26
proximidad_sentido_v1_500	cercania	GAT_LSTM	0,0448	0,0878	6,32	40,35
proximidad_sentido_v2_500	cercania	GAT_LSTM	0,0472	0,0867	6,49	28,24
proximidad_sentido_v2_50	correlacion	GAT_LSTM	0,0463	0,0857	6,73	12,51
proximidad_sentido_v1_500	cercania	GCN_GRU	0,0486	0,0907	6,80	31,27
proximidad_sentido_v1_50	correlacion	GAT_LSTM	0,0498	0,0869	6,99	14,40
proximidad_sentido_v2_500	cercania	GCN_LSTM	0,0519	0,0903	6,99	22,75
proximidad_comportamiento_500	correlacion	GCN_GRU	0,0456	0,0870	6,99	20,65
proximidad_sentido_v2_500	cercania	GCN_GRU	0,0521	0,0906	7,02	22,87
sensores_tal_cual	cercania	GCN_GRU	0,0475	0,0948	7,03	109,03
sensores_tal_cual	cercania	GCN_LSTM	0,0481	0,0951	7,08	118,22
sensores_tal_cual	cercania	GAT_LSTM	0,0476	0,1001	7,34	148,03

Caso de nodos	Adyacencia	Modelo	MAE prueba	RMSE prueba	MAPE prueba	Tiempo (min)
proximidad_50	correlacion	GAT_LSTM	0,0505	0,0951	7,55	11,06
proximidad_comportamiento_500	correlacion	GCN_LSTM	0,0502	0,0904	7,58	19,83
proximidad_comportamiento_500	correlacion	GAT_LSTM	0,0502	0,0982	7,93	28,06
proximidad_sentido_v1_50	cercania	GCN_LSTM	0,0570	0,0982	8,14	9,36
proximidad_sentido_v1_50	cercania	GCN_GRU	0,0589	0,0986	8,35	9,35
proximidad_sentido_v1_50	cercania	GAT_LSTM	0,0585	0,1037	8,51	14,39
proximidad_sentido_v2_50	cercania	GCN_GRU	0,0598	0,1036	8,65	7,73
proximidad_sentido_v2_50	cercania	GCN_LSTM	0,0652	0,1057	9,13	7,79
proximidad_50	cercania	GCN_GRU	0,0647	0,1057	9,24	6,97
proximidad_comportamiento_50	correlacion	GCN_GRU	0,0613	0,0985	9,38	7,19
proximidad_sentido_v2_50	cercania	GAT_LSTM	0,0647	0,1107	9,42	12,58
proximidad_50	cercania	GCN_LSTM	0,0633	0,1158	9,62	7,33
proximidad_50	cercania	GAT_LSTM	0,0689	0,1122	9,89	11,09
proximidad_comportamiento_50	correlacion	GCN_LSTM	0,0746	0,1090	11,19	7,14
proximidad_comportamiento_50	correlacion	GAT_LSTM	0,0717	0,1182	11,71	11,86
proximidad_comportamiento_500	cercania	GCN_GRU	0,0885	0,1367	13,32	20,61
proximidad_comportamiento_500	cercania	GAT_LSTM	0,0944	0,1427	14,23	28,05
proximidad_comportamiento_500	cercania	GCN_LSTM	0,1056	0,1421	15,15	19,81
proximidad_comportamiento_50	cercania	GCN_LSTM	0,1309	0,1727	20,57	7,14
proximidad_comportamiento_50	cercania	GCN_GRU	0,1337	0,1743	20,94	7,21
proximidad_comportamiento_50	cercania	GAT_LSTM	0,1332	0,1770	21,18	11,89

Tabla A.3.: Ranking completo de configuraciones del experimento E4.

B. GRÁFICAS DE MAE POR ADYACENCIA, NODO Y MODELO

En este anexo se incluyen las gráficas complementarias de MAE por tipo de adyacencia, definición de nodo y arquitectura neuronal. Estas figuras amplían el análisis presentado en las Secciones 7.4, 7.5 y 7.6.

B.1. MAE POR ADYACENCIA

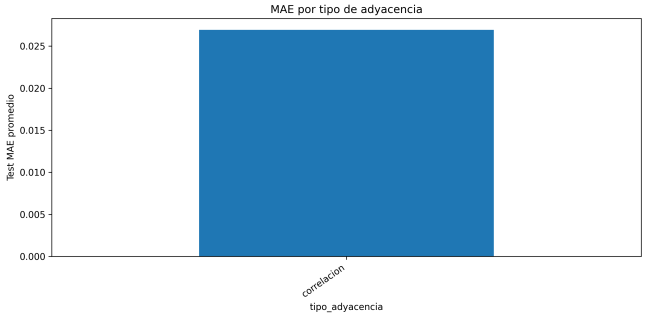

(a) Experimento E2

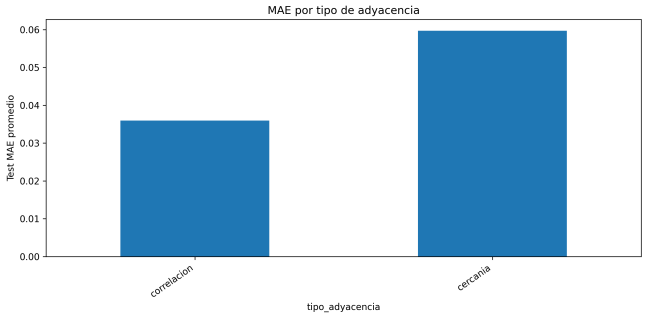

(b) Experimento E3

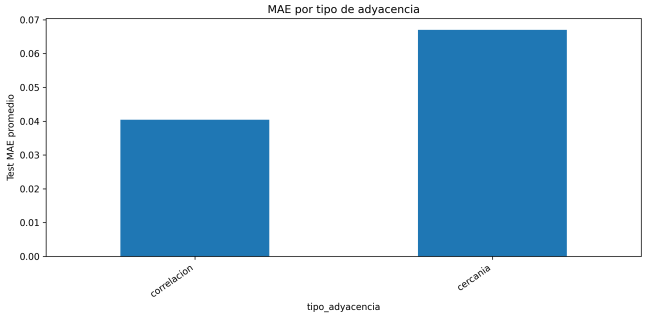

(c) Experimento E4

Figura B.1.: MAE por tipo de adyacencia en los experimentos E2, E3 y E4.

B.2. MAE POR CASO DE NODO

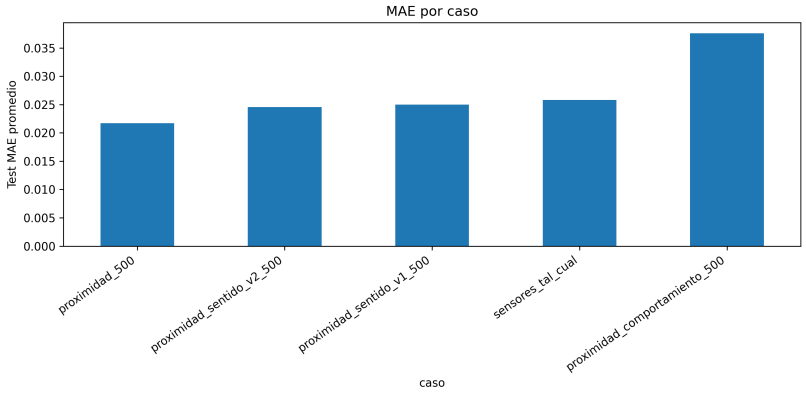

(a) Experimento E2

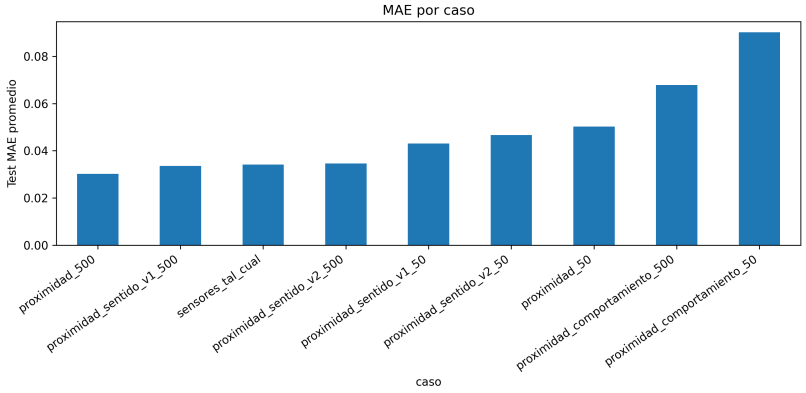

(b) Experimento E3

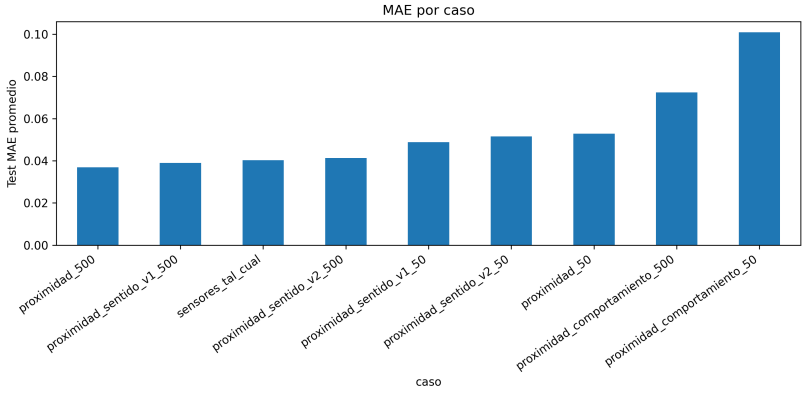

(c) Experimento E4

Figura B.2.: MAE por caso de nodo en los experimentos E2, E3 y E4.

B.3. MAE POR MODELO

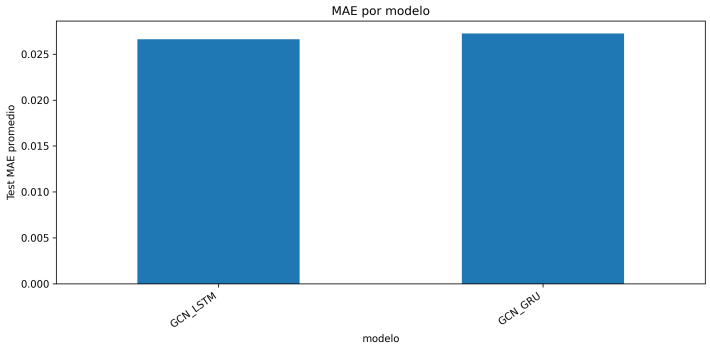

(a) Experimento E2

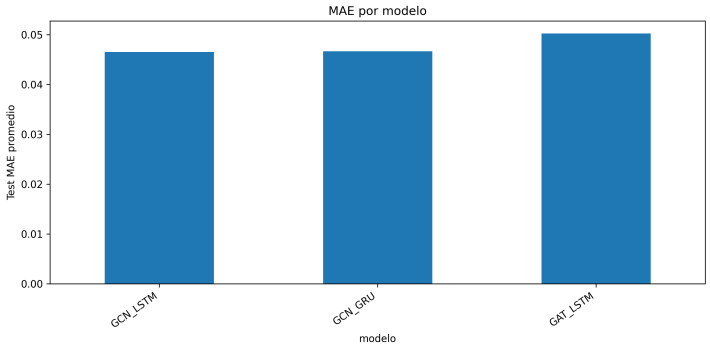

(b) Experimento E3

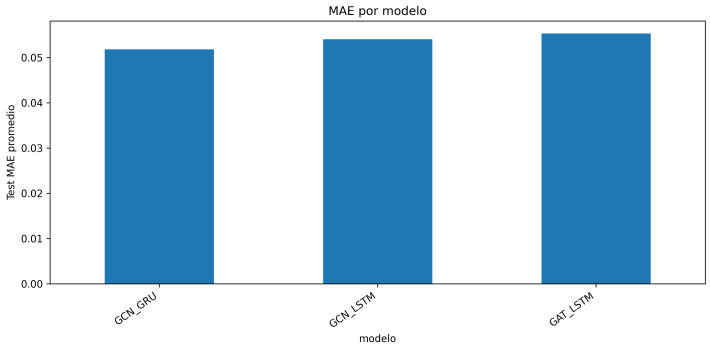

(c) Experimento E4

Figura B.3.: MAE por modelo en los experimentos E2, E3 y E4.

C. GRÁFICAS DE PREDICCIÓN FRENTE A VALOR REAL

En este anexo se incluyen gráficas complementarias de predicción frente a valor real para distintos nodos y configuraciones experimentales. Estas figuras amplían el análisis gráfico presentado en la Sección 7.7.

C.1. EXPERIMENTO E1

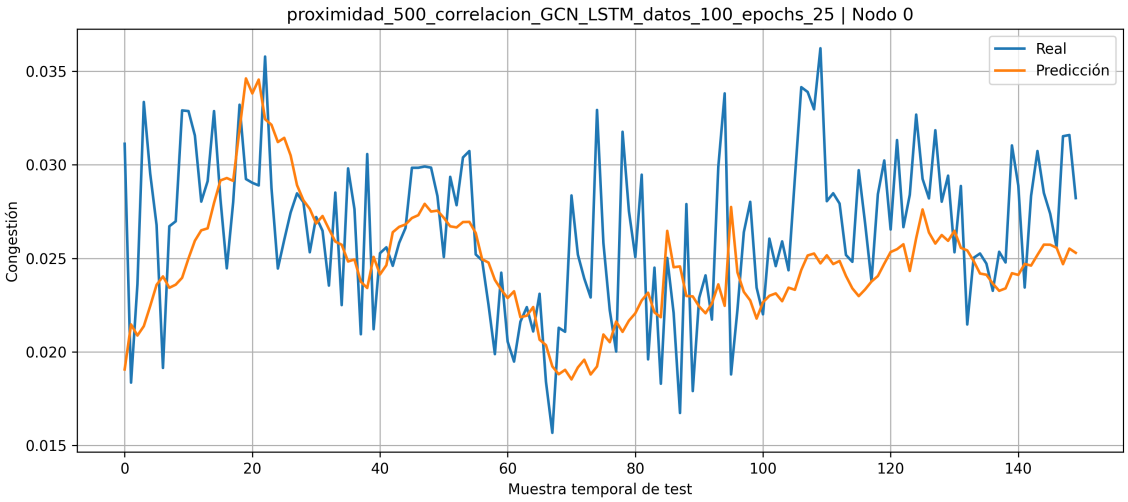

(a) Primer nodo analizado en el experimento E1

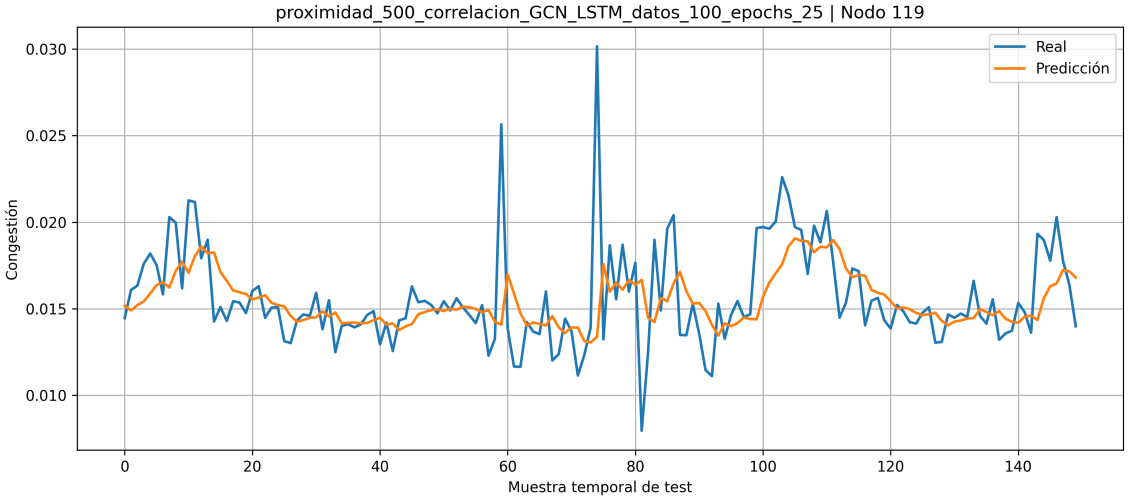

(b) Segundo nodo analizado en el experimento E1

Figura C.1.: Gráficas de predicción frente a valor real para el experimento E1.

C.2. EXPERIMENTO E2

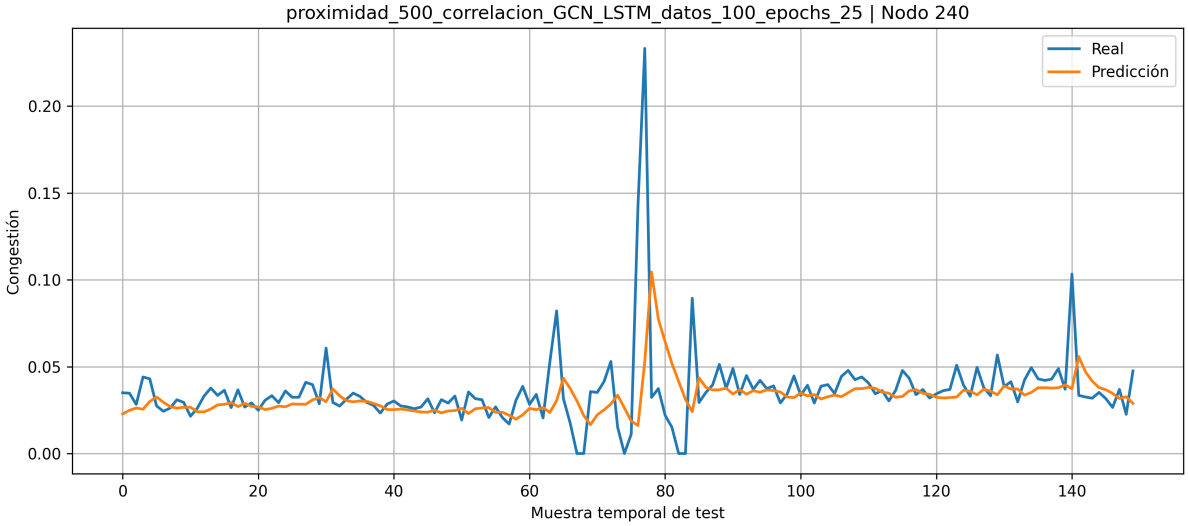

(a) Primer nodo analizado en el experimento E2

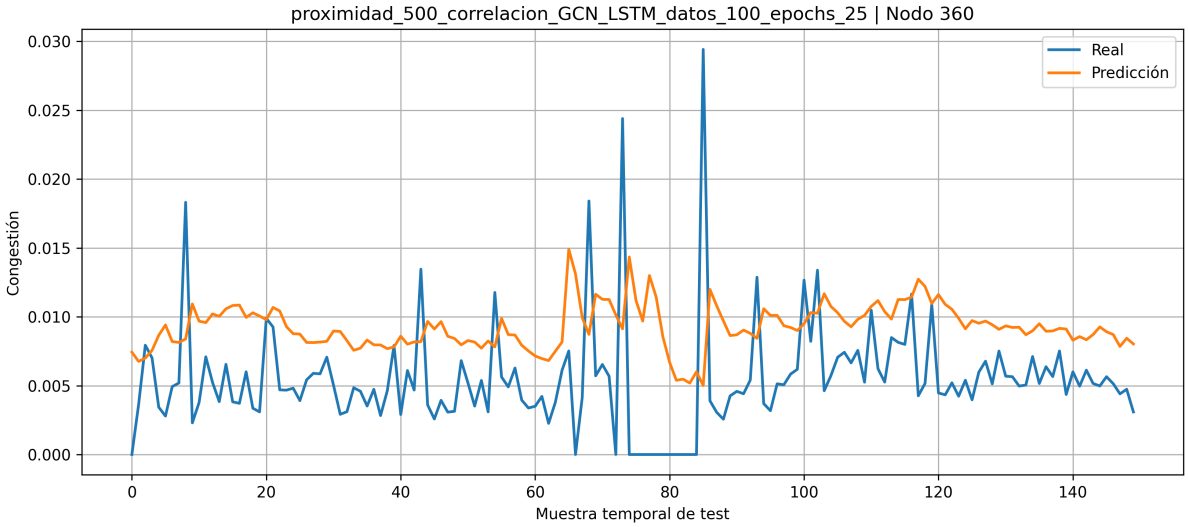

(b) Segundo nodo analizado en el experimento E2

Figura C.2.: Gráficas de predicción frente a valor real para el experimento E2.

C.3. EXPERIMENTO E4

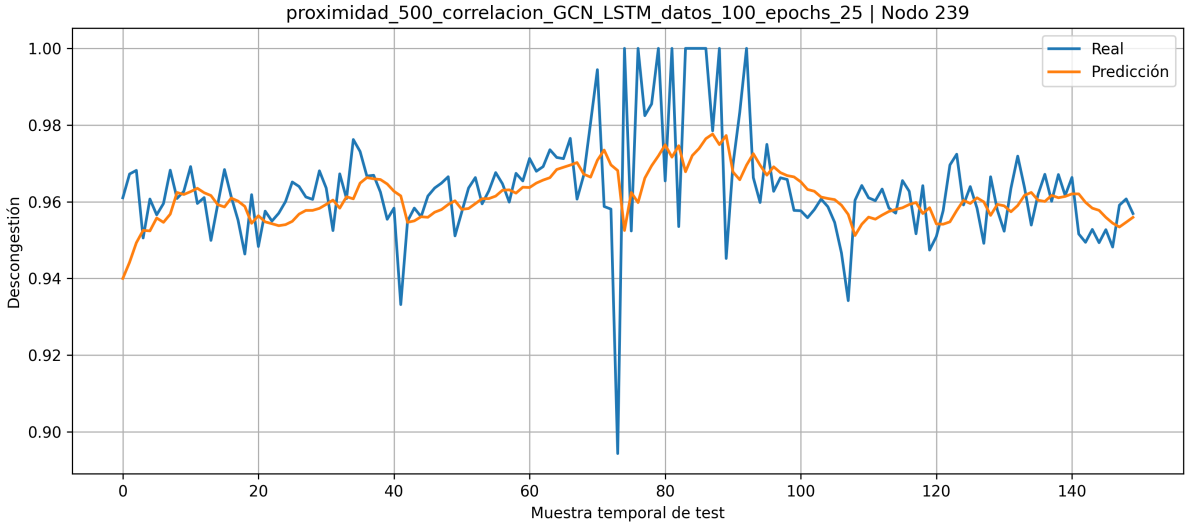

(a) Primer nodo analizado en el experimento E4

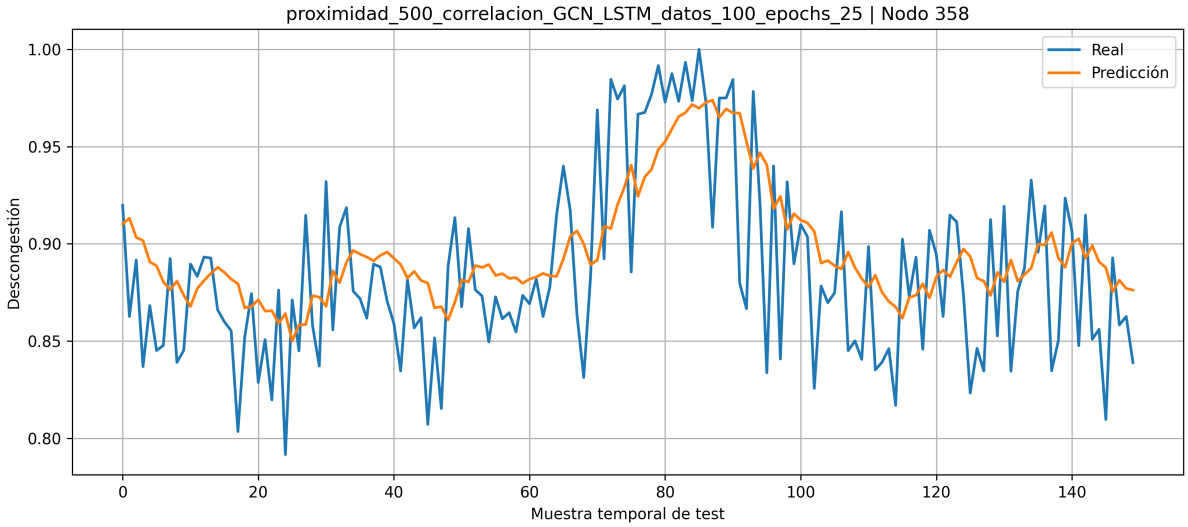

(b) Segundo nodo analizado en el experimento E4

Figura C.3.: Gráficas de predicción frente a valor real para el experimento E4.